报告正文（2026版）

参照以下提纲撰写，要求内容翔实、清晰，层次分明，标题突出。**申请书正文原则上不超过 30 页，鼓励简洁表达。请勿删除或改动下述提纲标题及括号中的文字。**

（一）立项依据：

（为什么要开展此项研究，研究的科学技术价值如何）

1.1 研究背景与意义

项目名称：面向长程多步骤智能体的自适应上下文压缩、动态卸载与按需证据恢复研究（ACORE）。本项目围绕 CCF—快手大模型探索者基金课题“Agent 上下文工程：面向多步骤任务的上下文压缩与卸载技术研究”，研究有限上下文下的长程行动可靠性。拟以现有大语言模型为执行主体，建立能够保留任务状态、按需回取有效证据并控制总调用开销的上下文管理方法。

多步骤智能体需要持续读取工具结果、维护未完成目标，并根据环境反馈修订行动。ReAct 将推理与行动交替组织，使模型能够利用外部观察推进任务 [1]；Toolformer 和 ToolLLM 进一步展示了学习工具选择与接口使用的可行性 [2, 3]。这些能力使智能体可承担信息检索、代码修改和跨工具协作，也使任务历史不断累积。一次检索可能返回多篇文档，一次测试可能产生长日志；只有少量信息与当前动作相关，而早先出现的约束仍可能决定后续操作是否正确。

例如，一个拟构建的跨工具测试任务要求智能体核对订单状态、读取适用政策并更新记录。早期观察包含对象标识、状态版本和禁止重复处理的约束，中间插入大量无关日志，后续政策又发生更新。若压缩只留下“已核对订单”这一概括，系统可能忘记适用对象或再次执行已完成动作；若恢复时取回内容相似的旧政策，即使字节完整，也可能作出不再满足当前条件的操作。这一例子是研究情境示意，不代表已有企业数据或前期实验。它揭示了需要同时回答的三个问题：压缩后哪些状态仍应可见，卸载证据如何恢复为当前可用的信息，以及这一过程是否值得付出额外成本。

上下文管理的价值因而包含两个相互制约的方面。一方面，减少工具噪声和重复历史有望降低资源消耗，缓解关键信息被淹没的问题；另一方面，压缩可能损失对象关系、时间条件和行动前提，使错误在长程执行中累积。Lost in the Middle 发现

关键信息位置能够影响长上下文任务表现[4]，说明名义窗口长度不能代替有效利用能力。但不同模型与任务的敏感性并不相同，不能据此推断所有长历史都应被强压缩。需要将任务状态、证据更新和资源约束放在同一实验条件下分析，寻找能够保持可靠行动的压缩范围。

本研究的科学价值在于解释**压缩后保留的动作依赖、回取证据的当前有效性与任务失败风险之间的关系**，并用受控干预检验这一关系。技术价值在于形成可接入现有文本与工具调用智能体的上下文管理原型，给出何时应压缩、何时值得恢复、何时应保留完整证据的可复核依据。公开环境中的可重复结论构成核心交付，企业业务验证在数据和接口授权落实后开展。

1.2 国内外研究现状及发展动态分析

提示压缩为资源节省提供了方法基础，但跨步信息价值需要另外判断。Selective Context 依据自信息量过滤内容[5]；LLMLingua 通过预算控制与逐词筛选压缩提示[6]，LongLLMLingua 进一步考虑查询相关性、信息密度和位置偏差[7]。LLMLingua-2 将保留决策蒸馏为较小模型的词级分类任务，以降低压缩开销并改善跨任务适用性[8]。在检索增强场景中，RECOMP 联合使用文本压缩与选择性增强，使送入主模型的内容更紧凑[9]。这些方法适合用作本项目的轻量基线，但静态问句中的信息显著性未必等价于未来动作所需的信息价值；将它们直接用于长程轨迹时，需要检验被删除的内容是否参与尚未完成的依赖关系。

轨迹压缩已经开始显式利用任务状态与失败反馈。ACON 针对观察和历史记录联合压缩，利用失败案例改进自然语言压缩指南，并研究小模型压缩器蒸馏[10]。它已关注保留关键环境信息，不能将“从文本压缩走向任务状态保持”笼统作为本项目独有贡献。AgentFold 通过细粒度凝练与跨步骤合并形成多尺度状态摘要，将主动上下文整理与任务行动结合[11]。两者分别提供失败驱动和轨迹折叠的直接比较对象。值得进一步追问的是，显式保留未完成动作的证据依赖，是否在相同摘要长度与候选证据条件下仍能降低后续违例；如果作用只是增加了上下文长度或查询次数，就不能将其归结为新的保真机制。

长期记忆与按需原文回取已有多种实现。MemoryBank 通过更新和遗忘机制组织历史信息[12]；Generative Agents 将经历记录、反思和动态检索结合[13]。MemGPT 借鉴分层存储，在工作上下文与外部记忆之间移动信息[14]。ReadAgent 生成关联原文位置的摘要记忆，再按任务需要回读原始段落[15]，已经覆盖“保留概要、按需恢复细节”的基本思路。A-MEM 通过笔记链接和记忆演化组织信息[16]，Mem0 研究

结构化抽取、整合和检索[17]。因此，可寻址存储、摘要回读或记忆图结构本身均不足以支撑本申请的创新论断。

检索增强生成和稠密检索为外部证据访问提供基础[18, 19]，Self-RAG将检索和反思与任务需求结合[20]。然而，对会修改环境的任务，语义相关的片段仍可能描述旧状态。近期MemStrata已直接讨论检索记忆的时间有效性[21]；PLACEMEM包含版本化记忆、来源信息和失效传播，并讨论算力与记忆组织的关系[22]；Agent Zero Memory进一步研究来源可追溯的长期记忆[23]。最新的Invalidation Contracts已讨论带版本信息的记忆失效与使用规则[24]，From Faulty Memories to Corrected Actions把记忆与动作关系用于纠错及选择性回放[25]。这些工作要求本项目将问题收窄到**压缩造成的动作依赖缺失如何与恢复证据的有效性共同影响真实操作**，而不能把版本管理或来源追溯单独包装成新机制。

统一记忆调度已进入学习型决策阶段，仍需检验总开销下的收益边界。Reflexion表明自然语言反馈能够影响后续尝试[26]；Memory-R1利用结果反馈学习记忆管理和选用[27]；AgeMem将长期与短期记忆操作纳入同一策略，研究渐进训练与步骤级奖励[28]。ContextBudget已明确研究预算约束下的长程搜索上下文管理[29]。本项目不以“统一压缩、卸载和恢复”这一结构名称主张原创性，而关注在固定执行模型后，动作依赖和证据有效性带来的可靠性改善能否覆盖压缩器、检索、验证及重试成本。What Does Context Compression Cost an Agent已指出压缩后的重新取证可能增加交互代价[30]。因此，全开销统计属于必要比较原则，拟研究的增量是元数据不完全可见时，有限预算应怎样分配给依赖保留与主动重查。

评价对象正从长文理解扩展到记忆与交互终态。LongBench为双语长上下文理解提供多任务测试[31]，RULER通过多跳追踪和信息聚合检验超出简单查找的能力[32]。LongMemEval覆盖信息抽取、多会话推理、时间推理、知识更新和拒答[33]，LoCoMo考察长期会话记忆[34]。这些测试有助于定位压缩与恢复错误，但问答正确不能直接证明工具操作正确。AppWorld使用可控应用环境及数据库终态测试判断任务是否完成[35]，WebArena提供可复现的网页交互环境[36]。AgentBench支持跨环境能力诊断[37]，SWE-bench和GAIA分别提供代码修改及多工具任务的扩展评测参照[38, 39]。τ-bench对规则遵从与多次运行可靠性的评价[40]进一步说明，任务完成率、重复运行稳定性和过程指标需要分别报告。

1.3 现有研究的不足

现有工作留下的研究空间，主要体现在**机制证据的连接**。压缩研究常报告长度和终态表现，记忆研究常报告检索或问答表现，版本管理研究则强调更新和失效处理。对连续操作环境，需要进一步区分：压缩是否删去了动作前提，检索是否遗漏正确片段，候选证据是否已经过期，以及执行模型在获得有效证据后是否仍选择错误动作。只有将这些环节分离，才可能判断改进来自何处、何时失效。本项目把这一点视为在本次已核验文献集合上的研究切入判断，不宣称相关问题从未被研究。

第二，关于可恢复性的论证容易混合不同层次。外部存储保留原文，只能提供重新读取的可能；内容哈希一致，只能证明读回字节与存入内容一致。动作真正需要的是对象、适用条件和版本均匹配的证据。当执行环境变化、索引滞后或元数据缺失时，找到旧证据反而可能使模型更加确信错误判断。因此，研究需要让恢复机制接受环境终态的检验，并将“检索到了”“版本有效”“动作正确”分别统计。

第三，成本比较容易遗漏控制过程。更多检索和更强验证可能提高任务成功率，却增加总体调用开销；反复压缩还可能将一次长输入的成本转化为多次短调用。不同基础模型、缓存策略和重试次数也会混淆比较。应固定执行模型与任务集合，先做相同候选证据和回取开销的机制比较，再做完整系统比较，并预先规定超时、拒答与资源耗尽的计分方式。

1.4 关键科学问题与研究切入点

本项目的中心科学问题是：**在有限上下文与总调用预算下，压缩后动作依赖的保留和恢复证据的有效性怎样共同影响长程智能体的任务失败风险，这种改善在什么条件下仍具有净收益？**其中，拟重点检验元数据只部分可见而当前状态仍可查询时，有限预算在依赖保留与主动取证之间应如何配置。围绕这一问题提出三个子问题：未完成动作所依赖的约束能否比文本显著性更准确地识别应保留信息？恢复时结合动作前提与当前环境版本，能否降低过期证据驱动的操作失败？额外压缩、检索和校验开销在何种任务长度、依赖跨度及更新频率下能够被抵消？

据此提出待检验假说：在相同执行模型、窗口预算与原文存储条件下，保留未完成动作的证据依赖，并在恢复时核对动作前提与证据版本，将在跨阶段依赖较强且环境经常更新的任务中降低终态失败风险；这种改善在静态、短程任务中可能减弱，额外控制开销也可能使净收益消失。通过“依赖保留有无”与“有效性校验有无”的交叉对照，检验组合效果是否超出简单模块叠加。如果在匹配候选证据、上下文长度和恢复开销后差异消失，或经调优的简单规则达到同等效果，将收缩相应

机制主张。

在版本号、依赖关系或有效期不完整的实际接口中，保留更多关系会挤占上下文，减少关系又可能增加重查次数。本项目进一步将压缩强度、依赖可见程度和元数据错漏作为分层条件，检验有限 Token 在保留与主动取证之间的配置规律。所有方法获得相同真实元数据；完整环境状态只供诊断标注，不单独向本方法开放。当前状态既不可观察又不可重查时，研究不主张保证动作正确。

研究由三项相互衔接的内容组成：任务状态感知的保真压缩、动作依赖引导的证据卸载与有效恢复、计及全开销的自适应调度与可靠性验证。前一项为后一项提供状态及不确定性依据，恢复结果又反馈给调度器更新保留与回取决策。预期贡献是形成这一关系的实验依据、可复用方法与适用边界，避免将原型开发或尚未取得的业务提升当作已验证成果。

参考文献

[1] Yao S, Zhao J, Yu D, Du N, Shafran I, Narasimhan K, Cao Y. ReAct: Synergizing Reasoning and Acting in Language Models[J/OL]. arXiv preprint arXiv:2210.03629, 2022. https://arxiv.org/abs/2210.03629.

[2] Schick T, Dwivedi-Yu J, Dessì R, Raileanu R, Lomeli M, Zettlemoyer L, Cancedda N, Scialom T. Toolformer: Language Models Can Teach Themselves to Use Tools[J/OL]. arXiv preprint arXiv:2302.04761, 2023. https://arxiv.org/abs/2302.04761.

[3] Qin Y, Liang S, Ye Y, Zhu K, Yan L, Lu Y, Lin Y, Cong X, Tang X, Qian B, Zhao S, Hong L, Tian R, Xie R, Zhou J, Gerstein M, Li D, Liu Z, Sun M. ToolLLM: Facilitating Large Language Models to Master 16000+ Real-world APIs[J/OL]. arXiv preprint arXiv:2307.16789, 2023. https://arxiv.org/abs/2307.16789.

[4] Liu N F, Lin K, Hewitt J, Paranjape A, Bevilacqua M, Petroni F, Liang P. Lost in the Middle: How Language Models Use Long Contexts[J/OL]. arXiv preprint arXiv:2307.03172, 2023. https://arxiv.org/abs/2307.03172.

[5] Li Y. Unlocking Context Constraints of LLMs: Enhancing Context Efficiency of LLMs with Self-Information-Based Content Filtering[J/OL]. arXiv preprint arXiv:2304.12102, 2023. https://arxiv.org/abs/2304.12102.

[6] Jiang H, Wu Q, Lin C-Y, Yang Y, Qiu L. LLMLingua: Compressing Prompts for Accelerated Inference of Large Language Models[J/OL]. arXiv preprint arXiv:2310.05736, 2023. https://arxiv.org/abs/2310.05736.

[7] Jiang H, Wu Q, Luo X, Li D, Lin C-Y, Yang Y, Qiu L. LongLLMLingua: Accelerating and Enhancing LLMs in Long Context Scenarios via Prompt Compression[J/OL]. arXiv preprint arXiv:2310.06839, 2023. https://arxiv.org/abs/2310.06839.

[8] Pan Z, Wu Q, Jiang H, Xia M, Luo X, Zhang J, Lin Q, Rühle V, Yang Y, Lin C-Y, Zhao H V, Qiu L, Zhang D. LLMLingua-2: Data Distillation for Efficient and Faithful Task-Agnostic Prompt Compression[C/OL] // Findings of the Association for Computational Linguistics: ACL 2024. 2024 : 963 – 981. https://aclanthology.org/2024.findings-acl.57/.

[9] Xu F, Shi W, Choi E. RECOMP: Improving Retrieval-Augmented LMs with Compression and Selective Augmentation[J/OL]. arXiv preprint arXiv:2310.04408, 2023. https://arxiv.org/

abs/2310.04408.

[10] Kang M, Chen W-N, Han D, Inan H A, Wutschitz L, Chen Y, Sim R, Rajmohan S. ACON: Optimizing Context Compression for Long-horizon LLM Agents[J/OL]. arXiv preprint arXiv:2510.00615, 2025. https://arxiv.org/abs/2510.00615.

[11] Ye R, Zhang Z, Li K, Yin H, Tao Z, Zhao Y, Su L, Zhang L, Qiao Z, Wang X, Xie P, Huang F, Chen S, Zhou J, Jiang Y. AgentFold: Long-Horizon Web Agents with Proactive Context Management[J/OL]. arXiv preprint arXiv:2510.24699, 2025. https://arxiv.org/abs/2510.24699.

[12] Zhong W, Guo L, Gao Q, Ye H, Wang Y. MemoryBank: Enhancing Large Language Models with Long-Term Memory[J/OL]. arXiv preprint arXiv:2305.10250, 2023. https://arxiv.org/abs/2305.10250.

[13] Park J S, O'Brien J C, Cai C J, Morris M R, Liang P, Bernstein M S. Generative Agents: Interactive Simulacra of Human Behavior[J/OL]. arXiv preprint arXiv:2304.03442, 2023. https://arxiv.org/abs/2304.03442.

[14] Packer C, Wooders S, Lin K, Fang V, Patil S G, Stoica I, Gonzalez J E. MemGPT: Towards LLMs as Operating Systems[J/OL]. arXiv preprint arXiv:2310.08560, 2023. https://arxiv.org/abs/2310.08560.

[15] Lee K-H, Chen X, Furuta H, Canny J, Fischer I. A Human-Inspired Reading Agent with Gist Memory of Very Long Contexts[J/OL]. arXiv preprint arXiv:2402.09727, 2024. https://arxiv.org/abs/2402.09727.

[16] Xu W, Liang Z, Mei K, Gao H, Tan J, Zhang Y. A-MEM: Agentic Memory for LLM Agents[J/OL]. arXiv preprint arXiv:2502.12110, 2025. https://arxiv.org/abs/2502.12110.

[17] Chhikara P, Khant D, Aryan S, Singh T, Yadav D. Mem0: Building Production-Ready AI Agents with Scalable Long-Term Memory[J/OL]. arXiv preprint arXiv:2504.19413, 2025. https://arxiv.org/abs/2504.19413.

[18] Lewis P, Perez E, Piktus A, Petroni F, Karpukhin V, Goyal N, Küttler H, Lewis M, Yih W-t, Rocktäschel T, Riedel S, Kiela D. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[J/OL]. arXiv preprint arXiv:2005.11401, 2020. https://arxiv.org/abs/2005.11401.

[19] Karpukhin V, Oğuz B, Min S, Lewis P, Wu L, Edunov S, Chen D, Yih W-t. Dense Passage Retrieval for Open-Domain Question Answering[J/OL]. arXiv preprint arXiv:2004.04906, 2020. https://arxiv.org/abs/2004.04906.

[20] Asai A, Wu Z, Wang Y, Sil A, Hajishirzi H. Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection[J/OL]. arXiv preprint arXiv:2310.11511, 2023. https://arxiv.org/abs/2310.11511.

[21] Yadav N. Temporal Validity in Retrieval Memory: Eliminating Stale-Fact Errors for AI Agents over Evolving Knowledge[J/OL]. arXiv preprint arXiv:2606.26511, 2026. https://arxiv.org/abs/2606.26511.

[22] Ganguly S. PLACEMEM: Toward a Compute-Aware Memory Plane for Lifelong Agents[J/OL]. arXiv preprint arXiv:2607.04089, 2026. https://arxiv.org/abs/2607.04089.

[23] Wu M, Zhu P. Agent Zero Memory: Provenance-Aware Long-Term Memory for LLM Agents[J/OL]. arXiv preprint arXiv:2608.29606, 2026. https://arxiv.org/abs/2608.29606.

[24] Wu M, Canedo A. Invalidation Contracts for Cross-Episode Agent Memory[J/OL]. arXiv preprint arXiv:2609.00243, 2026. https://arxiv.org/abs/2609.00243.

[25] Yu C, Wang Y, Zhang J, Duan Y, Zheng M, Wu Z, Shi K, Cai T. From Faulty Memories to Corrected Actions: Dependency-Guided Rollback Repair for Memory-Augmented Agents[J/OL]. arXiv preprint arXiv:2608.10502, 2026. https://arxiv.org/abs/2608.10502.

[26] Shinn N, Cassano F, Berman E, Gopinath A, Narasimhan K, Yao S. Reflexion: Language Agents

with Verbal Reinforcement Learning[J/OL]. arXiv preprint arXiv:2303.11366, 2023. https://arxiv.org/abs/2303.11366.

[27] Yan S, Yang X, Huang Z, Nie E, Ding Z, Li Z, Ma X, Bi J, Kersting K, Pan J Z, Schütze H, Tresp V, Ma Y. Memory-R1: Enhancing Large Language Model Agents to Manage and Utilize Memories via Reinforcement Learning[J/OL]. arXiv preprint arXiv:2508.19828, 2025. https://arxiv.org/abs/2508.19828.

[28] Yu Y, Yao L, Xie Y, Tan Q, Feng J, Li Y, Wu L. Agentic Memory: Learning Unified Long-Term and Short-Term Memory Management for Large Language Model Agents[J/OL]. arXiv preprint arXiv:2601.01885, 2026. https://arxiv.org/abs/2601.01885.

[29] Wu Y, Zheng Y, Xu T, Zhang Z, Yu Y, Zhu J, Ma C, Lin B, Dong B, Zhu H, Huang R, Yu G. ContextBudget: Budget-Aware Context Management for Long-Horizon Search Agents[J/OL]. arXiv preprint arXiv:2604.01664, 2026. https://arxiv.org/abs/2604.01664.

[30] Liu S. What Does Context Compression Cost an Agent? Interaction Costs Unrevealed by Task-Completion Metrics[J/OL]. arXiv preprint arXiv:2608.16370, 2026. https://arxiv.org/abs/2608.16370.

[31] Bai Y, Lv X, Zhang J, Lyu H, Tang J, Huang Z, Du Z, Liu X, Zeng A, Hou L, Dong Y, Tang J, Li J. LongBench: A Bilingual, Multitask Benchmark for Long Context Understanding[J/OL]. arXiv preprint arXiv:2308.14508, 2023. https://arxiv.org/abs/2308.14508.

[32] Hsieh C-P, Sun S, Kriman S, Acharya S, Rekesh D, Jia F, Zhang Y, Ginsburg B. RULER: What's the Real Context Size of Your Long-Context Language Models?[J/OL]. arXiv preprint arXiv:2404.06654, 2024. https://arxiv.org/abs/2404.06654.

[33] Wu D, Wang H, Yu W, Zhang Y, Chang K-W, Yu D. LongMemEval: Benchmarking Chat Assistants on Long-Term Interactive Memory[J/OL]. arXiv preprint arXiv:2410.10813, 2024. https://arxiv.org/abs/2410.10813.

[34] Maharana A, Lee D-H, Tulyakov S, Bansal M, Barbieri F, Fang Y. Evaluating Very Long-Term Conversational Memory of LLM Agents[J/OL]. arXiv preprint arXiv:2402.17753, 2024. https://arxiv.org/abs/2402.17753.

[35] Trivedi H, Khot T, Hartmann M, Manku R, Dong V, Li E, Gupta S, Sabharwal A, Balasubramanian N. AppWorld: A Controllable World of Apps and People for Benchmarking Interactive Coding Agents[J/OL]. arXiv preprint arXiv:2407.18901, 2024. https://arxiv.org/abs/2407.18901.

[36] Zhou S, Xu F F, Zhu H, Zhou X, Lo R, Sridhar A, Cheng X, Ou T, Bisk Y, Fried D, Alon U, Neubig G. WebArena: A Realistic Web Environment for Building Autonomous Agents[J/OL]. arXiv preprint arXiv:2307.13854, 2023. https://arxiv.org/abs/2307.13854.

[37] Liu X, Yu H, Zhang H, Xu Y, Lei X, Lai H, Gu Y, Ding H, Men K, Yang K, Zhang S, Deng X, Zeng A, Du Z, Zhang C, Shen S, Zhang T, Su Y, Sun H, Huang M, Dong Y, Tang J. AgentBench: Evaluating LLMs as Agents[J/OL]. arXiv preprint arXiv:2308.03688, 2023. https://arxiv.org/abs/2308.03688.

[38] Jimenez C E, Yang J, Wettig A, Yao S, Pei K, Press O, Narasimhan K. SWE-bench: Can Language Models Resolve Real-World GitHub Issues?[J/OL]. arXiv preprint arXiv:2310.06770, 2023. https://arxiv.org/abs/2310.06770.

[39] Mialon G, Fourrier C, Swift C, Wolf T, LeCun Y, Scialom T. GAIA: a benchmark for General AI Assistants[J/OL]. arXiv preprint arXiv:2311.12983, 2023. https://arxiv.org/abs/2311.12983.

[40] Yao S, Shinn N, Razavi P, Narasimhan K. τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains[J/OL]. arXiv preprint arXiv:2406.12045, 2024. https://arxiv.org/abs/2406.12045.

[41] Tang L, Wang L, Wang G, Sun M, Yan F. Feature Fusion Mamba Hashing via Decoupling for Cross-Modal Retrieval[J/OL]. IEEE Signal Processing Letters, 33 : 609 – 613, 2026. https://doi.org/10.1109/LSP.2026.3652952.
[42] Xu P, Yan F, Zhou Y, Liu Y, Wu C. RSHR+: Progressive question-conditioned visual calibration and structured state-space reasoning for remote sensing visual question answering[J/OL]. Expert Systems with Applications, 328 : 132953, 2026. https://doi.org/10.1016/j.eswa.2026.132953.
[43] Yan F, Li Z, Silamu W, Li Y. Knowledge-aware image understanding with multi-level visual representation enhancement for visual question answering[J/OL]. Machine Learning, 113 : 3789 – 3805, 2024. https://doi.org/10.1007/s10994-023-06426-6.

（二）研究内容：

（提纲不做限制，请按照研究工作的自身逻辑撰写。应提炼出特色与创新点、年度研究计划）

1.1 研究内容

本项目围绕长程任务中的“状态保留—证据恢复—预算调度”研究三个相互依赖的环节。研究内容一识别当前任务尚需保留的约束和证据关系，研究内容二以这些关系指导卸载与有效恢复，研究内容三根据恢复风险和资源余量选择操作，并通过共同实验检验各环节的独立与联合贡献。核心对象为文本和工具调用轨迹，不开展基座大模型预训练；多模态信息只在工具已经形成可追溯文本结果时接入。

研究内容一：任务状态感知的保真压缩。将轨迹划分为用户要求、未完成子目标、已执行动作、工具观察与证据引用，研究这些信息的后续任务价值。重点不是让摘要尽可能详细，而是识别会改变动作合法性、对象选择或子目标衔接的信息。拟比较基于近因、文本显著性和动作依赖的保留策略，研究有限摘要长度下哪些状态应原样保留，哪些内容可转为结构化事实，哪些内容可只保存原文索引。输出为带来源关联的紧凑任务状态和信息价值估计，供第二项研究确定卸载方式，并向第三项提供压缩失真风险。

研究内容二：动作依赖引导的证据卸载与有效恢复。在保留不可变原始记录的前提下，将长工具结果移出工作上下文，研究如何依据待执行动作的前置条件选择回取对象。恢复时联合检查对象标识、来源版本及适用条件；对可能过期的证据向环境重查，并记录校验失败。重点分析依赖保留与版本检查的交互效应，区分因摘要遗漏、索引遗漏、版本过期及执行误用造成的错误。输出为经核对的证据片段、仍未满足的前提及实际回取开销，为调度提供反馈。

研究内容三：计及全开销的自适应调度与可靠性验证。以固定执行模型为基础，

研究在保留、压缩、卸载、恢复及重查之间选择操作的规则与轻量策略。调度依据包括上下文占用、未完成依赖、候选证据风险和剩余资源；硬约束始终由实际计数执行。通过公开交互环境及受控扰动，检验整个系统在任务长度、噪声与版本变化条件下的成本—成功率关系，确定能实现净收益的区间及失效原因。

1.2 研究目标

总体目标是在固定执行模型和共同资源边界下，形成可追溯的上下文管理方法，明确压缩、有效恢复与长程任务可靠性的关系。项目拟实现三个可检验子目标：识别能稳定降低动作前提丢失的状态保留方式；验证动作依赖与有效性校验是否对过期证据引起的失败产生可重复影响；给出包含全部控制开销的成本—成功率比较及适用范围。

核心验收以公开环境的程序化任务终态为准，同时报告约束违例、有效证据恢复、峰值上下文和端到端时延。**【暂定核心工作点以任务成功率相对强基线下降不超过3个百分点为非劣界，争取累计Token减少30%】**。这些数值是待先导实验校准的设计目标，既不是已有结果，也不替代官方合同指标。若该工作点不能达到，仍须报告完整权衡关系、失败分型及可复现对照，而不能只选择最有利的压缩率。

1.3 拟解决的关键科学问题

哪些信息在压缩后仍应作为任务状态保留？同一句约束的价值可能随目标完成和环境变化而改变。拟研究以未完成动作的前置条件和证据关系表征未来需要，能否比文本显著性或最近访问时间更有效地保护关键状态，并分析这种优势对依赖跨度及观测不确定性的敏感性。

原文回取何时构成对当前动作有效的证据恢复？拟把恢复分解为定位、读取与适用性核对。通过独立操纵依赖保留和版本校验，分析二者是否存在可复核的交互作用。重点研究依赖记录被压缩或元数据不完备而当前状态仍可查询的情境；当前状态既不可见又不可查询时单列为不可充分识别条件。如果正确版本的证据仍不足以改善终态，需继续区分执行模型误用、前提定义错误或任务本身不可完成等原因。

可靠性改善何时能够抵消上下文管理开销？拟分析长工具输出、依赖跨度与更新频率如何改变压缩和回取的价值。研究目标包含无收益和负收益条件；短任务若直接保留历史更合适，调度器应能够选择低干预操作，而非为了展示模块能力而反复压缩。

1.4 研究方法

统一状态与操作定义。以第t步前可见历史H_t、紧凑状态Z_t、原文档案M_t与剩余预算b_t描述研究系统。Z_t包含当前目标、未完成约束、已执行动作及其证据关联；它是从观察估计的工作状态，不等于环境的完整真实状态。上下文操作记为u_t，任务动作记为a_t，二者分开记录，避免把额外控制调用藏入主模型的行动统计。

对候选片段e，拟估计其省略后导致关键动作错误的条件风险，并结合回取成本形成保留优先级。训练阶段可在可复位环境中比较保留或删除该片段后的执行分支；线上仅使用截至当前步已观察到的目标、动作、工具返回与历史记录。未来轨迹和答案只能用于训练标签与离线诊断，不能作为在线信息价值的输入。若干预分支出现合法替代动作，以前置条件与任务终态判断后果，不以动作字符串一致作为保真标准。

将任务约束失真记为D_c，未完成子目标丢失记为D_g，动作—证据依赖遗漏记为D_e，综合失真$D_t = w_c D_c + w_g D_g + w_e D_e$仅作训练与诊断量。权重在开发集设定，其数值不能保证实际任务安全。主要结果仍是环境判定的任务成功率及违例率，通过删除状态项、打乱关联和替换版本的消融检验各项是否具有预测与干预价值。

同条件实验体系。主实验采用 AppWorld 中可复位且具有程序化终态判定的任务[35]，跨环境验证采用 WebArena 中具备相应操作接口的任务[36]。LongMemEval 的知识更新与时间推理任务作为恢复模块诊断[33]；LongBench 和 RULER 用于压缩器的静态信息保留检查[31, 32]。SWE-bench 的代码任务只作为条件允许时的扩展，不与主实验争夺同等规模资源。任务清单与排除条件在比较前固定，不按某一方法是否成功来筛选样本。

同一任务集合设置未压缩历史、滑动窗口和固定周期摘要等基础参照。压缩方法采用 LLMLingua-2，外部记忆参照采用 MemGPT 与 ReadAgent 型方法，轨迹管理参照采用 ACON 和 AgentFold 型方法；在代码与资源允许时加入 AgeMem、ContextBudget、MemStrata、PLACEMEM 的相应实现。不同方法按公开代码版本冻结。对不可在同一执行模型上运行的训练型方法，另设原生配置参照，清楚区分“同骨干机制比较”和“原生系统比较”；简化复现不冒充作者实现，也不从跨模型分数直接推导机制优劣。

主干计划采用**【暂定两个可本地运行的指令模型档位、三个上下文预算和至少三次重复】**。先以**【暂定 60 个开发任务】**估计任务分歧率、运行成本与扰动可行性，再根据成对分歧率、非劣界与目标功效确定主评测任务数。若样本量不足，明确保

留探索性判断，不事后放宽非劣标准。先导阶段同时形成可用独立任务数与所需样本量的对照表，以每种方法单任务实测GPU时、接口调用数和失败重跑率估算总运行量；总量按任务数、比较方法数、种子数和实际保留的扰动层数相乘，再与可分配机时及经费核对。只有独立任务数量与资源两项同时满足时，才启动确认性比较；不足时保持原非劣界，先完成一个环境、一个模型和一个窗口的机制实验，其余配置依次延后，结论限于探索性证据。增加种子不补足独立任务，不能合并开发任务进入测试集。确认性主要比较预先固定为一个主模型、一个窗口工作点与有限元数据强组合基线，其余模型和预算用于迁移及敏感性分析。主测试使用官方可用测试划分，参数、提示词和阈值不在测试结果上调整；同一模板的改写任务、共享环境实例及派生扰动归入同一划分，防止近重复泄漏。外部模型若使用，需记录模型版本、调用日期和采样设置。

主要终点与统计分析。对每个预注册任务记录终态成功、约束违例及成本；超时、拒答、预算耗尽和恢复循环导致的中止都计为任务失败，并在失败原因中单列。不能以更频繁拒答降低违例率后声称成功率提升。统计以任务为单位，多个随机种子、步骤和扰动版本在任务内聚类。主要比较使用成对任务的成功差及任务级自助法置信区间，非劣判断采用预先指定的单侧区间；区间跨越非劣界时结论为证据不足。预先按“任务成功率达到非劣标准、再检验总成本降低”的顺序判断，不在看到测试结果后改选优效或降本终点。多基线和多预算作为次要分析，使用明确的多重比较校正并保留效应量。依赖保留与有效性检查的交互在成功率加性尺度上定义为$I = p_{11} - p_{10} - p_{01} + p_{00}$，其中下标表示两个因素是否启用；联合优于单项不能直接证明互补，须将I与开发阶段确定并预注册的最小有意义幅度比较。

全部方法遵守相同上下文窗口、最大任务动作数、外部接口调用总上限和累计Token预算；原文存储上限与访问接口保持一致。累计Token包括执行、压缩、索引中需要模型的部分、检索改写、有效性校验和失败重试的输入与输出，另列峰值窗口、检索次数、存储量、端到端时延中位数与高分位数。外部接口总调用数同时计入任务操作、控制器重查、恢复触发查询及失败重试，本地档案读取单列；不能仅限制主智能体动作而让控制器额外查询不受限。**【暂定外部接口调用上限按开发任务长度分层确定并冻结，各方法采用相同上限】**。推荐工作点还需将外部交互比率的单侧置信区间与开发阶段预注册的容忍界比较；若交互或时延增加，只报告Token与其它代价的权衡，不宣称总体效率提高。离线训练与索引构建开销单列，并报告是否以及按多少任务摊销。价格、缓存和批处理条件与Token物理计数分开，避免

不同计费策略造成虚假节省。

1.5 技术路线

总体技术路线。研究从可复位工具环境的完整轨迹出发，先建立任务状态与原始证据的关联，再比较不同压缩表示对动作前提的保留；长结果写入原文档案后，以未完成动作的证据需要驱动恢复，并通过来源版本与当前环境查询核对适用性；调度器接收压缩风险、恢复结果及预算反馈，选择下一步上下文操作。最终以任务终态、失败分型和全开销核算检验三项研究内容是否共同改善长程执行。

面向研究内容一的任务状态保真压缩路线。输入为当前指令、已执行动作、工具观察和已知未完成目标。首先提取对象、约束、动作前提及证据关联，区别已完成目标与仍需履行的要求；随后在相同长度预算下形成原文片段保留、结构化事实和子任务概要三种粒度的表示。禁止修改用户约束的逻辑方向、对象标识及仍有效的数值条件。对来源未明或提取不确定的关键内容优先保留原文，并把不确定性作为风险特征。

信息价值模型优先采用可解释特征与轻量分类器，以当前目标相关性、依赖是否未完成、信息是否被更新以及回取难度估计保留需求。通过可复位环境中的片段删除和恢复分支获得训练信号，不把全历史成功轨迹一律作为正确标签。样本中同时包含可解、失败和存在多个合法动作的任务，对标注分歧建立人工复核子集。若轻量模型未稳定优于规则基线，保留规则方案完成后续机制研究。

这一分路线输出紧凑状态、关联证据索引和保真风险。验证比较相同摘要长度下的关键约束遗漏率、动作前提满足情况与任务终态，并以去掉依赖关系、去掉未完成目标、随机保留等消融排除单纯长度优势。其输出直接作为下一分路线的恢复请求依据；不能由恢复模块看到压缩模块未被允许使用的未来答案。

面向研究内容二的证据卸载与有效恢复路线。输入为紧凑状态、拟执行动作及其缺失前提。每份工具结果在压缩前存入不可变档案，并建立来源、对象、版本、时间和访问条件的关联；卸载只移出工作窗口，不删除档案。概要记录指向具体原始片段，后续更新创建新版本并保留版本关系。在环境不提供版本号时，使用读取时间、来源快照及必要重查描述新旧关系，不把自定义哈希视作业务版本。

恢复先由动作前提生成候选请求，再结合对象过滤、语义匹配与来源关联选取片段。读取后分两层核对：哈希检查字节完整性，对象及有效期检查描述是否适用于当前动作；可能被外部操作改变的关键状态通过环境接口重新查询。对无法确定的前提，优先请求更完整原文或重查；资源不足时结束该次任务并记录失败，不能

凭近似摘要继续执行需确定证据的操作。恢复到旧原文属于可追溯回读，不等于摘要可逆或环境回滚。

核心机制实验采用“保留动作依赖/不保留动作依赖”与“核验当前有效性/不核验当前有效性”的交叉设计。四组共享原文档案、执行模型和候选证据规模，并在局部机制回放中匹配Token与实际查询开销，以分离更多上下文带来的影响；完整系统实验只匹配总预算上限，保留自然执行的实际调用差异，不添加无效调用强行配平成本。

将“环境原本不提供元数据”与“原本可见、随后被压缩删除”分别干预，线上策略只可使用已识别的前提缺口，不能使用实验者的隐藏缺漏率或未来变更。在此基础上分层改变压缩强度、依赖可见程度与元数据错漏比例，检验有限预算在保留关系和主动取证之间的配置。所有方法获得同等真实元数据，以“有限元数据下的依赖记录、版本过滤与规则重查强组合”为主要对照，并给予相同的调参预算及预算自适应重查能力；比较分配策略时向强基线提供同一可部署缺口识别结果并计费，另做识别器消融，以分离额外信息与分配决策的作用；全量无损元数据加确定性失效仅作诊断参照，每次重查作为高成本参照。

无变更任务和弱依赖任务作为负对照；元数据错漏、索引延迟和无可用新版本作为压力测试。预期若二者配合有效，其影响应集中在跨阶段依赖强、版本变化明显的任务；若单独版本过滤或简单规则组合已达到同等终态表现，则收缩交互机制解释。

此分路线输出经核对的证据、未满足前提与恢复成本。分别记录候选召回、读取完整、当前有效、正确使用四个环节；有效证据恢复率的分母是经独立标注确需回取且原文可用的事件，同时报告所有恢复请求中的失败比例。事件级指标只用于诊断，任务级终态承担主要结论。恢复风险和成本随后反馈给调度器，改变下一轮保留优先级。

面向研究内容三的全开销调度与验证路线。输入为工作状态、原文档案索引、恢复反馈与剩余预算。先建立窗口阈值、固定周期及依赖触发三类规则基线，再使用开发轨迹训练轻量控制器，比较其是否值得额外复杂度。控制器在保留、压缩、卸载、恢复与重查中选择操作；安全性和资源限制通过显式计数及动作前提检查实现，不能交由学习目标隐式保证。

具体而言，在两条候选证据均被同一识别器标为“状态不确定”、且只剩一次重查预算时，强规则按预先调好的风险阈值与近因次序选择；拟研究的策略进一步使

用可见的未完成动作依赖、原文重读长度和该对象历次变更记录，估计重查对下一动作前提的边际作用。它可能保留一条较旧但关联关键未完成约束的原文索引，把查询用于即将被修改的对象。该差异属于待检验的决策假设；上述特征也提供给特征规则基线，若规则取得相同效果，就不把学习控制器作为必要创新。

拟研究的约束形式为：

$$\min_{\pi} \mathbb{E}_{\pi}[C_{\text{all}}] \quad \text{s.t.} \quad p_{\pi} \geq p_{\text{ref}} - \delta, \qquad L_t \leq B, \qquad C_{\text{all}} \leq C_{\max}.$$

其中 C_{all} 表示单任务全部模型调用 Token 或同口径资源成本，p_{π} 为任务分布上的成功概率，p_{ref} 为指定强基线成功概率，δ 为预注册非劣界；L_t 为单次上下文占用，B 和 $C_{\max}$ 分别为窗口及累计预算上限。成功概率约束通过独立测试估计，不能在执行前保证；窗口和累计预算由运行器实际强制。若关键约束本身已超窗口，按不可容纳任务记录并计入总体结果，不从总体中静默剔除。

调度训练以已发生的状态和成本为输入，开发阶段可利用完整轨迹形成诊断参照。若采用未来信息决定最优操作，只能将其作为不可部署的理想参照，不能列入线上方案。控制器增加最小操作间隔和恢复次数限制，防止同一证据在压缩与恢复之间循环；阈值在开发集设定，全部额外调用进入核算。最终在不同任务长度、证据依赖跨度、无关输出比例和环境更新频率下比较方法，报告成本—成功率权衡及无收益区间。

三条路线形成可观察的反馈关系：状态表示决定可提出哪些恢复请求，恢复结果暴露表示遗漏及证据过期风险，调度依据这些反馈重新分配有限上下文。共同实验保持这一反馈链可追踪，既做分模块干预，也检查整条轨迹的最终操作结果。

1.6 关键技术

依赖关系的低成本提取与校验。优先从工具接口约束、对象标识和可验证动作前提出发，辅以模型提取自然语言要求，减少对不可观测内部推理的依赖。关键关系保留原文证据位置，人工核对的是少量争议样本和错误分型；不把所有工具日志转换为复杂知识图谱作为先决条件。对未明确指定的条件不自动补全为确定事实。

版本不完备条件下的恢复。同一对象可能对应多个读取时间与适用范围。恢复机制应先说明当前动作缺少什么，再决定是否需要重查，而非总是取时间最近的片段；有些历史事实本就需要旧版本。缺少可核验时间信息时，系统保留不确定性并限制依赖该事实的动作。实验同时包含“应使用最新状态”和“应追溯历史版本”两类任务，避免把一律选新误当作有效性推理。

可解释的错误归因。每个失败任务按首次可定位错误记录状态遗漏、索引未命中、版本误判、有效证据误用和环境异常，并允许多因共存。环境快照与成对干预用于检验错误归因是否成立；无法定位时标记原因不明，不强行归入某一模块。语言模型评委仅辅助判断自由文本结果，主要行动终态使用程序化测试，并对评委分歧进行人工复核。

1.7 可行性分析

方法层面，提示压缩、原文回读和可控交互环境均已有可核验实现基础，项目重点在共同条件下组织机制比较及针对性方法改进，无需从零建设通用智能体生态。技术层面，先运行规则和冻结模型，再依据开发证据引入轻量学习，可使失败原因较早暴露。条件层面，现有本地GPU支持中小规模模型和重复实验，昂贵原生训练方法以分层对照或条件性复现安排，不要求完成大规模端到端强化学习。

公开可复位环境能够承担核心证据链。企业数据授权尚未落实时，依然可以通过工具输出膨胀、跨阶段约束与版本变更的受控任务检验方法；这些扰动任务应明确标为构造测试，不称为快手真实业务样本。若依赖—版本交互不成立，项目将保留模块独立效果及全开销边界结论，调整方法复杂度，避免以扩大任务范围掩盖主要假说失败。

1.8 项目特色

项目以可产生环境状态变化的多步骤任务为研究对象，将上下文管理与行动所依赖的证据连接起来。静态长文理解和会话记忆作为诊断层，程序化终态测试作为主要验证层；同一轨迹同时记录状态、来源、版本与成本，使压缩效果能够追溯到具体的遗漏或恢复事件。方案采用冻结执行模型与渐进开发，在已有算力及一年期草案内优先完成能够被独立复核的机制实验。

1.9 创新点

（1）研究不完备元数据下依赖保留与主动取证的预算配置。现有轨迹压缩、原文回读及版本化记忆已提供重要基础。已有研究还覆盖记忆失效、动作纠错和回放。本项目聚焦依赖及版本信息不完全可见的条件，以未完成动作的前置条件连接压缩与恢复，分层改变压缩强度、依赖可见程度及元数据错漏，检验有限预算在状态保留与主动重查之间如何分配。以相同候选证据、摘要长度与恢复开销排除资源差异，使观察到的改善能够对应到具体任务条件；对静态、弱依赖和元数据不完备情境同时检验失效边界。创新成立与否取决于这一可证伪关系及针对性方法是否经验证，不以模块组合名称替代证据。

（2）建立由恢复风险决定、覆盖全部控制开销的调度收益判据。在已有预算上下文管理研究基础上，把前提缺失、版本不确定性和实际恢复代价共同用于决策，研究额外控制何时能带来净收益。通过任务级非劣比较与完整成本核算，区分降低窗口峰值、减少累计 Token 和提高任务可靠性三类效果；通过规则、轻量策略及不可部署理想参照揭示可改进空间。预期形成不同依赖跨度、噪声和更新频率下的适用依据，负结果亦作为明确方法边界的证据。

1.10 年度研究计划

项目按资料建议采用**【暂定自正式启动起 12 个月】**的研究周期。正式起止日期及合同要求以**【待补 F-KS-05：资助起止日期和结题成果要求】**为准。以下月份为相对启动月份，依据三项研究内容的依赖关系安排，不预先写成已批准的日历日期。

M1—M2：建立共同评测与状态标注。完成官方课题目标和任务边界核对，复现未压缩历史、滑动窗口、固定摘要及轻量压缩基线，建立原文档案和完整成本日志。通过开发任务检查工具接口、环境复位和终态测试，整理动作前提与证据关联标注规则。阶段验收以所有基线能在同一任务清单运行、错误可回溯、开销能核对为标准，并据开发分歧率确定主测试规模。同步按实测 GPU 时、接口调用数和可分配资源冻结扩展规模；若功效或资源不足，优先完成单环境单模型机制实验，延后额外模型和窗口，不放宽原非劣界。

M3—M5：研究任务状态保真压缩。完成规则与轻量信息价值估计，比较不同表示粒度及依赖保留方式，开展删除、随机保留和关系打乱消融。同步建立相同长度的机制对照和原文回读接口，形成第一版紧凑状态。若轻量学习不能稳定超过规则方案，保留规则作为后续恢复实验的可解释输入，不在这一阶段追求大规模训练。

M6—M8：完成有效恢复与核心交叉实验。实现对象关联、版本核对和必要环境重查，构造有无更新、有无强依赖的成对任务，运行依赖保留与有效性校验的交叉比较。重点核验过期证据导致的真实动作失败及其变化，形成失效案例和人工复核记录。对无法匹配原生模型的近期方法，完成同骨干机制对照并单列原生实现差异。

M9—M10：集成调度与外部验证。接入全开销计量，比较规则与轻量调度，在预先固定的任务划分上报告非劣结果和成本权衡。完成 WebArena 跨环境测试及元数据错误压力测试。企业场景的开展以**【待补 F-KS-03：业务数据授权、接口与协作负责人】**落实为前提；未落实时提交公开模拟环境结果和迁移要求，不把构造任务标记为真实业务验收。

M11—M12：整理成果与复现验收。冻结可交付版本，核对论文、代码、数据使

用许可和第三方依赖，整理全部正负结果及适用边界。由未参与主要方法实现的项目成员复跑核心比较；对无法复现的结果重新定位并报告原因。依据正式合同准备结题材料，最终验收以研究记录、方法实现和可复核证据的一致性为基础。

1.11 预期研究结果

预期形成**【暂定 1 套 ACORE 上下文管理原型、1 套公开环境评测与错误分析工具、1 份可复现技术报告、1—2 篇论文投稿】**。原型提供保真压缩、可追溯原文档案、有效恢复与预算调度接口，工具包含任务清单、固定配置、成本统计及错误分型。论文投稿是计划产出，不保证录用；知识产权申请在实际形成可保护成果并核对合作协议后决定，不预列专利号或承诺授权数量。

研究结论包括机制有效与无效的任务条件、不同资源预算下的权衡关系以及可复核负结果。拟公开不受第三方限制的代码、配置和任务描述；受限模型、原始数据及企业资产只提供符合授权范围的复现实验说明。正式成果数量和交付范围依据课题合同终核，研究方法的比较不因成果数量目标而选择性报告。

（三）研究基础：

1．研究基础与可行性分析（与本项目相关的研究工作积累和已取得的研究工作成绩，研究风险的应对措施等）；

1.1 与本项目相关的研究工作积累

申请人颜丰为新疆大学副教授、博士、硕士研究生导师，具有多源信息表示、跨模态检索、视觉问答和软件系统研发的研究积累。与本项目直接相关的基础主要来自证据检索、条件化信息选择和长上下文效率研究。上述积累支持算法实现与实验组织，但尚不能证明已完成智能体上下文压缩或有效恢复的先导实验。

在跨模态检索方面，申请人作为通讯作者参与 Feature Fusion Mamba Hashing via Decoupling for Cross-Modal Retrieval，负责研究构思、方法设计、实验指导及论文修改 [41]。该工作涉及信息表示与检索组织，可支持本项目比较不同证据索引和表示方式。任务模态与评价终点不同，因此项目将重新建立动作依赖及证据有效性实验，不把跨模态检索结果直接当作长程智能体性能。

在条件化信息选择和结构推理方面，申请人作为通讯作者参与 RSHR+，负责方法设计、实验指导与结果分析 [42]；作为第一作者兼通讯作者完成知识感知视觉问答研究 [43]。这些工作为研究“任务条件怎样改变信息选择”提供方法与实验经验，可迁移到本项目的状态提取、依赖关系对照与错误分析。其支持限于研究能力与相关方法，不等同于已验证本项目假说。

申请人参与“可学习乘积量化与状态空间模型协同的长上下文高效注意力机制研究”，正式负责高效注意力机制研究。该经历有助于理解长上下文资源消耗和效率评价。本申请研究运行时的上下文选择与证据恢复，以冻结执行模型开展主要比较，与改变注意力实现或模型内部结构的任务形成明确区分。

1.2 已取得的研究工作成绩

上述三项代表作的题录、作者角色与贡献已在共用申请人事实中确认，本次又核对出版元数据。它们分别支撑检索表示、条件化选择与知识增强推理；研究方案将把这些能力落实到可复现基线、成对干预及模型误用证据分析。正在承担的知识库研发工作提供数据组织和问答系统工程背景，但已有合同成果及知识产权受双方约定约束，不能未经授权移入本项目。

目前尚无可复用的本项目级数据、代码、模型配置、评价脚本或消融日志。项目启动后的首项任务是建立共同评测和基线，而不是以未经记录的实验数值支撑可行性。预期性能、成本节省和业务提升均保留为待检验目标；图件只表达研究设计、流程及条件，不展示虚构实验曲线或前期成果截图。

1.3 可行性分析

方法可行性。状态压缩、外部记忆、版本关联及可复位工具环境均有公开研究依据，核心挑战可以拆为可独立验证的局部问题。项目先用显式规则建立基线，再研究轻量信息价值估计及控制策略；只有开发证据支持时才增加训练复杂度。这一安排有助于把算法效果与系统调试问题分开。

人员与组织可行性。申请人负责科学问题、核心方法和实验质量；拟按状态压缩、恢复校验、评测工程三个任务组组织研究生协作，各组共享版本化任务清单和错误分析记录。本项目实际参与人员与投入安排为**【待补 F-KS-02：研究生团队名单、分工与投入期限】**。其它申请书中已确认的团队名单不自动转用为本项目成员，核心实验先按现有条件和明确负责人可组织的范围推进。

进度可行性。一年期草案以公开环境的机制实验和轻量原型为主体，企业场景作为授权后的扩展。跨环境测试使用已有任务体系，不新增大规模基座训练或自建综合业务平台。各阶段以可运行基线、错误可定位和结果可复现验收；若方法假说未得到支持，仍可形成边界分析与比较证据。

1.4 研究风险与应对措施

状态提取错误导致依赖保护无效。早期信号是人工核对发现未完成目标与已完成动作混淆，或依赖保留方案在相同长度下不优于近因规则。预案是收缩到有明确

接口前提的任务类型，保留关键原文和确定性规则，先完成可观测条件下的机制实验；对自然语言开放依赖只报告探索性结果。

版本信息不完备使恢复不能可靠判断。早期信号是新旧来源无法区分、元数据冲突或检索命中后仍频繁触发动作前提违例。预案是对当前状态可查询的任务使用主动重查，单独分析不可查询的情境；不能恢复确定证据时结束本次任务并计为失败。完整性哈希与来源版本分开解释，避免用完整性检查代替有效性判断。

额外控制开销抵消收益。早期信号是窗口峰值下降，但累计调用或端到端时延上升。预案是限制压缩频率和恢复循环，比较更简单的规则与轻量压缩器，并将短任务保留历史作为合理选择。若净收益只在高噪声长任务存在，就明确报告该范围，不将结果推广到所有任务。

近期研究重合与复现资源不足。若强组合基线已达到同等表现，将按证据撤回独有机制或性能优越的表述；若原生训练型方法超出现有资源，采用同骨干机制复现并标注差异，不把未复现方法作为弱基线。核心成果可转向元数据可观测性下的可靠性与成本边界，为后续研究保留可复核依据。

企业合作条件影响外部验证。若计划中的数据授权、接口或协作人员未落实，先完成公开可复位环境、构造压力测试及迁移要求说明。企业数据不作为主要机制结论的唯一来源，且不把公开构造任务声称为真实业务数据。授权落实后再按相同评价口径补充外部验证，不反向调整主测试结论。

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、全国重点实验室和部门重点实验室等研究基地的计划与落实情况）；

2.1 已具备的实验条件

申请人已确认可稳定使用 NVIDIA A40 共 8 张、NVIDIA GeForce RTX 3090 Ti 共 6 张，并具备 Linux、Python、深度学习框架、Git 与 LaTeX 等软件工具链。这些条件适合中小规模指令模型推理、轻量压缩器训练及分批重复评测。实验根据显存与并发条件配置，不假定不同型号显卡可以组成同质高速互联集群，也不把总卡数直接换算为大模型训练能力。

任务状态保真研究主要需要轨迹记录、可复位环境和少量标注；有效恢复研究需要原文档案、对象索引和版本查询；调度研究需要统一日志和调用成本记录。上述能力可在本地软件环境逐步实现。AppWorld、WebArena 等公开资源作为拟获取并按许可证使用的实验来源，其可公开获取不等于项目已完成本地部署或获得全部数

据授权。

2.2 尚缺少的实验条件及拟解决的途径

本项目尚缺共同条件下的智能体先导轨迹、动作依赖标注和完整对照日志，计划在启动初期建立。模型、任务与依赖包版本在评测前固定；项目级数据和代码的形成过程保留来源与变更记录，以支持后续独立复跑。团队的实际成员、分工和投入安排按已登记事实缺口补齐后落实。

企业侧业务验证尚需**【待补 F-KS-03：数据授权范围、业务接口和协作负责人】**。基金通知中的技术、算力和脱敏数据支持属于合作安排，不能等同于本申请已获得固定配额。核心算法和验证依托现有算力及公开环境完成；额外企业算力、学院公共资源或云端模型仅作为落实后的补充条件，不预写未获授权的设备与配额。

2.3 利用研究基地的计划与落实情况

项目依托申请人已确认的本地计算条件开展，不以国家实验室、全国重点实验室或部门重点实验室的未落实资源作为前提。需要使用学院公共算力时，按实际申请结果安排任务；若补充资源不能及时获得，优先减少原生大模型复现与扩展场景规模，保留核心交叉实验、强组合对照和多次重复，避免牺牲主要证据链。

3. 正在承担的与本项目相关的科研项目情况（申请人和主要参与者正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的资助机构、项目类别、批准号、项目名称、获资助金额、起止年月、与本项目的关系及负责的内容等）；

（1）可学习乘积量化与状态空间模型协同的长上下文高效注意力机制研究。资助来源为 CAAI—蚂蚁科研基金，项目编号 202604140006，获资助总额 15 万元，执行期 2026 年 2 月至 2027 年 2 月。申请人为参与者，正式负责高效注意力机制研究。本申请针对运行时任务状态、证据恢复和预算配置，主要固定执行模型；两项工作分别研究模型内部计算效率与智能体外部上下文管理，不将前一项目任务或成果重复列为本项目新交付。

（2）面向政企数字化应用的智能知识库与问答系统研发。委托单位为新疆数字云创有限公司，横向项目编号 202604140013，合同经费 12 万元，执行期 2026 年 6 月至 2026 年 10 月，申请人主持并按合同构建一个知识库。该项目提供知识组织及问答系统研发背景；本申请拟研究可复位多步骤任务中的压缩、恢复和全开销关系。既有项目成果及知识产权由合同双方共同享有，本申请不预设其代码、数据可公开或

直接复用。

（3）多模态融合技术研究及其在新疆产业集群中的应用。资助来源为自治区天池英才引进计划（青年博士人才），无独立项目批准号，以任务书为依据；经费50万元，执行期2025年2月至2028年2月，申请人主持并负责总体研究方案、关键模型设计与成果组织。该项目提供多源表示和实验组织基础，本申请的核心任务为文本与工具上下文管理，不将多模态应用任务重复安排为本项目交付。

（4）融合多源数据大模型驱动的光伏发电功率预测方法研究。资助来源为自治区高校基本科研业务费科研项目培育类，批准号XJEDU2026P005，经费5万元（直接经费3.9万元、间接经费1.1万元），执行期2026年1月至2026年12月，申请人主持，负责总体方案、模型研究与成果组织。该项目以功率预测为对象，与本申请的多步骤任务证据管理在研究对象与评价终点上不同，仅提供多源模型与实验管理经验。

以上内容依据已确认项目事实列示。主要参与者及其在研项目情况随**【待补F-KS-02：本项目人员及相关在研项目清单】**一并核对，正式申报时依据企业基金表格确定最终列示范围，不据此推断全部参与者均无其它项目。

4. 完成国家自然科学基金项目情况（对申请人负责的前一个已资助期满的科学基金项目（项目名称及批准号）完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该项目的研究工作总结摘要（限 500 字）和相关成果详细目录）。

申请人未主持完成国家自然科学基金项目，因此无本人作为负责人应说明的前一期资助期满项目及其研究工作总结。申请人参与在研地区项目62466056，该项目尚在执行期，不能列为本人已主持完成项目。本文件使用现有NSFC模板保留该项事实说明；本次实际申报对象为CCF—快手企业科研基金。

（四）其他需要说明的情况：

1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系；已收到自然科学基金委不予受理或不予资助决定的，无需列出）。

本次申报为CCF—快手大模型探索者基金，采用现有NSFC模板组织研究正文；本项为国家自然科学基金专属申报声明，不适用于本次企业基金申报。此说明不构成对申请人或参与者当年国基申报、登记单位及职称情况的确认，企业基金要求的声明在其正式申报表中据实填写。

2. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

本次申报为CCF—快手大模型探索者基金，采用现有NSFC模板组织研究正文；本项为国家自然科学基金专属申报声明，不适用于本次企业基金申报。此说明不构成对申请人或参与者当年国基申报、登记单位及职称情况的确认，企业基金要求的声明在其正式申报表中据实填写。

3. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在与正在承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

本次申报为CCF—快手大模型探索者基金，采用现有NSFC模板组织研究正文；本项为国家自然科学基金专属申报声明，不适用于本次企业基金申报。此说明不构成对申请人或参与者当年国基申报、登记单位及职称情况的确认，企业基金要求的声明在其正式申报表中据实填写。

4. 申请人和主要参与者同年以不同专业技术职务（职称）申请或参与申请科学基金项目的情况（应详细说明原因）。

本次申报为CCF—快手大模型探索者基金，采用现有NSFC模板组织研究正文；本项为国家自然科学基金专属申报声明，不适用于本次企业基金申报。此说明不构成对申请人或参与者当年国基申报、登记单位及职称情况的确认，企业基金要求的声明在其正式申报表中据实填写。

5. 其他。

本申请研究方向为CCF—快手基金课题1.7，正文借用NSFC模板组织。正式提交材料须与**【待补 F-KS-01：课题介绍附件的完整目标和填报要求】**核对；企业基金所要求的重复申报、利益冲突、知识产权约定和附件签章事项，以**【待补 F-KS-04：本人及参与者确认的企业基金声明与附件记录】**为准，不能由本稿自动代替。

本稿在主题整理、文献梳理、文字草拟、图件设计及格式检查中使用生成式人工智能辅助。申请人须对实际提交的观点、事实、引文与图件逐项核对并承担责任。研究设计示意图不代表实验结果；现阶段不存在可支持ACORE性能提升的项目级先导数据。正文中的待补事实与暂定研究参数须在正式提交前按真实材料核对。