报告正文（2026版）

参照以下提纲撰写，要求内容翔实、清晰，层次分明，标题突出。**申请书正文原则上不超过 30 页，鼓励简洁表达。请勿删除或改动下述提纲标题及括号中的文字。**

（一）立项依据：

（为什么要开展此项研究，研究的科学技术价值如何）

1.1 研究背景与意义

大模型智能体通过调用工具、读取环境反馈和调整行动计划，将语言理解能力转化为多步任务的执行能力。ReAct 将推理与行动交替组织，Toolformer 探索从数据中学习工具调用，使模型能够借助外部计算与信息完成任务[1, 2]。与单次问答相比，智能体的输出还包括会改变后续状态的动作。一个语句流畅的回答可能对应错误的工具参数，一次接口返回成功也不意味着用户目标已经实现。因此，智能体的能力需要依据行动过程及最终状态评价，不能只看回答质量。

实际任务环境会持续变化：同类请求的组成改变，新工具加入，旧接口的字段或规则调整，反馈又可能延迟、缺失或出错。这些变化不仅降低当前任务成功率，还会改变适配数据的质量和模型置信度的含义。AgentBench、ToolLLM 和 τ-bench 从多环境任务、工具调用及用户交互等角度推动了智能体评测[3, 4, 5]，但在连续任务中，学会新工具、保留旧能力和避免错误执行需要同时面对资源约束。每次变化都重新训练全部参数，难以支持频繁适应；持续增加独立适配器，则会把训练效率问题转移为存储、路由与维护问题。

本项目题为**面向动态任务的大模型智能体参数高效自适应后训练与可信校准方法研究**，英文名称为 Parameter-Efficient Adaptive and Calibrated Training for LLM Agents under Dynamic Tasks，简称 PACT-Agent，面向 CCF–百度松果基金所关注的大模型后训练与 Agent 技术方向。项目以文本工具智能体为研究对象，考察固定资源预算内的持续适应机制。公开能源时序任务提供非平稳性和反馈延迟的补充验证环境，主体评价仍围绕通用工具任务展开。研究价值在于弄清何种任务变化值得增加参数更新、何种轨迹值得用于学习，以及策略更新后原有的行动置信度在何种条件下失效，从而为资源受限的持续后训练提供可验证的依据。

1.2 国内外研究现状及发展动态分析

参数高效学习已具备成熟起点，跨任务预算分配仍需结合能力变化考察。LoRA 冻结预训练主干，以低秩增量完成任务适配[6]；QLoRA 结合量化主干与低秩训练，降低显存占用[7]。AdaLoRA 根据参数重要性在权重矩阵之间重新分配预算，说明不同层和模块的更新价值并不相同[8]；DoRA 从权重幅度与方向分解改进低秩适配的表达能力[9]。这些研究表明，固定低秩配置并非唯一选择，也意味着“动态调整秩”不能直接作为新的科学贡献。对连续任务而言，需要进一步区分当前任务的适配收益、历史能力干扰，以及为估计这些收益所额外付出的计算成本。只有在累计存储与总计算预算相同的条件下，才能判断任务变化信息是否带来了有效的参数分配依据。

后训练正在由单轮指令扩展到交互轨迹，监督质量成为关键变量。InstructGPT 研究示范与偏好反馈对模型行为的影响[10]，Self-Instruct 利用模型生成并筛选指令样本[11]，LIMA 则显示高质量样本值得单独考察[12]。DPO 将偏好学习转化为直接的策略优化目标，为轻量后训练提供了方法基础[13]。在智能体场景中，AgentTuning 通过交互轨迹与通用指令混合训练增强智能体能力[14]；Agent Lightning 将执行与训练解耦，以轨迹接口连接复杂交互和学习过程[15]。AgentFlow 进一步在多轮交互中优化规划器，并结合执行、验证和记忆模块[16]。2026 年的 Agent Lightning v1.0 还讨论了运行控制器参与训练时的数据拼接与优化细节[17]。因此，建立多模块闭环本身已有充分先例，本项目需将研究重点放在证据对学习决策的作用及其可识别边界。

轨迹质量并不等价于最终成功标签。错误中间步骤可能被后续动作偶然修正，工具异常也可能被自然语言反馈掩盖。数学推理中的验证器研究说明，结果验证可以用于选择候选解答[18]；过程监督研究进一步比较了中间步骤与最终结果监督的差异[19]。但其可验证性依赖任务条件，不能将数学验证器的效果直接移用于任意接口。模型不确定性同样具有两面性：低置信轨迹可能包含重要的困难样本，也可能是错误反馈；高置信轨迹可能正确，也可能只是生成器与验证器共同偏差的结果。如何区分“执行正确”与“用于训练后有益”，是自动轨迹学习需要进一步回答的问题。

持续学习提供了抗遗忘方法，但参数记忆与行为可靠性的关系尚需检验。EWC 通过保护历史重要参数减轻遗忘[20]；GEM 以情景记忆约束梯度并刻画前后向迁移[21]；LAMOL 通过生成旧任务样本支持语言持续学习[22]。面向语言模型，O-

LoRA 研究正交低秩子空间，LoRAMoE 通过低秩专家与路由缓解知识遗忘 [23, 24]。Reflexion 则在不更新模型参数的情况下，以文字反思与情景记忆改善后续尝试 [25]。这些工作为本项目提供直接对照，也提示必须区分参数更新、上下文记忆和额外尝试次数带来的收益。对工具智能体，旧答案仍然正确并不保证旧动作仍然符合更新后的接口规则；历史轨迹是否值得重放，需要同时检查能力覆盖和工具版本有效性。

置信校准与选择性预测能够刻画可靠性，行动场景对信息时点提出更严格要求。现代神经网络可能存在置信度与正确率不匹配的问题，温度缩放提供了简洁的后处理基线 [26]。Semantic Uncertainty 从语义等价角度刻画自然语言生成的不确定性 [27]。然而，多个表达相近的回答可能对应不同工具参数或不同环境后果。行动校准需要明确预测对象：模型估计的是候选动作满足前置条件的概率，还是整个任务最终成功的概率；两者不能混用。校准特征还必须在动作执行前可取得，不能将执行后才知道的验证结果回填为决策依据。

选择性预测通过拒绝部分样本改变风险与覆盖率的关系 [28]。共形风险控制研究在明确条件下约束特定损失的期望，适应性共形推断研究分布变化中的长期覆盖 [29, 30]。这些结论各有统计对象和假设，不意味着任意工具变化下的每个动作都能获得安全保证。WebArena 等可复现交互环境为功能正确性验证提供基础 [31]，但真正评价持续校准，还需要将策略版本、校准数据时点和被拒绝动作的潜在结果分开记录。否则，系统可能仅因拒绝更多任务而表现出较低错误率。

1.3 现有研究的不足

综上，现有研究分别推进了参数效率、轨迹监督、抗遗忘和置信校准。本项目关注这些方法进入动态任务序列后出现的三个具体问题。首先，任务变化强度并不直接等于参数需求，反馈噪声也可能被误判为能力不足；如果资源分配只依据当前损失，额外更新可能强化错误轨迹并干扰旧能力。其次，轨迹筛选与能力保持存在联系，过度保留容易成功的轨迹会缩小能力覆盖，简单重放旧轨迹又可能传播已失效的工具规则。再次，后训练改变了策略及其访问状态，旧校准器的误差不一定保持稳定；只有已执行动作留下结果时，还会产生选择偏差。

这三个问题不能仅靠增加模块数量解决。需要在累计参数、轨迹记忆和计算成本均受约束的条件下，区分任务漂移、验证证据与真实能力变化的作用，并观察这些作用如何传递到行动风险。项目因此以任务变化、轨迹证据和校准时点为共同研究线索，使背景问题能够对应到具体方法和验证终点。

1.4 关键科学问题与研究切入点

本项目的中心科学问题是：**在固定总资源预算和有限记忆下，轨迹证据如何影响参数适配、历史能力保持与行动风险之间的关系，其有效条件和失效边界是什么？**进一步提出三个子问题：任务状态与候选参数更新的边际收益之间是否存在可利用的稳定关系？执行证据、验证器反馈与不确定性如何共同区分轨迹正确性和训练价值？策略及工具版本改变后，历史记忆与独立校准如何影响行动选择的可靠性？

由此形成待检验的中心假设：在反馈可审计、任务变化具有一定可识别性且资源预算匹配的条件下，利用证据协调更新、记忆和校准，能够在预先规定的覆盖率、遗忘和行动风险容限内提高任务成功率；这一收益会随证据失真、反馈延迟和任务差异增大而减弱。若收益在匹配生成、验证和训练成本后消失，或只能通过持续扩充适配器与降低覆盖率获得，则该假设不成立。

研究将保留四条相互衔接的路线：任务感知的参数高效适配、证据驱动的可信轨迹学习、有界记忆下的持续抗遗忘、独立校准下的风险感知执行。各路线首先对其直接效果进行检验，再通过同一任务序列上的组合对照研究相互作用。预期贡献包括可比较的持续后训练方法、对证据失效情形的解释，以及包含成本、遗忘和风险覆盖率的可复现评价方案；不预设所有指标均同时改善，也不将尚未开展的实验写为已有结论。

参考文献

[1] Yao S, Zhao J, Yu D, Du N, Shafran I, Narasimhan K, Cao Y. ReAct: Synergizing Reasoning and Acting in Language Models[J/OL]. arXiv preprint arXiv:2210.03629, 2022. https://arxiv.org/abs/2210.03629.

[2] Schick T, Dwivedi-Yu J, Dessì R, Raileanu R, Lomeli M, Zettlemoyer L, Cancedda N, Scialom T. Toolformer: Language Models Can Teach Themselves to Use Tools[J/OL]. arXiv preprint arXiv:2302.04761, 2023. https://arxiv.org/abs/2302.04761.

[3] Liu X, Yu H, Zhang H, Xu Y, Lei X, Lai H, Gu Y, Ding H, Men K, Yang K, Zhang S, Deng X, Zeng A, Du Z, Zhang C, Shen S, Zhang T, Su Y, Sun H, Huang M, Dong Y, Tang J. AgentBench: Evaluating LLMs as Agents[J/OL]. arXiv preprint arXiv:2308.03688, 2023. https://arxiv.org/abs/2308.03688.

[4] Qin Y, Liang S, Ye Y, Zhu K, Yan L, Lu Y, Lin Y, Cong X, Tang X, Qian B, Zhao S, Hong L, Tian R, Xie R, Zhou J, Gerstein M, Li D, Liu Z, Sun M. ToolLLM: Facilitating Large Language Models to Master 16000+ Real-world APIs[J/OL]. arXiv preprint arXiv:2307.16789, 2023. https://arxiv.org/abs/2307.16789.

[5] Yao S, Shinn N, Razavi P, Narasimhan K. τ-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains[J/OL]. arXiv preprint arXiv:2406.12045, 2024. https://arxiv.org/abs/2406.12045.

[6] Hu E J, Shen Y, Wallis P, Allen-Zhu Z, Li Y, Wang S, Wang L, Chen W. LoRA: Low-Rank Adaptation of Large Language Models[J/OL]. arXiv preprint arXiv:2106.09685, 2021. https:

//arxiv.org/abs/2106.09685.

[7] Dettmers T, Pagnoni A, Holtzman A, Zettlemoyer L. QLoRA: Efficient Finetuning of Quantized LLMs[J/OL]. arXiv preprint arXiv:2305.14314, 2023. https://arxiv.org/abs/2305.14314.

[8] Zhang Q, Chen M, Bukharin A, Karampatziakis N, He P, Cheng Y, Chen W, Zhao T. AdaLoRA: Adaptive Budget Allocation for Parameter-Efficient Fine-Tuning[J/OL]. arXiv preprint arXiv:2303.10512, 2023. https://arxiv.org/abs/2303.10512.

[9] Liu S-Y, Wang C-Y, Yin H, Molchanov P, Wang Y-C F, Cheng K-T, Chen M-H. DoRA: Weight-Decomposed Low-Rank Adaptation[J/OL]. arXiv preprint arXiv:2402.09353, 2024. https://arxiv.org/abs/2402.09353.

[10] Ouyang L, Wu J, Jiang X, Almeida D, Wainwright C L, Mishkin P, Zhang C, Agarwal S, Slama K, Ray A, Schulman J, Hilton J, Kelton F, Miller L, Simens M, Askell A, Welinder P, Christiano P, Leike J, Lowe R. Training language models to follow instructions with human feedback[J/OL]. arXiv preprint arXiv:2203.02155, 2022. https://arxiv.org/abs/2203.02155.

[11] Wang Y, Kordi Y, Mishra S, Liu A, Smith N A, Khashabi D, Hajishirzi H. Self-Instruct: Aligning Language Models with Self-Generated Instructions[J/OL]. arXiv preprint arXiv:2212.10560, 2022. https://arxiv.org/abs/2212.10560.

[12] Zhou C, Liu P, Xu P, Iyer S, Sun J, Mao Y, Ma X, Efrat A, Yu P, Yu L, Zhang S, Ghosh G, Lewis M, Zettlemoyer L, Levy O. LIMA: Less Is More for Alignment[J/OL]. arXiv preprint arXiv:2305.11206, 2023. https://arxiv.org/abs/2305.11206.

[13] Rafailov R, Sharma A, Mitchell E, Ermon S, Manning C D, Finn C. Direct Preference Optimization: Your Language Model is Secretly a Reward Model[J/OL]. arXiv preprint arXiv:2305.18290, 2023. https://arxiv.org/abs/2305.18290.

[14] Zeng A, Liu M, Lu R, Wang B, Liu X, Dong Y, Tang J. AgentTuning: Enabling Generalized Agent Abilities for LLMs[J/OL]. arXiv preprint arXiv:2310.12823, 2023. https://arxiv.org/abs/2310.12823.

[15] Luo X, Zhang Y, He Z, Wang Z, Zhao S, Li D, Qiu L K, Yang Y. Agent Lightning: Train ANY AI Agents with Reinforcement Learning[J/OL]. arXiv preprint arXiv:2508.03680, 2025. https://arxiv.org/abs/2508.03680.

[16] Li Z, Zhang H, Han S, Liu S, Xie J, Zhang Y, Choi Y, Zou J, Lu P. In-the-Flow Agentic System Optimization for Effective Planning and Tool Use[J/OL]. arXiv preprint arXiv:2510.05592, 2025. https://arxiv.org/abs/2510.05592.

[17] He Z, Zhang S, Zhou Z, Yang Y, Kang Y, Zhang Y, Qiu L K, Tsui T Y, Xu J, Luo C. Agent Lightning v1.0: Towards Harnessed Agentic RL[J/OL]. arXiv preprint arXiv:2608.17528, 2026. https://arxiv.org/abs/2608.17528.

[18] Cobbe K, Kosaraju V, Bavarian M, Chen M, Jun H, Kaiser L, Plappert M, Tworek J, Hilton J, Nakano R, Hesse C, Schulman J. Training Verifiers to Solve Math Word Problems[J/OL]. arXiv preprint arXiv:2110.14168, 2021. https://arxiv.org/abs/2110.14168.

[19] Lightman H, Kosaraju V, Burda Y, Edwards H, Baker B, Lee T, Leike J, Schulman J, Sutskever I, Cobbe K. Let's Verify Step by Step[J/OL]. arXiv preprint arXiv:2305.20050, 2023. https://arxiv.org/abs/2305.20050.

[20] Kirkpatrick J, Pascanu R, Rabinowitz N, Veness J, Desjardins G, Rusu A A, Milan K, Quan J, Ramalho T, Grabska-Barwinska A, Hassabis D, Clopath C, Kumaran D, Hadsell R. Overcoming catastrophic forgetting in neural networks[J/OL]. arXiv preprint arXiv:1612.00796, 2016. https://arxiv.org/abs/1612.00796.

[21] Lopez-Paz D, Ranzato M. Gradient Episodic Memory for Continual Learning[J/OL]. arXiv preprint arXiv:1706.08840, 2017. https://arxiv.org/abs/1706.08840.

[22] Sun F-K, Ho C-H, Lee H-Y. LAMOL: LAnguage MOdeling for Lifelong Language Learning[J/

OL]. arXiv preprint arXiv:1909.03329, 2019. https://arxiv.org/abs/1909.03329.
[23] Wang X, Chen T, Ge Q, Xia H, Bao R, Zheng R, Zhang Q, Gui T, Huang X. Orthogonal Subspace Learning for Language Model Continual Learning[J/OL]. arXiv preprint arXiv:2310.14152, 2023. https://arxiv.org/abs/2310.14152.
[24] Dou S, Zhou E, Liu Y, Gao S, Zhao J, Shen W, Zhou Y, Xi Z, Wang X, Fan X, Pu S, Zhu J, Zheng R, Gui T, Zhang Q, Huang X. LoRAMoE: Alleviate World Knowledge Forgetting in Large Language Models via MoE-Style Plugin[J/OL]. arXiv preprint arXiv:2312.09979, 2023. https://arxiv.org/abs/2312.09979.
[25] Shinn N, Cassano F, Berman E, Gopinath A, Narasimhan K, Yao S. Reflexion: Language Agents with Verbal Reinforcement Learning[J/OL]. arXiv preprint arXiv:2303.11366, 2023. https://arxiv.org/abs/2303.11366.
[26] Guo C, Pleiss G, Sun Y, Weinberger K Q. On Calibration of Modern Neural Networks[J/OL]. arXiv preprint arXiv:1706.04599, 2017. https://arxiv.org/abs/1706.04599.
[27] Kuhn L, Gal Y, Farquhar S. Semantic Uncertainty: Linguistic Invariances for Uncertainty Estimation in Natural Language Generation[J/OL]. arXiv preprint arXiv:2302.09664, 2023. https://arxiv.org/abs/2302.09664.
[28] Geifman Y, El-Yaniv R. Selective Classification for Deep Neural Networks[J/OL]. arXiv preprint arXiv:1705.08500, 2017. https://arxiv.org/abs/1705.08500.
[29] Angelopoulos A N, Bates S, Fisch A, Lei L, Schuster T. Conformal Risk Control[J/OL]. arXiv preprint arXiv:2208.02814, 2022. https://arxiv.org/abs/2208.02814.
[30] Gibbs I, Candès E. Adaptive Conformal Inference Under Distribution Shift[J/OL]. arXiv preprint arXiv:2106.00170, 2021. https://arxiv.org/abs/2106.00170.
[31] Zhou S, Xu F F, Zhu H, Zhou X, Lo R, Sridhar A, Cheng X, Ou T, Bisk Y, Fried D, Alon U, Neubig G. WebArena: A Realistic Web Environment for Building Autonomous Agents[J/OL]. arXiv preprint arXiv:2307.13854, 2023. https://arxiv.org/abs/2307.13854.
[32] Sun Q, Yan F, Sun W, Zhou Y. DWT-Former: Fusing wavelet-based multi-scale features and transformer-based temporal representations for photovoltaic power forecasting[J/OL]. Energy, 341 : 139283, 2025. https://doi.org/10.1016/j.energy.2025.139283.
[33] Liu Y, Yan F, Xu P, Liu C, Wang L. WaveKAN: Adaptive wavelet decomposition and Kolmogorov-Arnold network for long-term time series forecasting[J/OL]. Neurocomputing, 682 : 133361, 2026. https://doi.org/10.1016/j.neucom.2026.133361.
[34] Yan F, Li Z, Silamu W, Li Y. Knowledge-aware image understanding with multi-level visual representation enhancement for visual question answering[J/OL]. Machine Learning, 113(6) : 3789–3805, 2024. https://doi.org/10.1007/s10994-023-06426-6.

（二）研究内容：

（提纲不做限制，请按照研究工作的自身逻辑撰写。应提炼出特色与创新点、年度研究计划）

1.1 研究内容

本项目围绕动态任务下智能体的持续后训练展开，研究对象为具有明确工具接口、状态转移和结果判定的文本工具智能体。四项研究内容分别考察参数更新、轨迹训练价值、历史能力保持和行动选择，形成由证据支持的持续适应过程。拟在公

开模型与可复现沙箱上实现 PACT-Agent，研究任务分布变化、工具规则变化和反馈噪声三类干预，不将真实业务上线作为检验方法有效性的前提。

研究内容一：动态任务感知的参数高效适配。研究任务表征、可观察漂移证据与低秩参数更新收益之间的关系。任务表征由请求语义、所需工具、轨迹长度和历史失败类型构成；漂移检测仅使用当前可获得的任务输入与既往日志。针对新建、复用、冻结或调整适配器等候选动作，估计其单位计算成本下的适配收益与旧能力干扰，在预定总预算内选择更新位置和低秩容量。重点判断：任务变化能否提供超出梯度重要性本身的信息，以及这种信息在反馈噪声较高时何时失效。

研究内容二：证据驱动的可信轨迹筛选与学习。研究执行状态、验证器判断、轨迹一致性和模型不确定性对样本训练价值的共同作用。分别定义轨迹是否满足任务目标、是否包含可定位错误，以及加入训练后是否改善独立开发集表现。优先用确定性工具状态与约束检查建立标签，再以审计样本估计验证器偏差；对缺乏可靠结果的轨迹保留未知状态。形成面向监督微调、样本加权和同任务偏好对构造的选择机制，考察其能否在相同候选池和训练成本下保留有效困难样本、减少伪成功轨迹。

研究内容三：有限记忆下的能力保持与持续后训练。研究参数记忆和经验轨迹记忆在固定容量下的作用差异。参数记忆记录适配器的能力覆盖、版本与使用代价；轨迹记忆保留覆盖历史任务和典型失败类型的可验证样本。针对新任务学习引起的干扰，比较适配器复用、正交约束、经验重放和组合机制。对过期工具轨迹重新执行规则校验，必要时淘汰；通过预先保留的历史开发样本判断合并或替换是否可接受。目标是明确有限记忆条件下能够保留什么能力，以及何种任务差异会导致保持与适应之间的冲突。

研究内容四：行动置信校准与风险感知执行。研究候选动作的预测置信度与其实际正确性之间的对应关系，并与整项任务成功概率分别建模。以更新后冻结的策略在独立校准任务上生成动作，构造执行前可用的证据特征；在沙箱中获得动作后果标签，再建立校准器和选择规则。比较直接执行、追加验证、有限次重规划和拒绝四类行为，联合评估执行覆盖率、选择风险、全任务成功率和额外开销。重点分析策略改变、接口更新及标签延迟对校准器有效性的影响。

1.2 研究目标

总体目标是在固定训练与记忆预算下，建立可重现的 PACT-Agent 方法，解释证据条件如何改变新任务适应、历史能力保持和行动风险的关系。项目以可检验的方法与边界结论为成果，不将大模型规模增长或额外调用次数作为取得性能优势的主

要来源。

参数适配以等预算任务成功率和适配速度为终点，对照静态 LoRA、AdaLoRA 及不更新策略；轨迹学习以同一候选池中的净训练收益、伪成功保留率和困难正确样本覆盖率为终点，对照随机选择、仅成功过滤及仅验证器选择；能力保持以固定记忆下的平均历史成功率和遗忘量为终点，对照仅重放、O-LoRA 与固定路由；行动校准以风险覆盖率曲线、Brier 分数及全任务成功率为终点，对照未校准、温度缩放和固定阈值执行。各目标使用同一任务版本及共同随机种子配对比较。

1.3 拟解决的关键科学问题

其一，任务变化如何转化为参数更新需求？任务特征相近未必需要相同参数子空间，工具接口变化也可能仅需更新少量映射。项目比较任务证据和梯度重要性对候选更新收益的增量解释力，检验任务感知分配是否在预算匹配后仍有效。

其二，什么证据能够识别真正有用的学习轨迹？结果正确、步骤正确与训练有益是不同属性。项目分析不确定性与执行证据是否存在互补作用，特别考察验证器与生成器错误相关时的失效，以及高质量筛选是否损害长尾任务覆盖。

其三，能力保持与行动校准何时能够兼容？旧任务正确率恢复后，置信度仍可能偏移；保护历史参数也可能妨碍新工具适应。项目在相同策略版本下分别测量遗忘和校准误差，并检验独立校准对降低行动风险的贡献及其成本。

1.4 研究方法

问题形式化与资源约束。设第 t 阶段的任务分布为 $\mathcal{D}_t$，冻结主干参数为 θ_0，可训练低秩参数为 ϕ_t，记忆为 $\mathcal{M}_t$，校准器为 g_t。一条轨迹记为 $\tau = (x, a_1, o_1, \ldots, a_K, o_K, y)$，其中 x 为任务，a_k 与 o_k 分别为动作和工具观测，y 为经任务判定器核验的结果。未能判定的 y 不当作成功标签。拟采用如下受约束目标组织比较：

$$\max \ \overline{S} \quad \text{s.t.} \quad F \le \delta_F, \quad R(c_0) \le \delta_R, \quad P_{\text{all}} \le B_P, \quad |\mathcal{M}_t|_{\text{byte}} \le B_M, \quad C_{\text{all}} \le B_C. \tag{1}$$

这里 $\overline{S}$ 为按阶段等权平均的任务成功率，每阶段以全部指派任务为分母，拒绝与未完成不计成功。F 为历史任务遗忘量：在各历史任务、原工具及判定器的冻结快照上，以该任务学习结束时的策略为参照，计算当前策略成功率降幅的非负部分并对历史任务等权平均；现行规则下的迁移成功率另报，不混入 F。$R(c_0)$ 为预定覆盖率 c_0 下的选择风险。P_{all} 统计所有保留适配器、路由器及新增预测模块，C_{all} 包括轨迹生成、验证、探测更新、正式训练和重新校准的实际成本，调参、审计及失败运行逐方法列账，共用评价成本单列；外部调用费用另列。δ_F、δ_R 与 c_0 在开发阶段预先

锁定。若约束不可同时满足，报告不可行区域及各项代价，不以改变阈值隐藏失败。

数据来源与任务变化。主要采用 AgentBench 中可离线运行的文本交互任务和 τ-bench 的工具与末态判定思想构建版本化实验；现有标准测试集作为冻结外部评价，定制训练任务另行生成并审计[3, 5]。工具沙箱实现检索、计算、结构化查询和受控状态修改等能力，所有状态修改限定在可重置实验副本。分别设置任务组成渐变、工具字段或规则突变、反馈错误及延迟，再设置少量复合变化。每类变化都记录实际操作和标签生成方式，避免把增加题目难度直接等同于分布漂移。

公开能源时序数据作为第二层验证，智能体完成历史窗口读取、预测器选择、误差计算与报告生成。以训练时可见的时间戳为界构造季节变化和噪声变化，预测目标仅在其真实可获得时点进入反馈。数据具体来源与许可在首阶段核验后固定，不声称已取得私有场站或电网数据。该环境用于检验方法对非平稳任务的适用性，不把金融交易收益或真实电网控制作为终点。

训练、调参与评价隔离。主实验在每个已发生的工具版本内，按独立任务来源、模板与用户意图划分训练集、开发集、校准集和最终测试集，并遵守反馈时间先后；版本作为共同实验条件，同源任务不跨区。完全未见版本的外推评价另列，在获得该版本反馈前不得重校准。同源任务的改写、同一状态派生轨迹和近重复问题放在同一分区。开发集用于预算选择、质量分学习和超参数比较；校准集只在策略冻结后拟合概率映射与执行门槛；测试集用于阶段性冻结评价，结果不回流算法。另设可重放的历史开发样本判断适配器合并，不能借助历史测试集选择保留哪一个模型。开发任务再按模板交叉留出，质量分拟合与效用预测核验使用不同折；历史校准记录仅在对应版本的校准比较中使用，不转作训练或质量分拟合样本。

实验规模初稿为**【暂定：以3B级模型完成主实验，7B级模型完成关键复核；设置6个连续任务阶段、3种任务顺序和3个训练随机种子】**。每阶段样本量先通过小规模试跑估计成本，再在正式比较前锁定。全参数微调仅作为可承受规模的参照，超过统一预算时报告其成本及不可比部分。主要效果比较使用等 GPU 时方案，并补充等训练样本与等可训练参数方案，避免用单一“参数少”替代实际效率。

统计分析与失败判据。以任务实例为配对单位汇总成功和失败，以任务模板或时间块为重采样簇，报告成功率差、遗忘量差及风险覆盖率曲线的置信区间。随机种子作为重复实验单独呈现，不将同一轨迹中的多个步骤当作独立样本。预先指定一个主要比较：在锁定覆盖率、遗忘和风险容限下，完整方法相对最强等预算组合基线的任务成功率差。最强组合基线及阶段权重在开发阶段确定，不由测试结果反

选。

最小有效成功率收益 ϵ_S 以及绝对遗忘、风险容限 δ_F、δ_R 在开发阶段锁定。支持主要假说要求成功率差置信区间下界超过 ϵ_S，且完整方法的 F、$R(c_0)$ 区间上界分别不超过 δ_F、δ_R；成功率差上界低于 ϵ_S，或 F、$R(c_0)$ 的区间下界超过对应容限时构成反证，其余情况报告证据不足。遗忘差另作次要比较，不混入绝对容限的判据。多条路线的次要检验采用多重比较校正。结果分析同时保留失败任务与不可判定结果，避免只分析被系统接受的轨迹。

执行覆盖率定义为至少执行一次动作的任务数占全部指派任务数，选择风险定义为至少出现一次错误执行的任务数占有执行任务数；中途拒绝的任务仍计入相应分母。同时报告最终完成率、执行步数和最大步数，防止提前停止造成表面改善。覆盖容差在开发阶段锁定，测试报告实际覆盖；无法达到预定覆盖率时记为不可达，不外推风险值。预先固定动作结果观察窗口：已确认错误的任务计入错误数；尚无已知错误但存在未知动作结果的任务单列为未知。风险识别下界为已知错误数除以执行任务数，上界为已知错误与未知任务数之和除以执行任务数，同时报告未知率。风险区间同时包络识别上下界与抽样不确定性：支持风险约束须使保守上界的抽样上限低于容限，反证则须已知错误下界的抽样下限超过容限；仅因未知率高而上界超限时报告证据不足。概率评分只评价结果可判定的动作并报告标签覆盖，未知结果不视为正确。

1.5 技术路线

总体技术路线。先固定任务、工具和评价版本，用既往交互记录构造任务状态与漂移证据；据此选择低秩更新的候选位置和预算，再由当前策略生成训练轨迹。轨迹经独立执行检查、验证器及一致性检查后进入质量建模，为参数更新和记忆选择提供依据。完成有界记忆约束下的持续后训练后，冻结新策略，使用独立校准任务确定动作概率映射和选择门槛。部署于沙箱的策略产生新日志，只有在下一轮划分中允许使用的记录才能进入后续训练，最终测试结果始终隔离。四条分路线由此共享证据定义和接口，各自使用符合用途的数据分区。

分路线一：任务感知的参数高效适配。输入当前任务特征、过去阶段的训练日志、适配器摘要及剩余预算。首先将请求语义、工具集合和既往失败类别编码为任务状态 z_t，以窗口比较得到漂移证据 d_t；再在预定低秩配置集合中进行有限次探测更新，估计不同层与适配器的开发集收益及历史开发集损失。探测成本计入总预算，既往轨迹尚未获得标签时不使用未来结果。以候选更新的收益与成本比排序，并施加

总容量限制，在复用、更新、冻结和替换之间选择；不会无限追加适配器。输出带有版本和成本记录的适配策略，为轨迹生成提供当前 Agent。与静态 LoRA、AdaLoRA 和随机任务路由比较，并打乱任务证据但保持计算量不变，以判断收益是否确由任务信息带来 [6, 8]。

分路线二：证据驱动的可信轨迹学习。输入路线一产生的候选轨迹及工具版本。先由末态目标、参数合法性和任务约束给出执行证据 e，再加入验证器分数 v、轨迹一致性 s 和不确定性 u。以人工抽查和确定性标签构成的开发数据学习质量分 $q = f(e, v, s, u)$，分别保留正确性估计和训练效用估计，不将 q 直接解释为成功概率。对无结果标签的轨迹设置未知类别；对困难但已验证正确的样本维持覆盖配额。监督训练使用有界权重，偏好训练只对同任务、相近工具成本且优劣有独立证据的轨迹配对，防止较长轨迹仅因调用更多而被判优 [13, 14]。输出加权训练池、可信偏好对和审计记录，交给路线三完成更新与记忆管理。验证时固定候选池，对照随机、成功过滤、单验证器及全部证据方案。训练效用以配对短程探测中“加入 / 不加入同一轨迹”对独立开发任务的增量收益为依据，候选模型、训练步数及随机种子配对；验证器标签不能同时充当该效用的真值。

分路线三：有界记忆下的持续抗遗忘。输入加权训练池、历史适配器及轨迹记忆。以覆盖任务能力和失败类型为原则选择固定字节容量的回放样本，并剔除已不符合当前工具规则的记录。更新目标由当前任务学习项、历史重放项和低秩干扰约束组成；先采用固定权重作为基线，再比较由开发集证据控制的有限候选权重。参考 O-LoRA 对参数子空间干扰的处理，并以 GEM 式历史约束作为方法参照 [23, 21]。适配器库达到容量上限时，根据历史开发集表现决定合并、替换或冻结，合并失败则保留旧版本并缩减新任务目标。输出固定容量的适配器库、经验记忆及冻结后的策略版本，随后交给路线四校准。消融分别关闭参数记忆、轨迹记忆和证据协调，保持容量、训练步数及回放读取量匹配，以识别两类记忆的作用及交互。

分路线四：独立校准与风险感知执行。输入冻结策略、当前工具版本和独立校准任务。对动作 a 仅使用执行前的上下文、模型输出及已观察历史构造特征 h，预测其正确性 $p = g(h)$；另为整项任务成功建立单独预测头，避免两种概率混淆。以温度缩放或逻辑校准为基础，比较加入漂移和工具状态特征后的校准效果 [26]。对同一标量动作正确性分数采用单调温度缩放，作为保持排序的校准对照，其 Brier 分数改善不能直接证明同覆盖率风险降低；后者只检验新增行动证据是否改善选择排序。对每个候选动作按预定门槛选择执行、追加验证、有限重规划或拒绝，所有追加操

作计入推理成本。校准任务中的候选动作在可重置副本上获得影子结果，主执行是否接受不影响其被评估机会，从而缓解只观测已接受动作的偏差。该影子过程仅用于沙箱评价，不推定真实业务中可获得反事实标签。输出校准器、阈值及风险覆盖率结果，分别检验冻结校准、每阶段重校准和漂移触发重校准。反馈不足或工具规则突然改变时转为保守执行并记录覆盖率下降，不声称无条件风险保证[28, 29, 30]。

1.6 关键技术

跨模块证据的一致表达。为任务版本、工具版本、动作、观测、验证结果、模型版本和时间戳建立统一定义，使一条轨迹能够追溯其使用目的。共用的是变量含义与处理接口，训练轨迹和校准任务仍分别保存。对不确定性使用固定采样预算，分别比较输出概率、候选动作分歧和语义一致性；语义一致性仅辅助判断，最终以工具结果和任务约束区分等价动作[27]。

相关错误的机制对照。在可确定真值的沙箱中设置“错误相关性高 / 低”与“错误轨迹回放剂量高 / 低”的 2×2 对照。按任务难度分层固定生成器及验证器的边际假阳性、假阴性率，预先锁定联合错误注入与多证据聚合规则，并固定任务重叠度。减少已知错误轨迹回放时，以任务、难度和长度匹配的正确轨迹补足训练量，使总训练成本相当。依次观察伪成功入选率、错误回放暴露量、参数干扰及历史任务损失，检验错误是否在低秩更新场景中被放大。真值替换仅用于机制诊断，不作为可部署算法的收益。若剂量干预未改变历史损失，或成本匹配后效应消失，则不支持该链式解释。

可识别的联合效果。完整方法之外设置各模块获得同类证据、采用同类校准器并享有相同调参总预算的模块组合基线，仅关闭跨模块协调规则；删除或打乱证据另作信息消融。采用局部交互对照：轨迹筛选有无与记忆协调有无组成一组，策略更新有无与重校准有无组成另一组。在相同资源下检验交互项，避免将多个单模块改进简单相加后称为协同。主要对照均锁定工具、提示、解码与最大行动步数，必要时同时报告关闭重规划后的模型本体结果。

跨框架复现与工程交付。先实现最小可运行文本工具流程，保存低秩参数、日志及评价脚本，再完成飞桨生态兼容验证。跨框架迁移分别检查权重形状、分词与工具格式、固定输入输出差异及任务结果，尚未验证的功能不标为已兼容。参考 Agent Lightning 的训练与执行分离方式组织接口，但算法结论不依赖某一运行控制器的专属特性[15, 17]。

1.7 可行性分析

四条路线均具有可运行的基础对照：低秩适配、结果验证、经验回放与后处理校准可以先独立运行，再比较协调机制。某一路线未达到预期时，仍可通过独立对照形成清楚的边界结论。现有算力适合以中小规模开源模型开展参数高效实验；模型规模升级安排在关键机制得到证据之后。通过公开任务与自包含工具沙箱降低外部接口变更的影响，通过固定时间块与工具版本支持时序补充验证。首年优先完成可信对照和成本核算，扩展环境与更大模型根据阶段结果推进。

1.8 项目特色

本项目将动态工具任务中的可验证结果与持续学习过程连接起来，用同一套资源口径比较参数适配、轨迹学习、能力保持和行动校准。研究以文本工具沙箱为主体、公开时序任务为补充，既保留 Agent 技术的通用性，也利用申请人在非平稳时序建模方面的积累。四条路线均设置能够独立运行的基础对照，方法增益、额外成本和失效情形分别报告。

1.9 创新点

从轨迹证据的传递关系解释持续适应中的收益与干扰。已有动态秩、适配器路由和经验重放方法分别解决局部问题。本项目拟研究验证偏差如何经轨迹入选和回放进入低秩更新，并影响历史能力，另行检验更新后的行动置信度变化；通过证据打乱、相关错误注入及容量匹配的组合对照，判断哪些证据信号能够支持有效更新，哪些信号会放大干扰。创新性取决于能否得到超出独立模块组合的可重复机制证据，而非动态秩或闭环结构本身。

将执行正确性与训练效用分开建模，研究有限记忆中的轨迹取舍。轨迹成功标签只能说明一次交互结果，不能直接说明其训练价值。项目拟用独立开发集上的配对探测更新检验候选轨迹的边际作用，在固定生成、验证和训练成本下比较易例、困难正确样本及高置信伪成功样本的选择后果，并考察其通过记忆复用影响旧能力的路径。该设计预期形成可审计的样本取舍依据及其失效条件。

围绕策略与工具版本变化建立可核验的行动校准研究。现有回答级校准不能直接替代动作正确性判断。本项目拟在策略冻结后用独立任务重建行动概率映射，并利用可重置沙箱中的影子结果分析选择偏差，在相同覆盖率与推理预算下区分校准、重规划和拒绝带来的效果。预期回答校准信息何时过期、如何识别过期及恢复需要多少反馈，不将经验风险降低写成任意漂移下的安全保证。

1.10 年度研究计划

按照本次 CCF–百度松果基金研究资料，以**【暂定：合同生效后 12 个月】**组织任务，月份均为相对月份。经费与最终验收要求依据**【待补 F-PACT-01：正式课题附件及合同条款】**核定。以下安排体现各路线的依赖关系，不以模型规模或论文数量代替研究进展。

第 1–2 个月：建立可比较的实验起点。核验公开数据与模型许可，固定工具沙箱、任务序列和四类数据分区；复现静态低秩适配、基本验证器、经验回放和温度缩放。完成小规模成本测量，预先确定主要比较、覆盖率、遗忘容限和试验规模。形成任务协议、基础结果及成本清单，作为后续算法比较的共同起点。

第 3–4 个月：检验任务证据与参数更新需求。研究任务状态表征和有限探测更新，比较证据驱动分配与 AdaLoRA 等方法。在预算匹配后判断是否存在稳定增益；若任务证据未提供增量信息，则以固定配置保留可运行主线，并记录其边界。交付参数适配模块和相应消融结果。

第 5–6 个月：区分轨迹正确性与训练价值。建立结果与步骤证据，审计验证器错误及样本覆盖，完成同任务轨迹选择与偏好构造。对相关错误、反馈延迟及困难样本进行独立干预，形成可信轨迹学习模块和经版本标识的候选池。

第 7–8 个月：研究有界记忆下的能力保持。在固定适配器与轨迹记忆容量下比较复用、合并、重放及干扰约束，检验轨迹选择与历史记忆的相互作用。交付连续任务评价与遗忘分析；若合并导致历史能力明显下降，保留容量内的冻结策略并缩减扩展任务。

第 9–10 个月：完成行动校准与双层验证。对冻结策略建立独立校准器，比较固定、周期更新与漂移触发更新；开展影子审计、风险覆盖率分析及公开时序补充实验。完成核心流程在飞桨生态中的兼容检查，记录实际支持范围。

第 11–12 个月：形成可复核结论与交付。完成多种任务顺序、关键模型规模、消融与成本复核，整理失败案例和统计区间。冻结代码、配置、适配器与可公开轨迹，形成研究论文稿、技术报告和实验复现说明，按合同要求整理验收材料。

1.11 预期研究结果

预期形成一套 PACT-Agent 研究原型，包含参数适配、轨迹学习、有界记忆和行动校准四类模块；形成一套版本化任务及评价资源，完整记录训练、生成、验证、存储和推理成本；形成关于证据条件、任务变化与适应–遗忘–风险关系的实验分析。每项主要结论附对照、重复试验和失败条件，未观察到显著增益时也提交可解释的

否定性结果。

拟形成可投稿的研究论文、开源代码及技术报告，具体数量与开放范围按任务书确定。可公开资产仅包含许可允许的代码、配置与轨迹；第三方模型权重、受限制数据及既有合同成果按原许可处理。预期成果不列未经依据的专利、性能百分比或真实业务收益承诺。

（三）研究基础：

1．研究基础与可行性分析（与本项目相关的研究工作积累和已取得的研究工作成绩，研究风险的应对措施等）；

1.1 与本项目相关的研究工作积累

申请人为新疆大学副教授、硕士研究生导师，研究积累涉及多尺度时序建模、多源信息融合与视觉问答。与本项目最直接的联系在于非平稳数据表示、不同来源证据的组织和可复现实验设计。上述积累可以支持动态任务构造、轨迹证据表示与方法比较；本项目的智能体持续后训练、适配器记忆及行动校准仍需专门研究和验证。

在非平稳时序建模方面，申请人参与完成 DWT-Former 与 WaveKAN 研究。DWT-Former 融合小波多尺度特征与 Transformer 时间表示，开展光伏功率预测 [32]。

WaveKAN 研究自适应小波分解与 Kolmogorov–Arnold 网络的长时序建模 [33]。这两项工作支撑对尺度变化、时间划分和预测误差的理解，可用于构造具有明确时间边界的动态补充任务。项目将把任务层的工具调用与底层预测器效果分开评价，避免把预测模型进步直接算为 Agent 方法收益。

在证据表示方面，申请人开展了知识感知视觉问答研究，通过多层视觉表示增强图像理解 [34]。该工作支撑对异质证据、问题条件和模型判断之间关系的分析，可迁移为本项目的轨迹证据组织思路。此次研究以文本工具任务为主体，已有多模态成果只用于说明相关方法能力，不扩展出缺少验证资源的新研究路线。

1.2 已取得的研究工作成绩

申请人为 DWT-Former 的通讯作者，该成果发表于 *Energy*，DOI 为 10.1016/j.energy.2025.139283；为 WaveKAN 的共同第一作者，该成果发表于 *Neurocomputing*，DOI 为 10.1016/j.neucom.2026.133361；为 Knowledge-aware Image Understanding with Multi-level Visual Representation Enhancement for Visual Question Answering 的第一作者兼通讯作者，该成果发表于 *Machine Learning*，DOI 为 10.1007/s10994-023-06426-6。作者身份依据申请人已确认资料，题录依据出版登记元数据核对。

申请人主持多模态技术、光伏功率预测及知识库问答相关项目，并参与高效注

意力机制研究，具备组织模型研究和软件实现的经验。有关项目的正式名称、经费、执行期及本项目边界在承担项目部分列示。已有成果能够说明研究积累，但不作为 PACT-Agent 已实现性能提升的证据；本项目将新建专用工具沙箱、轨迹库和校准实验，所有先导结果均以实际运行记录为准。

1.3 可行性分析

理论与方法方面，参数高效训练、经验回放和概率校准均具有明确基础方法，能够先形成独立基线再开展机制研究。任务证据是否有效、轨迹选择是否放大验证偏差以及校准是否随策略更新失效，都可以通过受控干预与组合对照检验，不依赖无法观察的业务结果。

实验与实现方面，已有多尺度时序和问答研究为任务构造、误差分析及模型实现提供经验；Linux、Python、深度学习框架、Git 与 LaTeX 工具链已具备。研究从可重置的文本工具环境开始，把外部接口变化、随机用户模拟和模型解码分别控制，先回答可识别的问题，再扩大任务范围。

组织方面，由申请人负责总体研究、关键方法设计与质量把关。模型训练、轨迹审计、持续评估和工程整合的具体承担人员为**【待补 F-PACT-02：本项目成员及确认分工】**。现有其他项目的学生名单不自动作为本项目团队；相关人力投入需在首阶段落实。任务之间采用明确接口，人员未完全到位时优先完成单模型、单沙箱的核心实验。

1.4 研究风险与应对措施

证据偏差与误差放大风险。生成器和验证器可能对同类错误同时自信，使错误轨迹在筛选与重放中反复出现。早期信号是执行判定与验证器高分持续不一致，或加入高分轨迹后独立开发集反而退化。预案是增加确定性约束检查与分层人工审计，将无法判定轨迹保留为未知；暂停其进入偏好对和历史记忆，用仅可靠结果过滤的基线维持研究。相关错误干预本身保留为主要失败边界实验。

方法增益不足与任务干扰风险。动态分配和双重记忆可能增加开销，却未带来等预算收益。早期信号是总 GPU 时匹配后优势消失，或适配器合并引起历史开发集持续下降。预案是保留静态配置、固定容量回放和独立校准的最小系统，通过模块与交互消融确定无效环节；不以增加模型规模弥补缺少机制证据。最终可交付资源匹配下的边界结论。

校准失效与标签不足风险。工具突变或反馈延迟可能使当前校准器失效。若连续监测窗口中错误执行增多或有效标签不足，则冻结新的高风险状态修改、限制重

规划次数并记录覆盖率损失；在沙箱补齐独立校准数据后重新评估。仅报告具备样本支持的风险区间，不能由长期平均覆盖推断当前动作已安全。

资源与进度风险。多种顺序、规模和控制器的组合可能超出首年算力与人力。以首阶段实测成本作为预警依据，若关键复现未按阶段完成，优先保留3B级模型、核心工具任务和三类单独变化，减少外部环境与大模型扩展。飞桨兼容工作先验证核心低秩训练和日志接口，不承诺未经测试的全栈兼容；相关技术限制连同可复现基线一并交付。

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、全国重点实验室和部门重点实验室等研究基地的计划与落实情况）；

2.1 已具备的实验条件

申请人已确认可稳定使用NVIDIA A40显卡8张及NVIDIA GeForce RTX 3090 Ti显卡6张，并具备Linux、Python、深度学习框架和Git等软件工具链。上述条件用于中小规模开源模型的参数高效后训练、轨迹生成与重复实验。不同型号显卡的显存和算力不混作同一计算单位，主要比较固定硬件类型并报告实际GPU时；公开模型能否满足预定批量和上下文长度，以首阶段显存测量为准。

研究数据以可公开获取、许可允许的文本工具任务及能源时序数据为基础。实验采用版本化、可重置的本地工具沙箱，保存任务状态、动作参数与判定结果，支持同任务重复运行和影子审计。申请人现有的时间序列与问答研究经验用于建立数据划分、版本管理和评价流程；专用于PACT-Agent的轨迹与适配器资产由本项目新建。

2.2 尚缺少的实验条件及拟解决的途径

当前需落实本项目人员投入与轨迹审计安排，具体为**【待补F-PACT-02：人员名单、分工及投入期限】**。首阶段优先配置模型训练、工具环境和结果审计三类任务，按样本规模调整审计工作量；参与人数较少时减少扩展环境，保留主要机制对照。

需要依据正式基金附件核定模型生态适配、可公开数据范围与验收工作量，相关依据为**【待补F-PACT-01：课题附件、经费与验收约定】**。公开基准依赖和模型许可先核验后使用，在线工具如出现不稳定或权限限制，切换到功能一致且可审计的本地版本，并将其列为定制实验而非原基准官方分数。验证器人工审计、公共模型下载和存储需求纳入首阶段资源核算。

2.3 利用研究基地的计划与落实情况

本项目核心实验依托申请人已确认可用的设备与软件条件开展。学院公共算力可作为补充申请渠道，尚未落实的固定账号、型号或额度不计入必需条件。项目不以新增国家实验室、全国重点实验室合作或私有行业数据授权为前提；如后续获得正式支持，在实际授权范围内开展扩展验证，并保留原有资源条件下的核心对照结果。

3. 正在承担的与本项目相关的科研项目情况（申请人和主要参与者正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的资助机构、项目类别、批准号、项目名称、获资助金额、起止年月、与本项目的关系及负责的内容等）；

以下根据申请人已确认资料列示与方法或应用背景相关的在研项目。列示用于说明研究基础和任务区别，不将既有项目成果自动计入本申请验收。

多模态融合技术研究及其在新疆产业集群中的应用。自治区天池英才引进计划（青年博士人才）项目，依据任务书无独立项目批准号，经费50万元，执行期为2025年2月至2028年2月；申请人主持，负责总体研究方案、关键模型设计与成果组织。该项目面向多模态技术及产业应用，本申请聚焦文本工具智能体在固定资源下的持续后训练与行动校准，拟形成独立任务协议和机制验证。

面向政企数字化应用的智能知识库与问答系统研发。新疆数字云创有限公司委托横向项目，编号202604140013，经费12万元，执行期为2026年6月至2026年10月；申请人主持，按合同构建知识库。合同成果和知识产权由双方共同享有。本申请以公开任务与可重置工具沙箱开展通用方法研究，不将该合同的数据、代码或知识产权未经授权移作公开资产。

可学习乘积量化与状态空间模型协同的长上下文高效注意力机制研究。CAAI–蚂蚁科研基金项目，编号202604140006，经费15万元，执行期为2026年2月至2027年2月；申请人参与，负责高效注意力机制研究。该项目研究模型内部注意力计算，本申请研究动态任务中的低秩适配、轨迹学习与校准，模型内部高效注意力不列为本申请新增成果。

融合多源数据大模型驱动的光伏发电功率预测方法研究。自治区高校基本科研业务费科研项目培育类，编号XJEDU2026P005，经费5万元，其中直接经费3.9万元、间接经费1.1万元，执行期为2026年1月至2026年12月；申请人主持，负责总体方

案、模型研究与成果组织。该项目以光伏功率预测为研究终点，本申请将公开能源时序仅作为动态任务补充环境，主要终点为智能体适应、遗忘与行动风险。

本项目主要参与者及其相关在研任务待**【待补 F-PACT-02：团队名单与相关任务说明】**落实后逐项核对；同一成果的归属依据任务书、成果标注与授权材料确定。

4. 完成国家自然科学基金项目情况（对申请人负责的前一个已资助期满的科学基金项目（项目名称及批准号）完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该项目的研究工作总结摘要（限 500 字）和相关成果详细目录）。

根据申请人已确认资料，申请人尚未主持完成国家自然科学基金项目，因此无前一个由本人负责且资助期满的科学基金项目需要在本条填写完成情况、500字总结及成果目录。申请人参与的在研项目不作为本人主持完成项目列示。本稿用于 CCF–百度松果基金科研正文，正式材料按该基金申报要求整理。

（四）其他需要说明的情况：

1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系；已收到自然科学基金委不予受理或不予资助决定的，无需列出）。

本稿用于2026年CCF–百度松果基金科研正文，所借用模板的本条仅针对国家自然科学基金同年不同类型项目申报，不适用于本次基金申请。本次申请与相关在研项目的研究任务区别已在承担项目部分说明；申请人其他国家自然科学基金申报记录以当年度系统信息为准，本稿不代作该项年度声明。

2. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

本次申报对象为CCF–百度松果基金，本条关于国家自然科学基金同年申请或参与申请单位一致性的专项声明不适用。申请人本次科研正文使用已确认的新疆大学身份；正式申报单位及参与者信息按松果基金申报表核验。

3. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在与正在承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

本次CCF–百度松果基金申请不适用本条所列国家自然科学基金在研项目单位一致性专项声明。已承担项目的登记信息和个人职责按真实资料列示；如正式基金附件另要求单位或合作关系说明，由申请人依据相应项目记录填写。

4. 申请人和主要参与者同年以不同专业技术职务（职称）申请或参与申请科学基金项目的情况（应详细说明原因）。

本次申报不适用国家自然科学基金同年以不同专业技术职务申请或参与申请的专项声明。申请人在本稿中使用已确认的副教授职称，参与人员的正式身份与分工纳入本项目团队材料核验。

5. 其他。

本申请拟研究内容、评价流程和预期成果均为计划性安排，文中未将方法示意图或预期变化作为实际实验结果。申请资格、有效 CCF 会员证明及重复资助和利益冲突说明需依据**【待补 F-PACT-03：本次申报资格证明与相关声明】**完成终核；资助额度、成果开放和验收范围按正式课题附件及合同办理。

本稿使用生成式人工智能辅助资料整理、正文起草、语言修订和研究流程示意图制作。论文题录依据公开原始来源核验，申请人事实依据已确认资料使用；研究设计及全文内容仍需由申请人审阅确认。图件表示拟开展的方法与评价关系，不含生成的实验数据或伪造前期结果。