高等教育智能体可信评测与伦理风险监测：研究现状与切入点

摘要

大语言模型驱动的教育智能体将教学对话与检索、工具和记忆连接起来，使可信评价需要同时考察教育目标、执行过程与环境后果。教育研究提示，生成式人工智能的学习价值受支架设计和教师参与方式影响，单次任务表现不足以代表独立学习能力。智能体研究已建立行为轨迹评测、间接提示注入测试和运行保护方法，近期教学工作流评测进一步覆盖教学判断、连续辅导与平台行动。由此可见，研究重点应落在教育情境中不同风险证据的有效性、告警的时间边界及干预所付出的教学代价。可复现沙箱、独立人工标注、任务家族隔离和安全与效用的共同报告，为一年期开放课题提供了可操作的验证路径。

引言

教育智能体的行动能力使教学支持从文本建议延伸到检索资料、保存学习记录和调用课程工具。ReAct 通过交替处理推理与行动展示了语言模型与外部环境交互的研究路径 (Yao et al. 2022)；Toolformer 讨论模型对工具调用时机及参数的学习 (Schick et al. 2023)。二者证明了技术路径的可行性，却没有给出教育行为可接受性的充分判据。对一名学生而言，答案是否正确、支持是否符合本次学习目标、学习记录是否被不当暴露，可以同时产生不同评价。因此，需要在具体任务授权和教学约束中界定可信性。

教育证据中的收益、依赖与教师角色

高等教育 AI 系统综述指出，技术应用与教育理论、风险反思之间存在连接不足 (Zawacki-Richter et al. 2019)。教育 AI 三范式的概念研究进一步讨论了学习者与智能系统之间的角色关系 (Ouyang and Jiao 2021)。这些工作支持将教育主体和使用目的纳入评价，但不能代替对当前工具型智能体的实验。

不同干预试验给出的教育效果并不一致。Bastani 等在高中数学场景中发现，无适当约束的辅助可伴随撤去工具后独立表现下降，设计中的学习保护能够改变这种结果 (Bastani et al. 2025)。Kestin 等在大学物理课程的交叉试验中报告，遵循教学原则设计的 AI 辅导取得了积极的即时学习结果 (Kestin et al. 2025)。这两项证据的学生群体、对照、工具与测量时间不同，不能直接拼成“教育 AI 必然有益”或“必然损害学习”的结论。

Tutor CoPilot 将 AI 用于支持真人辅导者，其随机试验提供了人机协作的教育证据 (R. E. Wang et al. 2024)。LearnLM 将教学行为表达为可指定的教学指令，并采用专家偏好评价 (LearnLM Team et al. 2024)。前者的作用路径是辅助教师，后者的专家偏好也不等于长期学习效果。因此，开放课题可以借鉴教学适切性量表和教师复核，却应把真实学习增益留给具备相应样本、审批和追踪条件的后续研究。

智能体能力、行为风险与轨迹评价

AgentBench 通过多种交互环境评估代理推理和决策 (X. Liu et al. 2023)，WebArena 以可复现网页环境和最终环境状态衡量任务完成 (Zhou et al. 2023)。这些能力测量为构造运行基线提供基础，同时提示“任务失败”需要与“完成了未经授权的动作”分开。

ToolEmu 使用语言模型模拟工具环境并评价风险，降低了构建高风险测试的成本，但模拟出的失败仍需与真实环境语义核对 (Ruan et al. 2023)。R-Judge 直接使用多轮交互记录进行风险判断 (Yuan et al. 2024)。AgentDojo 与 InjecAgent 则把不可信外部内容置于工具流程之中，测试间接提示注入导致的行为偏离 (Debenedetti et al. 2024; Zhan et al. 2024)。AgentHarm 关注明确恶意任务下的多步骤危害行为，与良性教育请求被污染的威胁模型不同 (Andriushchenko et al. 2024)。这些研究已经构成丰富的过程与行为评测基础，不能在立项时把既有工作概括成“都只评最终答案”。

数学推理中的过程监督与首错识别分别由 Let' s Verify Step by Step 和 ProcessBench 给出代表性路径 (Lightman et al. 2023; C. Zheng et al. 2024)。可借鉴其逐步评价思想，但教学工具轨迹中的权限和情境风险不等于数学解题错误。对闭源模型，研究可观测动作、工具参数和外显回复即可，不应声称读取到模型完整内部推理。

评价器可靠性与运行干预

MT-Bench 相关研究讨论了位置、冗长和自我偏好等评判偏差 (L. Zheng et al. 2023)；G-Eval 也提醒模型评价可能偏向模型生成文本 (Y. Liu et al. 2023)。事实性指标如 FActScore 聚焦原子事实支持 (Min et al. 2023), Ragas 区分检索上下文与回答忠实性 (Es et al. 2023)，TruthfulQA 考察错误信念的复述 (Lin, Hilton, and Evans 2021)。这些维度各有目标，不能直接加权得到一个未经验证的“教育可信总分”。

GuardAgent 已采用独立保护代理和规则执行约束目标代理 (Xiang et al. 2024)。2026 年的 NEXUS 预印本进一步使用结构化计划、规则和风险评分实施分级动作控制 (Hossain et al. 2026)。因此，“评价—监测—干预闭环”可作为系统组织方式，其存在本身不是新的科学发现。需要证明某种教育情境证据在固定误报水平和任务能力后仍有作用，并衡量干预后的正常完成率、误阻断与人工负担。

讨论：近期进展对研究边界的约束

TeachArena 当前版本已结合教学专业判断、多轮辅导与学习管理系统行动，以可观测过程和环境状态验证教学工作 (Chen et al. 2026)。它直接缩小了“教育过程评测尚缺”的泛化空间。本课题更适合以教育风险首个可观察点、动作前告警及教学支持代价作为研究焦点。

近期关于安全基准测量效度的预印本指出，不同基准的目标行为、类别比例和能力因素会影响其解释 (Y. Wang et al. 2026)。这一工作尚属预印本，宜作为方法学警示而非最终共识。实验应同时报告误报率、召回、精确率和类别比例，并用基础任务配对控制模型差异；不能仅凭 F1 较高宣称系统更安全。

展望

首先，构造只改变授权范围、教学要求或不可信信息的受控任务对，验证同一最终答案背后的风险差异。其次，在只允许使用当前前缀的条件下比较结果和轨迹评价，记录首个可观察风险、首次告警以及未检出事件。最后，固定正常任务损失约束，在相同任务与随机条件下比较事后检查、规则保护和分级干预，判断风险减少能否超出简单拒绝策略。双智能体污染传播可作为压力测试，以相同调用预算排除额外复杂性造成的假性增益。

结论

教育智能体可信性研究需要连接教学情境、行为证据与执行后果。已有研究提供了工具型代理、过程评价与保护方法，开放课题的增量价值应通过清晰的反证实验建立。以公开资源和可控沙箱先形成测量证据，再在授权条件下开展小规模教育案例，可以兼顾一年期项目的可行性和结果解释的边界。

参考文献

Andriushchenko, Maksym, Alexandra Souly, Mateusz Dziemian, Derek Duenas, Maxwell Lin, Justin Wang, Dan Hendrycks, et al. 2024. "AgentHarm: A Benchmark for Measuring Harmfulness of LLM Agents." *arXiv Preprint arXiv:2410.09024*. https://arxiv.org/abs/2410.09024.

Bastani, Hamsa, Osbert Bastani, Alp Sungu, Haosen Ge, Özge Kabakcı, and Rei Mariman. 2025. "Generative AI without guardrails can harm learning: Evidence from high school mathematics." *Proceedings of the National Academy of Sciences* 122 (26): e2422633122. https://doi.org/10.1073/pnas.2422633122.

Chen, Zixin, Peng Liu, Rui Sheng, Haobo Li, Jianhong Tu, Xiaodong Deng, Kashun Shum, Dayiheng Liu, and Huamin Qu. 2026. "TeachArena: Are Language Agents Ready for Realistic Teaching Work?" *arXiv Preprint arXiv:2605.14322*. https://arxiv.org/abs/2605.14322.

Debenedetti, Edoardo, Jie Zhang, Mislav Balunović, Luca Beurer-Kellner, Marc Fischer, and Florian Tramèr. 2024. "AgentDojo: A Dynamic Environment to Evaluate Prompt Injection Attacks and Defenses for LLM Agents." *arXiv Preprint arXiv:2406.13352*. https://arxiv.org/abs/2406.13352.

Es, Shahul, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. 2023. "Ragas: Automated Evaluation of Retrieval Augmented Generation." *arXiv Preprint arXiv:2309.15217*. https://arxiv.org/abs/2309.15217.

Hossain, Elias, Md Mehedi Hasan Nipu, Tasfia Nuzhat Ornee, Rajib Rana, and Niloofar Yousefi. 2026. "NEXUS: Structured Runtime Safety for Tool-Using LLM Agents." *arXiv Preprint arXiv:2607.19356*. https://arxiv.org/abs/2607.19356.

Kestin, Greg, Kelly Miller, Anna Klales, Timothy Milbourne, and Gregorio Ponti. 2025. "AI tutoring outperforms in-class active learning: an RCT introducing a novel research-based design in an authentic educational setting." *Scientific Reports* 15 (1): 17458. https://doi.org/10.1038/s41598-025-97652-6.

LearnLM Team, Abhinit Modi, Aditya Srikanth Veerubhotla, Aliya Rysbek, Andrea Huber, Brett Wiltshire, Brian Veprek, et al. 2024. "LearnLM: Improving Gemini for Learning." *arXiv Preprint arXiv:2412.16429*. https://arxiv.org/abs/2412.16429.

Lightman, Hunter, Vineet Kosaraju, Yura Burda, Harri Edwards, Bowen Baker, Teddy Lee, Jan Leike, John Schulman, Ilya Sutskever, and Karl Cobbe. 2023. "Let' s Verify Step by Step." *arXiv Preprint arXiv:2305.20050*. https://arxiv.org/abs/2305.20050.

Lin, Stephanie, Jacob Hilton, and Owain Evans. 2021. "TruthfulQA: Measuring How Models Mimic Human Falsehoods." *arXiv Preprint arXiv:2109.07958*. https://arxiv.org/abs/2109.07958.

Liu, Xiao, Hao Yu, Hanchen Zhang, Yifan Xu, Xuanyu Lei, Hanyu Lai, Yu Gu, et al. 2023. "AgentBench: Evaluating LLMs as Agents." *arXiv Preprint arXiv:2308.03688*. https://arxiv.org/abs/2308.03688.

Liu, Yang, Dan Iter, Yichong Xu, Shuohang Wang, Ruochen Xu, and Chenguang Zhu. 2023. "G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment." *arXiv Preprint arXiv:2303.16634*. https://arxiv.org/abs/2303.16634.

Min, Sewon, Kalpesh Krishna, Xinxi Lyu, Mike Lewis, Wen-tau Yih, Pang Wei Koh, Mohit Iyyer, Luke Zettlemoyer, and Hannaneh Hajishirzi. 2023. "FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation." *arXiv Preprint arXiv:2305.14251*. https://arxiv.org/abs/2305.14251.

Ouyang, Fan, and Pengcheng Jiao. 2021. "Artificial intelligence in education: The three paradigms." *Computers and Education: Artificial Intelligence* 2: 100020. https://doi.org/10.1016/j.caeai.2021.100020.

Ruan, Yangjun, Honghua Dong, Andrew Wang, Silviu Pitis, Yongchao Zhou, Jimmy Ba, Yann Dubois, Chris J. Maddison, and Tatsunori Hashimoto. 2023. "Identifying the Risks of LM Agents with an LM-Emulated Sandbox." *arXiv Preprint arXiv:2309.15817*. https://arxiv.org/abs/2309.15817.

Schick, Timo, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. 2023. "Toolformer: Language Models Can Teach Themselves to Use Tools." *arXiv Preprint arXiv:2302.04761*. https://arxiv.org/abs/2302.04761.

Wang, Rose E., Ana T. Ribeiro, Carly D. Robinson, Susanna Loeb, and Dora Demszky. 2024. "Tutor CoPilot: A Human-AI Approach for Scaling Real-Time Expertise." *arXiv Preprint arXiv:2410.03017*. https://arxiv.org/abs/2410.03017.

Wang, Youting, Xiao Han, Dingyan Shang, Yuan Tang, and Bowen Liu. 2026. "Safety, or Just Capability? A Validity Audit of Agent-Safety Benchmarks." *arXiv Preprint arXiv:2607.28685*. https://arxiv.org/abs/2607.28685.

Xiang, Zhen, Linzhi Zheng, Yanjie Li, Junyuan Hong, Qinbin Li, Han Xie, Jiawei Zhang, et al. 2024. "GuardAgent: Safeguard LLM Agents by a Guard Agent via Knowledge-Enabled Reasoning." *arXiv Preprint arXiv:2406.09187*. https://arxiv.org/abs/2406.09187.

Yao, Shunyu, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. 2022. "ReAct: Synergizing Reasoning and Acting in Language Models." *arXiv Preprint arXiv:2210.03629*. https://arxiv.org/abs/2210.03629.

Yuan, Tongxin, Zhiwei He, Lingzhong Dong, Yiming Wang, Ruijie Zhao, Tian Xia, Lizhen Xu, et al. 2024. "R-Judge: Benchmarking Safety Risk Awareness for LLM Agents." *arXiv Preprint arXiv:2401.10019*. https://arxiv.org/abs/2401.10019.

Zawacki-Richter, Olaf, Victoria I. Marín, Melissa Bond, and Franziska Gouverneur. 2019. "Systematic review of research on artificial intelligence applications in higher education –where are the educators?" *International Journal of Educational Technology in Higher Education* 16 (1): 39. https://doi.org/10.1186/s41239-019-0171-0.

Zhan, Qiusi, Zhixiang Liang, Zifan Ying, and Daniel Kang. 2024. "InjecAgent: Benchmarking Indirect Prompt Injections in Tool-Integrated Large Language Model Agents." In *Findings of the Association for Computational Linguistics: ACL 2024*, edited by Lun-Wei Ku, Andre Martins, and Vivek Srikumar, 10471–506. Bangkok, Thailand: Association for Computational Linguistics. https://doi.org/10.18653/v1/2024.findings-acl.624.

Zheng, Chujie, Zhenru Zhang, Beichen Zhang, Runji Lin, Keming Lu, Bowen Yu, Dayiheng Liu, Jingren Zhou, and Junyang Lin. 2024. "ProcessBench: Identifying Process Errors in Mathematical Reasoning." *arXiv Preprint arXiv:2412.06559*. https://arxiv.org/abs/2412.06559.

Zheng, Lianmin, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, et al. 2023. "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena." *arXiv Preprint arXiv:2306.05685*. https://arxiv.org/abs/2306.05685.

Zhou, Shuyan, Frank F. Xu, Hao Zhu, Xuhui Zhou, Robert Lo, Abishek Sridhar, Xianyi Cheng, et al. 2023. "WebArena: A Realistic Web Environment for Building Autonomous Agents." *arXiv Preprint arXiv:2307.13854*. https://arxiv.org/abs/2307.13854.