
课程答疑
文献学习辅助
任务目标
明确应用场景
界定任务范围
帮助边界
可提供的帮助
不可越界的内容
数据授权
可使用的数据
数据使用范围
R1 风险表征
情境—行为配对
构建风险相关的情境与行为对
独立标注与仲裁
多标注者标注与分歧仲裁
风险类别与证据案例
梳理风险类别并收集证据案例
证据案例
标注规则与开发案例
规则与案例
R2 轨迹评测
任务执行轨迹（按时间顺序）
t_1 t_2 t_3 … t_n
规则核验
基于规则的风险检查
语义判别
基于语义的风险识别
前缀风险与证据定位
定位高风险前缀及其依据
校准阈值与不确定性
风险与依据
R3 监测干预
候选动作评估
对下一步候选动作进行风险评估
风险判定
执行
风险可接受
正常执行
重规划
引导调整
重新规划
阻断
高风险动作
直接阻断
人工复核
不确定时
人工复核
风险后果与任务代价
独立留出验证
使用独立留出数据集
进行全面评估
风险识别
识别潜在风险
动作前告警
在执行前进行预警
正常完成
任务可顺利完成
人工负担
评估人工复核的工作量
按家族划分：开发 12 | 校准 6 | 测试 6
测试前冻结，留出集不参与调参