

报告正文（2026版）

参照以下提纲撰写，要求内容翔实、清晰，层次分明，标题突出。
请勿删除或改动下述提纲标题及括号中的文字。

（一）立项依据与研究内容（建议8000字以下）：

1. **项目的立项依据**（研究意义、国内外研究现状及发展动态分析，需结合科学研究发展趋势来论述科学意义；或结合国民经济和社会发展中迫切需要解决的关键科技问题来论述其应用前景。附主要参考文献目录）；

1.1 研究背景与意义

民族地区自然场景图像往往同时包含物体外观和场景文字。路牌、招牌、海报上的维吾尔语既标识地点与商户，也构成图像语义的一部分。现有视觉—语言模型主要在英文或中文图文对上训练，倾向于回答“图中是什么”，对黏着语、从右向左书写、连写变体丰富的维吾尔语场景文字缺乏稳定编码[1, 2]。若把这类图像只当作一般照片做跨模态检索，文字通道被当成纹理；若只做场景文字识别，又丢掉物体与场景上下文。

本项目面向教育部重点实验室“民族语言多模态提取融合”方向，研究如何把维吾尔语场景文字作为独立视觉语言通道，与图像外观、维吾尔语描述和汉语描述一并编码，并在公开可核验数据上检验跨语言图像—文本检索与小规模图像理解。对象收敛到维—汉图文，不扩展为通用民汉翻译系统、语音交互或舆情治理。

该问题具有方法与应用双重约束。方法上，外观特征、文字区域特征与双语描述的粒度、噪声和脚本方向不同，直接拼接或单一对比损失容易互相干扰。应用上，跨语言检索需要支持汉查询维图、维查询汉图，而不能假设用户与图像文字使用同一语言。项目因此把“第三通道是否有用”写成可消融、可证伪的问题，而不是先承诺平台或语料规模。

实验室开放课题经费有限、周期两年，不适合以大规模预训练或在线系统为交付。可检验的交付是：在公开数据上复现基线、加入文字通道、报告检索与消融。若文字通道只提高OCR分数、不提高汉↔维检索，则说明识别与理解仍是两件事，项目应收缩主张而不是改写指标。

1.2 国内外研究现状及发展动态分析

视觉—语言对比学习把图像与句子拉到共享空间，CLIP、ALIGN 与 SigLIP 提供了可迁移的图文编码器 [1, 3, 4]。细粒度匹配与统一预训练进一步改善检索和理解，SCAN、ALBEF、BLIP 与 Flamingo 分别强调区域—单词对齐、先对齐后融合、理解—生成一体和少样本条件生成 [5, 6, 7, 8]。早期视觉—语义嵌入则说明跨模态检索的评价应同时报告图像到文本与文本到图像 [9, 10]。这些模型的训练数据以自然描述为主，图像中的文字通常不被单独建模。对维吾尔语场景图，这一隐含假设会带来两类错误：招牌文字被当成纹理噪声，或模型用英文/中文先验去“猜”图意而忽略真实书写。因此，把 CLIP 式编码器直接零样本用于维—汉检索，只能作为对照，不能当作已经解决场景文字问题。

场景文字识别把“图中的字”当作序列转写问题。CRNN 给出端到端卷积—循环基线，ABINet 用双向语言模型迭代校正，TrOCR 与 CLIP4STR 把预训练视觉—语言模型引入识别 [11, 12, 13, 14]。评测协议本身会影响结论，因此不能只报单一测试集准确率 [15]。当答案写在图里时，TextVQA、ST-VQA 与 OCR-VQA 表明物体外观不够，必须读取文字 [16, 17, 18, 19]。OCR-free 文档理解试图跳过显式转写 [20]，但其数据仍集中在英文或中文印刷体，不能直接外推到维吾尔语连写招牌。对申请书更关键的是任务接口：STR 输出字符串，图像理解需要的是可与外观特征相加或门控的连续向量。若只把识别结果再翻译成汉语再检索，错误会在 OCR、翻译和检索三级累积，且无法做“去掉文字通道”的干净消融。本项目因此保留显式文字编码器，但把它的输出当作融合特征，而不是停在转写竞赛。

多语图文模型用替换文本编码器、蒸馏或翻译图文对扩展 CLIP，AltCLIP、mCLIP、Chinese CLIP、M3P 与 UC2 在 Multi30k、COCO-CN 等基准上提升跨语言检索 [2, 21, 22, 23, 24, 25]。这些评测很少把维吾尔语当作主测试语言。视觉枢纽研究则表明，当句对稀缺时，共享图像可以约束跨语言潜空间 [26]。针对英—维、汉—维远程语言对，人工翻译的 Multi30k-Distant 显示视觉枢纽对多模态翻译有增益 [27, 28]。该基准提供了同图维/汉/英描述，但任务是翻译而不是场景文字增强的图像理解。翻译指标对词序和形态变化敏感，维吾尔语作为黏着语更容易被 BLEU 低估或高估。本项目改用检索 $\text{Recall}@K$ 与 MRR：它们直接回答“汉查询能否找到对应维语描述的图像”，也便于与无文字通道模型比较。Multi30k 图像本身很少是新疆街景招牌，因此 RUST 仍用于检验文字通道，二者不互相替代。

维吾尔语场景文字已出现可公开使用的数据。SUST 含 60 万合成词级场景文

字图，RUST 含 4000 张新疆实景图，后续工作讨论低资源协同编码与视觉预测增强[29, 30, 31]。验收指标仍是识别准确率，文字区域特征尚未进入跨语言检索。MC² 提供维吾尔语网页单语文本，CUTE 提供中维藏英平行与非平行语料[32, 33]。CUTE 含机器翻译生成部分，只适合文本预训练，不适合作为图像理解金标准。对开放课题而言，使用这些语料的边界必须写清楚：它们可以改善维语子词切分和文本编码器，但不能用来宣称已经拥有大规模维语图文理解基准。商业平行库不进入本项目数据清单。

申请人前期在知识增强视觉问答、空间共注意力、遥感视觉问答和跨模态检索上形成了多模态表征与对齐基础[34, 35, 36, 37]。本项目把这些能力迁移到维吾尔语场景文字与维—汉图文，而不是重复新能源预测或教学资源构建。

1.3 现有研究不足

第一，图文检索模型缺少维吾尔语场景文字通道，无法区分“图中是什么”与“图中写了什么”。把多语 CLIP 零样本分数当作维语场景理解能力，会高估资源语言先验、低估文字通道。

第二，维语 STR 工作停在识别准确率，没有检验文字特征是否改善跨语言检索或图像理解。识别正确也不等于融合有用：错误的文字向量可能损害物体检索。

第三，视觉枢纽与 Multi30k-Distant 面向翻译，缺少以检索 Recall@K、MRR 和去掉文字通道消融为主的图像理解验收。公开维语 VQA 大规模基准几乎不存在，不能把英文 TextVQA 结论直接写成维语结果。拟建 200–400 题只是辅助协议，主结论仍必须落在公开检索划分上。

1.4 本项目的研究切入点

项目以“场景文字编码—异构融合—跨语言检索与理解评价”为主线。在 SUST/RUST 上训练并测试维语场景文字编码器，输出供融合使用的区域特征；在外观、文字与维/汉描述之间做分通道编码和门控融合；在 Multi30k-Distant 上报告汉↔维互检索，并拟建 200–400 题小规模理解协议。对照包括通用多语 CLIP 零样本、无文字通道对比学习、OCR 后翻译再检索。若去掉文字通道后主指标不下降，或翻译流水线全面不低于视觉枢纽，项目如实报告负结果并收缩主张。

参考文献

- [1] Radford A, Kim J W, Hallacy C, Ramesh A, Goh G, Agarwal S, Sastry G, Askell A, Mishkin P, Clark J, Krueger G, Sutskever I. Learning Transferable Visual Models From Natural Language Supervision[C/OL] // Proceedings of the 38th International Conference on Machine Learning. [S.l.]: PMLR, 2021 : 8748–8763. <https://proceedings.mlr.press/v139/radford21a.html>.

- [2] Chen Z, Liu G, Zhang B-W, Ye F, Yang Q, Wu L. AltCLIP: Altering the Language Encoder in CLIP for Extended Language Capabilities[C/OL] // Findings of the Association for Computational Linguistics: ACL 2023. 2023 : 8666 – 8682. <http://dx.doi.org/10.18653/v1/2023.findings-acl.552>.
- [3] Jia C, Yang Y, Xia Y, Chen Y-T, Parekh Z, Pham H, Le Q, Sung Y-H, Li Z, Duerig T. Scaling Up Visual and Vision-Language Representation Learning With Noisy Text Supervision[C/OL] // Proceedings of the 38th International Conference on Machine Learning. [S.l.] : PMLR, 2021 : 4904 – 4916. <https://proceedings.mlr.press/v139/jia21b.html>.
- [4] Zhai X, Mustafa B, Kolesnikov A, Beyer L. Sigmoid Loss for Language Image Pre-Training[C/OL] // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2023 : 11975 – 11986. <http://dx.doi.org/10.1109/ICCV51070.2023.01100>.
- [5] Lee K-H, Chen X, Hua G, Hu H, He X. Stacked Cross Attention for Image-Text Matching[C/OL] // Proceedings of the European Conference on Computer Vision (ECCV). 2018 : 201 – 216. http://dx.doi.org/10.1007/978-3-030-01225-0_13.
- [6] Li J, Selvaraju R, Gotmare A, Joty S, Xiong C, Hoi S C H. Align before Fuse: Vision and Language Representation Learning with Momentum Distillation[C] // Advances in Neural Information Processing Systems : Vol 34. 2021 : 9694 – 9705.
- [7] Li J, Li D, Xiong C, Hoi S. BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation[C] // Proceedings of the 39th International Conference on Machine Learning. [S.l.] : PMLR, 2022 : 12888 – 12900.
- [8] Alayrac J-B, Donahue J, Luc P, Miech A, Barr I, Hasson Y, Lenc K, Mensch A, Millican K, Reynolds M, Ring R, Rutherford E, Cabi S, Han T, Gong Z, Samangooei S, Monteiro M, Menick J, Borgeaud S, Brock A, Nematzadeh A, Sharifzadeh S, Binkowski M, Barreira R, Vinyals O, Zisserman A, Simonyan K. Flamingo: a Visual Language Model for Few-Shot Learning[C] // Advances in Neural Information Processing Systems : Vol 35. 2022 : 23716 – 23736.
- [9] Frome A, Corrado G S, Shlens J, Bengio S, Dean J, Ranzato M, Mikolov T. DeViSE: A Deep Visual-Semantic Embedding Model[C] // Advances in Neural Information Processing Systems : Vol 26. 2013.
- [10] Faghri F, Fleet D J, Kiros J R, Fidler S. VSE++: Improving Visual-Semantic Embeddings with Hard Negatives[J/OL], 2018. <https://arxiv.org/abs/1707.05612>.
- [11] Shi B, Bai X, Yao C. An End-to-End Trainable Neural Network for Image-Based Sequence Recognition and Its Application to Scene Text Recognition[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 39(11) : 2298 – 2304, 2017. <http://dx.doi.org/10.1109/TPAMI.2016.2646371>.
- [12] Fang S, Xie H, Wang Y, Mao Z, Zhang Y. Read Like Humans: Autonomous, Bidirectional and Iterative Language Modeling for Scene Text Recognition[C/OL] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021 : 7098 – 7107. <http://dx.doi.org/10.1109/CVPR46437.2021.00702>.
- [13] Li M, Lv T, Chen J, Cui L, Lu Y, Florencio D, Zhang C, Li Z, Wei F. TrOCR: Transformer-Based Optical Character Recognition with Pre-trained Models[C/OL] // Proceedings of the AAAI Conference on Artificial Intelligence : Vol 37. 2023 : 13094 – 13102. <http://dx.doi.org/10.1609/aaai.v37i11.26538>.
- [14] Zhao S, Quan R, Zhu L, Yang Y. CLIP4STR: A Simple Baseline for Scene Text Recognition With Pre-Trained Vision-Language Model[J/OL]. IEEE Transactions on Image Processing, 33 : 6893 – 6904, 2024. <http://dx.doi.org/10.1109/TIP.2024.3512354>.
- [15] Baek J, Kim G, Lee J, Park S, Han D, Yun S, Oh S J, Lee H. What Is Wrong With Scene Text Recognition Model Comparisons? Dataset and Model Analysis[C/OL] // Proceedings of

- the IEEE/CVF International Conference on Computer Vision (ICCV). 2019 : 4715 – 4723. <http://dx.doi.org/10.1109/ICCV.2019.00481>.
- [16] Singh A, Natarajan V, Shah M, Jiang Y, Chen X, Batra D, Parikh D, Rohrbach M. Towards VQA Models That Can Read[C/OL] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019 : 8317 – 8326. <http://dx.doi.org/10.1109/CVPR.2019.00851>.
- [17] Biten A F, Tito R, Mafla A, Gomez L, Rusinol M, Valveny E, Jawahar C V, Karatzas D. Scene Text Visual Question Answering[C/OL] // Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2019 : 4291 – 4301. <http://dx.doi.org/10.1109/ICCV.2019.00439>.
- [18] Mishra A, Shekhar S, Singh A K, Chakraborty A. OCR-VQA: Visual Question Answering by Reading Text in Images[C/OL] // 2019 International Conference on Document Analysis and Recognition (ICDAR). 2019 : 947 – 952. <http://dx.doi.org/10.1109/ICDAR.2019.00156>.
- [19] Hu R, Singh A, Darrell T, Rohrbach M. Iterative Answer Prediction With Pointer-Augmented Multimodal Transformers for TextVQA[C/OL] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020 : 9992 – 10002. <http://dx.doi.org/10.1109/CVPR42600.2020.01001>.
- [20] Kim G, Hong T, Yim M, Nam J, Park J, Yim J, Hwang W, Yun S, Han D, Park S. OCR-Free Document Understanding Transformer[C/OL] // Proceedings of the European Conference on Computer Vision (ECCV). 2022 : 498 – 517. http://dx.doi.org/10.1007/978-3-031-19815-1_29.
- [21] Chen G, Hou L, Chen Y, Dai W, Shang L, Jiang X, Liu Q, Wen J, Li R. mCLIP: Multilingual CLIP via Cross-lingual Transfer[C/OL] // Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023 : 13028 – 13043. <http://dx.doi.org/10.18653/v1/2023.acl-long.728>.
- [22] Yang A, Pan J, Lin J, Men R, Zhang Y, Zhou J, Zhou C. Chinese CLIP: Contrastive Vision-Language Pretraining in Chinese[C/OL] //. 2022. <https://arxiv.org/abs/2211.01335>.
- [23] Ni M, Huang H, Su L, Cui E, Bharti T, Wang L, Zhang D, Duan N. M3P: Learning Universal Representations via Multitask Multilingual Multimodal Pre-training[C/OL] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021 : 3977 – 3986. <http://dx.doi.org/10.1109/CVPR46437.2021.00397>.
- [24] Zhou M, Zhou L, Yu S, Bharti T, Meng Z, Dai H, Yuan S, Zhang C, Liu J. UC2: Universal Cross-lingual Cross-modal Vision-and-Language Pre-training[C/OL] // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021 : 4155 – 4165. <http://dx.doi.org/10.1109/CVPR46437.2021.00414>.
- [25] Elliott D, Frank S, Sima'an K, Specia L. Multi30K: Multilingual English-German Image Descriptions[C/OL] // Proceedings of the 5th Workshop on Vision and Language. 2016 : 70 – 74. <http://dx.doi.org/10.18653/v1/W16-3210>.
- [26] Huang P-Y, Hu J, Chang X, Hauptmann A G. Unsupervised Multimodal Neural Machine Translation with Pseudo Visual Pivoting[C/OL] // Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. 2020 : 8226 – 8237. <http://dx.doi.org/10.18653/v1/2020.acl-main.731>.
- [27] Tayir T, Li L, Tao X, Maimaiti M, Li M, Liu J. Visual Pivoting Unsupervised Multimodal Machine Translation in Low-Resource Distant Language Pairs[C/OL] // Findings of the Association for Computational Linguistics: EMNLP 2024. 2024 : 5596 – 5607. <http://dx.doi.org/10.18653/v1/2024.findings-emnlp.320>.
- [28] Tayir T, Li L, Li B, Liu J. Unsupervised Multimodal Machine Translation for Low-resource Distant Language Pairs[J/OL]. ACM Transactions on Asian and Low-Resource Language In-

- formation Processing, 23(4): 1–22, 2024. <http://dx.doi.org/10.1145/3652161>.
- [29] Kong F, Ma Z, Chen G, Cao L. SUST and RUST: Two Datasets for Uyghur Scene Text Recognition[J/OL]. IEEE Access, 11: 127636–127645, 2023. <http://dx.doi.org/10.1109/ACCESS.2023.3331213>.
- [30] Yang W, Simayi W, Xu M, Yibulayin T. Collaborative Encoding Method for Scene Text Recognition in Low Linguistic Resources: The Uyghur Language Case Study[J/OL]. Applied Sciences, 14(5): 1707, 2024. <http://dx.doi.org/10.3390/app14051707>.
- [31] Ma Z, Kong F, Chen G, Cao L. Scene Uyghur Recognition Based on Visual Prediction Enhancement[J/OL]. Sensors, 23(20): 8610, 2023. <http://dx.doi.org/10.3390/s23208610>.
- [32] Zhang C, Tao M, Huang Q, Lin J, Chen Z, Feng Y. MC²: Towards Transparent and Culturally-Aware NLP for Minority Languages in China[C/OL] // Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2024: 8832–8850. <http://dx.doi.org/10.18653/v1/2024.acl-long.479>.
- [33] Zhuang W, Sun Y. CUTE: A Multilingual Dataset for Enhancing Cross-Lingual Knowledge Transfer in Low-Resource Languages[C/OL] // Proceedings of the 31st International Conference on Computational Linguistics. 2025: 10037–10046. <https://aclanthology.org/2025.coling-main.670/>.
- [34] Yan F, Li Z, Silamu W, Li Y. Knowledge-Aware Image Understanding with Multi-Level Visual Representation Enhancement for Visual Question Answering[J/OL]. Machine Learning, 113(6): 3789–3805, 2024. <http://dx.doi.org/10.1007/s10994-023-06426-6>.
- [35] Yan F, Silamu W, Li Y, Chai Y. SPCA-Net: A Based on Spatial Position Relationship Co-Attention Network for Visual Question Answering[J/OL]. The Visual Computer, 38: 3097–3108, 2022. <http://dx.doi.org/10.1007/s00371-022-02524-z>.
- [36] Xu P, Yan F, Zhou Y, Liu Y, Wu C. RSHR+: Progressive Question-Conditioned Visual Calibration and Structured State-Space Reasoning for Remote Sensing Visual Question Answering[J/OL]. Expert Systems with Applications, 297: 132953, 2026. <http://dx.doi.org/10.1016/j.eswa.2026.132953>.
- [37] Xu P, Yan F. RSSR: Efficient Knowledge Transfer and Deep Spatial Modeling for Remote Sensing Visual Question Answering[J/OL]. Computer Vision and Image Understanding, 264: 104753, 2026. <http://dx.doi.org/10.1016/j.cviu.2026.104753>.
- [38] van den Oord A, Li Y, Vinyals O. Representation Learning with Contrastive Predictive Coding[J/OL], 2018. <https://arxiv.org/abs/1807.03748>.
- [39] Sun Q, Yan F, Sun W, Zhou Y. DWT-Former: Fusing Wavelet-Based Multi-Scale Features and Transformer-Based Temporal Representations for Photovoltaic Power Forecasting[J/OL]. Energy, 320: 139283, 2025. <http://dx.doi.org/10.1016/j.energy.2025.139283>.
- [40] Liu Y, Yan F, Xu P, Liu C, Wang L. WaveKAN: Adaptive Wavelet Decomposition and Kolmogorov-Arnold Network for Long-Term Time Series Forecasting[J/OL]. Neurocomputing, 637: 133361, 2026. <http://dx.doi.org/10.1016/j.neucom.2026.133361>.
- [41] Wang Z, Yan F, others. S-YOLO: An Enhanced Small Object Detection Method Based on Adaptive Gating Strategy and Dynamic Multi-Scale Focus Module[J/OL]. Neural Networks, 185: 107782, 2025. <http://dx.doi.org/10.1016/j.neunet.2025.107782>.

2. 项目的研究内容、研究目标，以及拟解决的关键科学问题（此部分为重点阐述内容）；

（1）研究内容

本项目设置三项一一对应的研究内容，均在公开数据上完成，不依赖未授权采集。

内容一：维吾尔语场景文字视觉编码。在 SUST 上训练或适配词级场景文字编码器，在 RUST 上测试。目标不是单独刷新识别排行，而是得到可供融合的文字区域特征 s 。对无文字图像，令 $s = \mathbf{0}$ 并在融合中关闭该通道。中间指标为 RUST 识别准确率，用于确认编码器可用，不作为课题主验收。

内容二：图像外观、场景文字与双语描述的异构融合。外观编码器 f_v 、文字编码器 f_s 与维/汉文本编码器分别提取 v 、 s 、 h^{ue} 、 h^{zh} 。融合头 $g(v, s)$ 采用门控残差，避免文字噪声直接覆盖物体语义。对齐损失对外观—文本与文字—文本分开计算。比较简单拼接、单 InfoNCE 与门控双对齐，检验异构通道是否互相干扰。

内容三：跨语言检索与小规模图像理解评价。在 Multi30k-Distant 测试集上报告图像到维/汉文本、维/汉文本到图像，以及汉查询—维描述、维查询—汉描述的 Recall@K 与 MRR。在测试图像上拟建 200–400 题理解协议，区分“图中是什么”与“图中写了什么”。翻译流水线只作对照，不把 BLEU 当主指标。CUTE 与 MC² 仅用于文本编码器继续预训练。三项内容共享同一组基线与消融表，避免各写各的指标。经费与算力约束下，不把“再训练一个通用多语 VLM”列作研究内容。

（2）研究目标

总体目标：给出可复现的维语场景文字增强多模态融合方法，并在公开基准上证明或证伪其对维—汉跨语言图像理解的贡献。

具体目标：（1）在 RUST 上得到可用的场景文字编码器，并使去掉该通道后的跨语言检索 Recall@5 下降可观测；（2）在 Multi30k-Distant 测试集上，完整模型的汉↔维互检索 Recall@5 高于无文字通道与 OCR—翻译流水线；（3）完成 200–400 题理解协议并报告准确率，不将其表述为已有大规模维语 VQA 库；（4）形成可支撑 1 篇中科院三区及以上 SCI 的方法与实验，署名遵守实验室第一单位要求。

（3）拟解决的关键科学问题

问题一：场景文字能否成为维语图像理解的稳定第三通道？若消融后检索与理解均不下降，则拒绝普遍有用的主张。

问题二：外观、连写维文与维/汉描述如何融合而不互相干扰？若门控融合在物体检索和文字相关检索上同时差于单通道，则拒绝必须复杂融合的主张。

问题三：共享图像作为枢纽，能否在缺少大规模维语 VQA 标注时改善汉↔维互检索？若翻译流水线全面不低于视觉枢纽，则把枢纽降为辅助模块。

3. 拟采取的研究方案及可行性分析（包括研究方法、技术路线、实验手段、关键技术等说明）；

3.1 研究方法

记输入图像为 I ，场景文字区域为 $\{t_k\}_{k=1}^K$ ，维吾尔语与汉语描述为 y^{ug} 、 y^{zh} 。外观、文字与文本编码器分别给出

$$v = f_v(I), \quad s = f_s(\{t_k\}), \quad h^\ell = f_\ell(y^\ell), \quad \ell \in \{\text{ug}, \text{zh}\}. \quad (1)$$

无文字区域时 $s = \mathbf{0}$ 。融合采用门控残差，使文字通道可关闭：

$$z = g(v, s) = v + \alpha \sigma(W[v; s]) \odot s, \quad (2)$$

其中 σ 为 Sigmoid， α 为可学习或验证集选择的尺度。检索打分为余弦相似度

$$\text{sim}(z, h) = \frac{z^\top h}{\|z\| \|h\|}. \quad (3)$$

对齐使用分通道 InfoNCE[38]。以外观—文本为例，批内

$$\mathcal{L}_{v \rightarrow t} = -\log \frac{\exp(\text{sim}(v, h^+)/\tau)}{\sum_j \exp(\text{sim}(v, h_j)/\tau)}, \quad (4)$$

文字—文本损失 $\mathcal{L}_{s \rightarrow t}$ 同构。总损失为

$$\mathcal{L} = \mathcal{L}_{v \rightarrow t} + \lambda_s \mathcal{L}_{s \rightarrow t} + \lambda_{\text{hub}} \mathcal{L}_{\text{hub}}, \quad (5)$$

其中 $\mathcal{L}_{\text{hub}}$ 将同一图像上的 h^{ug} 与 h^{zh} 通过 z 对齐，对应视觉枢纽。 λ_s 、 λ_{hub} 在验证集选择。主指标定义为

$$\text{R@}K = \frac{1}{N} \sum_{i=1}^N \mathbf{1}[r_i \leq K], \quad \text{MRR} = \frac{1}{N} \sum_{i=1}^N \frac{1}{r_i}, \quad (6)$$

r_i 为第 i 个查询的正确匹配秩。理解任务报告准确率。上述公式分别对应表征、融合、优化、枢纽约束与评价，不作装饰。

3.2 技术路线

研究按“编码—融合—评价”推进。先在 SUST 上得到 f_s ，在 RUST 上确认文字特征可用；再冻结或低学习率适配 f_v 与文本编码器，训练 g 与对齐损失；最后在 Multi30k-Distant 上做单语与跨语言检索，并在测试图像上执行理解协议。对照顺序固定为：多语 CLIP 零样本、无文字通道、OCR—翻译流水线、完整模型；消融顺序固定为：去 s 、去门控、去 $\mathcal{L}_{s \rightarrow t}$ 、去 $\mathcal{L}_{\text{hub}}$ 。技术路线的可检验节点是三张表：RUST 上文字通道是否可用，Multi30k-Distant 上跨语言检索是否提高，以及去掉 s 后主指标是否回落。任一节点失败，只收缩对应假设，不改写另外两张表的口径。

3.3 实验手段

数据划分遵循公开协议：Multi30k-Distant 为 Train 29,000 / Val 1,014 / Test 1,000[27, 25]；SUST 用于 f_s 训练，RUST 按作者划分测试[29]。CUTE 与 MC² 只更新文本编码器，不进入图像测试[33, 32]。理解题在测试集上编写，问题文本不使用训练集描述原句。实验在课题组现有 GPU 上完成，不从随机初始化训练大型视觉语言模型。

3.4 关键技术

第一，面向连写、从右向左脚本的维吾尔语场景文字区域编码，使 s 对融合稳定。第二，分通道对齐与门控融合，使物体语义与文字语义可分开检验。第三，以图像为枢纽的汉—维互检索协议，以及与翻译流水线的公平对照。

3.5 可行性分析

理论可行：对比学习、STR 与视觉枢纽均有可复现实现[1, 12, 26]。数据可行：主评测只用公开数据集。条件可行：申请人已有视觉问答与跨模态检索训练经验[34, 36]。主要风险是图像许可、RUST 与 Multi30k 的域差，以及 5 万元经费下的算力上限。应对分别是核验许可后使用合法子集、不把 OCR 准确率解释为检索增益、只训练融合头与轻量适配。若 H1-H3 被证伪，收缩为“文字通道仅对文字主导图像有效”或“枢纽不优于翻译流水线”，不强行维持原主张。

4. 本项目的特色与创新之处；

本项目的特色在于把维吾尔语场景文字从识别正确率问题改写为跨语言图像理解问题，并在公开数据上用消融与对照把主张限制为可证伪命题。

(1) 创新点一：场景文字作为跨语言图像理解的第三通道

已有维语 STR 工作提供 SUST/RUST 并报告识别准确率 [29, 30], TextVQA 则主要在英文图像上证明“读字”的必要 [16]。本项目检验的是：把维语文字区域特征送入融合表征后，汉 $\leftrightarrow$ 维检索与理解是否提高。验收看去掉文字通道后 Recall@5 或准确率是否下降，而不是只看 OCR 分数。

(2) 创新点二：低资源维—汉条件下的分通道融合与视觉枢纽评价

多语 CLIP 很少以维吾尔语为主测语言 [2, 21]; Multi30k-Distant 上的视觉枢纽面向翻译 [27]。本项目在同一图像上联合外观、文字与维/汉描述，用分通道 InfoNCE 和枢纽损失服务检索，并以翻译流水线为对照。若枢纽不优于翻译，则如实降级该模块。

5. 年度研究计划及预期研究结果（包括拟组织的重要学术交流活动、国际合作与交流计划等）。

5.1 年度研究计划

研究期限为两年，与实验室开放课题管理要求一致。

第一年(2027 年 1 月—12 月)。完成公开数据合规审查与划分核对；在 SUST 上训练场景文字编码器并在 RUST 上测试；实现无文字通道的图文对比基线与 OCR—翻译流水线；搭建 Recall@K、MRR 与消融记录脚本；提交年度进展报告。阶段目标是确认 f_s 可用，并得到 B0-B2 的可复现分数。

第二年(2028 年 1 月—12 月)。完成门控融合与视觉枢纽训练；在 Multi30k-Distant 上报告单语与跨语言检索；完成 200–400 题理解协议与专家核对；撰写并投稿 SCI 论文；按实验室要求提交结题报告。阶段目标是完成 H1-H3 的检验，并形成署名符合实验室第一单位要求的成果。

5.2 预期研究结果

方法上，形成维语场景文字增强的多模态融合与跨语言检索评价协议。实验上，报告完整模型、三类基线与四项消融。成果上，力争发表中科院三区及以上 SCI 论文 1 篇；论文由申请人所在单位与教育部重点实验室共同署名，并以实验室为第一单位。不预先承诺专利、平台上线或学生数据实验。

5.3 学术交流与合作计划

拟在课题执行期内参加 1 次国内多模态或民族语言信息处理学术会议，汇报检索与消融结果。与实验室的合作以合同、年度报告和成果署名为准，不安排未

落实的国际合作经费。差旅与会务按实验室实报实销科目列支。预算总额 5 万元，按申请人确定列为劳务费 3.5 万元、业务费 1.5 万元。业务费对应测试费 0.8 万元、会议费/差旅费 0.4 万元、出版物/文献/信息费 0.3 万元。劳务费能否按实验室科目报销，以立项合同和实报实销审定为准。立项后首期使用 50% 经费，中期报告达到优或良后再使用其余 50%。

(二) 研究基础与工作条件

1. 研究基础（与本项目相关的研究工作积累和已取得的研究工作成绩等）；

1.1 与本项目相关的研究工作积累

申请人长期从事多模态信息处理、视觉问答与跨模态检索，并与新疆大学民族语言信息处理方向合作开展图像理解研究。与本课题直接相关的积累有三类。第一，知识增强与空间关系建模的视觉问答，能够把问题条件作用于多层视觉表征[34, 35]。第二，遥感视觉问答中的视觉校准与状态空间推理，说明申请人具备在专业图像上训练多模态理解模型的经验[36, 37]。第三，跨模态检索中的特征融合，为图文对齐与检索评价提供方法基础。新能源功率预测与小目标检测等工作[39, 40, 41]证明申请人具备深度学习训练与实验组织能力，但不构成本课题的研究对象。

1.2 已取得的研究工作成绩

申请人已以第一或通讯作者发表多篇 SCI 收录论文，满足实验室对申请人的资格要求。代表性工作包括 Machine Learning、The Visual Computer、Expert Systems with Applications 与 Computer Vision and Image Understanding 等期刊上的视觉问答与图像理解论文[34, 35, 36, 37]。上述成绩用于证明有能力完成本课题的编码器适配、融合训练与检索评价，不把其中的新能源或遥感指标表述为本课题已经完成的结果。

1.3 项目组能力与任务分工

申请人颜丰负责总体设计、方法实现与论文撰写。课题组现有约 10 名研究生，可承担数据整理、基线复现、消融实验与评测记录。任务按研究内容划分：场景文字编码器与 RUST 测试、融合与对齐训练、跨语言检索与理解题核对。不把未书面确认的实验室固定人员写成课题组成员。

1.4 前期基础与本项目的衔接

内容一衔接申请人在视觉表征与检测方面的训练经验，用于场景文字区域编码。内容二衔接视觉问答中的跨模态交互与检索中的特征融合。内容三衔接已有的检索/问答评价习惯，改为 Recall@K、MRR 与小规模理解准确率。天池英才项目研究产业集群场景下的多模态融合，与本课题的民族语言场景图文对象不同，不构成重复申报。

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、全国重点实验室和部门重点实验室等研究基地的计划与落实情况）；

2.1 已具备的实验条件

申请人依托新疆大学开展研究，具备 GPU 训练环境、深度学习开发工具链以及多模态实验代码基础。SUST/RUST、Multi30k-Distant、CUTE 与 MC² 均为公开数据，写作阶段已核验来源，实验阶段按许可下载。课题组已有视觉问答与检索训练流程，可复用对比学习、评测脚本和消融记录方式。

2.2 尚缺少的实验条件

缺少现成的维语场景文字与图文融合代码；缺少 Multi30k-Distant 图像与文本的本地对齐副本；缺少 200–400 题理解协议的题面与核对记录。实验室侧的报销、年度报告与成果署名流程需在立项合同中落实。

2.3 拟解决的途径

融合代码在开源 CLIP/STR 实现上适配，不新造基础模型。图像按 Multi30k/Flickr 许可获取，不能合法使用的样本从评测中剔除并在报告中说明。理解题由研究生按测试集编写、申请人抽检。经费按申请人确定为劳务费 3.5 万元、业务费 1.5 万元，实验室实报实销；业务费对应测试、会议差旅与出版物。若劳务费不能列支，在合同阶段调整到指南允许科目。

2.4 利用研究基地的计划与落实情况

拟在立项后与“民族语言智能分析与安全治理”教育部重点实验室签订开放课题合同，按实验室要求提交年度报告与结题材料，论文第一单位使用实验室规定署名。不承诺使用实验室未对开放课题开放的内部数据或生产系统。

3. 正在承担的与本项目相关的科研项目情况（申请人和主要参与者正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的资助机构、项目类别、批准号、项目名称、获资助金额、起止年月、与本项目的关系及负责的内容等）；

申请人正在主持的、与本课题方法相关的项目如下。所列经费与编号以已有书面材料为准；未写入编号的项目不编造批准号。

（1）自治区天池英才引进计划（青年博士人才）项目“多模态融合技术研究及其在新疆产业集群中的应用”，新疆人社厅，经费 50 万元，2025.02–2028.02。申请人主持。该项目面向产业集群场景中的多模态融合，与本课题的维吾尔语场景文字及维—汉图像理解对象不同，不构成相同内容重复申报。

（2）自治区高校基本科研业务费科研项目（培育类）“融合多源数据大模型驱动的光伏发电功率预测方法研究”，项目编号 XJEDU2026P005，新疆教育厅，2026.01–2026.12。申请人主持。研究对象为光伏功率预测，仅提供深度学习训练经验，不构成本课题研究内容。

（3）自治区优秀博士后资助“面向通用领域的多模态视觉问答关键技术研究”，新疆人社厅，经费 3 万元，2024.07–2025.11。申请人主持。该项目提供视觉问答训练基础，已近结束；本课题将其方法迁移到民族语言场景图文，而不是重复通用域 VQA 任务。

（4）横向课题“面向政企数字化应用的智能知识库与问答系统研发”，项目编号 202604140013，经费 12 万元，2026.06–2026.10。申请人主持。该项目为应用系统研发，与本课题的公开基准评测无相同考核指标。

主要与研究生的其他在研课题与本开放课题无相同研究内容。申请人目前未主持尚未结题的本实验室开放课题。

4. 完成国家自然科学基金项目情况（对申请人负责的前一个资助期满的科学基金项目（项目名称及批准号）完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该项目的研究工作总结摘要（限 500 字）和相关成果详细目录）。

4.1 前一个资助期满项目的完成情况

申请人此前未作为负责人承担国家自然科学基金项目，无前一期资助期满的科学基金项目需要按本栏目说明。

4.2 后续研究进展及与本申请项目的关系

无相应国家自然科学基金延续关系。本栏目仅作模板保留。本申请为教育部重点实验室开放课题，完成情况与后续计划见第（一）部分年度计划。

4.3 研究工作总结摘要

无对应国家自然科学基金项目总结摘要。

4.4 相关成果详细目录

与本课题方法相关的已发表成果见研究基础中的视觉问答与图像理解论文目录，此处不重复罗列。

（三）其他需要说明的情况

1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系；已收到自然科学基金委不予受理或不予资助决定的，无需列出）。

本申请为教育部重点实验室开放课题，不是国家自然科学基金项目。申请人同年无需要按本栏目对照说明的不同类型国家自然科学基金项目。无相关情况。

2. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

无相关情况。

3. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在与正在承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

无相关情况。

4. 申请人和主要参与者同年以不同专业技术职务（职称）申请或参与申请科学基金项目的情况（应详细说明原因）。

无相关情况。

5. 其他。

本申请已按实验室 Word 模板填报，电子版文件名为“2026年开放课题申请-新疆大学-颜丰-副教授”。经费按申请人确定为劳务费 3.5 万元、业务费 1.5 万元。无同年国家自然科学基金项目对照情形，无单位不一致或不同职务申请情形。

与已获资助项目的区分：（1）天池英才项目面向新疆产业集群多模态融合，本课题面向维吾尔语场景文字与维—汉图像理解；（2）申请人另有新能源教学资源开放课题写作材料，其对象为高校课程资源，不纳入本课题研究内容。

申请材料不涉及国家秘密。理解评测题为项目拟构建协议，不是已经发布的大规模维语 VQA 基准。