

弱网环境下跨境物流多模态感知与边缘协同研究 综述

摘要

新疆口岸—中亚运输—边境仓储链路同时面临感知模态异构、网络间歇连接、端侧资源受限和风险跨阶段累积等问题。现有研究分别在多模态表示、时序异常检测、边缘智能、任务导向通信和物流物联网方面形成了较成熟的方法，但多数工作默认数据同步完备、网络持续在线或业务阶段相互独立，因而难以直接解释弱网跨境物流中的可靠性—时延—能耗耦合。本综述从不完备观测下的可靠感知、非平稳多变量异常建模、信息价值驱动的端边协同和运输—仓储跨阶段风险四条主线梳理相关进展。综合证据表明，项目的关键不在于简单叠加视觉、传感器和边缘计算模块，而在于统一建模模态可靠性、信息新鲜度、事件风险与资源预算，并通过跨口岸、跨季节和受控缺失实验验证其可迁移性。由此提出面向地区基金的研究切入点：构建可校准的异步多模态状态表征，以风险价值约束端侧推理与传输决策，并刻画运输事件对仓储风险的动态传播。

1 引言

跨境物流状态监测并非一般意义上的“多传感器接入”。车辆振动、倾斜、电子封志、光感、图像以及仓储温湿度、烟雾和门禁信号具有不同采样频率、噪声机制与故障模式；边境长距离运输又使高丢包、低带宽、长时延和间歇连接成为常态。供应链物联网综述显示，既有研究较多集中于交付过程、食品和制造供应链，概念框架与系统原型多，而围绕复杂网络约束开展的可重复定量研究不足 [1]。物流仓储物联网研究也指出，理论支撑、实证场景和标准化评价之间仍存在断层 [2]。因此，弱网跨境物流研究需要同时回答三个层次的问题：数据不完备时状态能否辨识，端侧应优先保留和传输哪些信息，以及运输与仓储风险如何连续演化。

从技术谱系看，多模态学习提供了表示、对齐、融合和协同学习的通用框架 [3]；边缘计算则通过靠近数据源的计算降低响应时间与带宽开销 [4]。二者结合并不自动得到可靠系统：模态缺失可能使模型置信度失真，网络状态又会改变数据缺失分布；如果调度策略只优化平均时延或平均能耗，稀有但高损失的货损、非法开启或烟雾事件可能被

压缩、延迟甚至丢弃。研究对象因而应从“传感数据”扩展为“数据—网络—资源—风险”的联合状态，并将任务性能、校准误差、上传成功率、信息时效和单位能耗纳入同一验证框架。

2 不完备观测下的多模态可靠感知

多模态学习的基本优势来自模态互补，但这种优势以观测可用性和对齐质量为前提。Transformer 已成为跨模态交互的重要架构，能够统一处理多层次特征与长程依赖 [5]；然而专门的鲁棒性研究表明，当测试阶段缺失某一模态时，训练时依赖完整输入的模型会发生显著退化 [6]。EmbraceNet 通过随机模态拥抱机制在训练期模拟输入缺失，是早期具有代表性的稳健融合方法 [7]。进一步地，多模态校准研究发现，模态损坏或移除后模型置信度可能反而上升，说明仅看分类准确率不足以判断系统可靠性 [8]。

上述结论对跨境物流有两点直接启示。第一，振动、图像和封志等模态不是“等可信”的：传感器老化、车辆颠簸、遮挡和弱网缓存会产生状态相关噪声，可靠性权重应由观测质量和历史一致性共同决定，而不应固定。第二，异步不仅是时间戳对齐问题，也会造成事件证据在不同模态中的先后顺序改变。异步多变量传感序列研究已使用时空注意结构联合建模变量关系与时间依赖 [9]，多源传感器图分解方法进一步说明，显式刻画变量拓扑有助于区分局部扰动与系统性异常 [10]。因此，本项目适合采用“模态内时序编码—跨模态可靠性门控—事件级证据聚合”的层次结构，并以模态丢失率、时间偏移、噪声强度和校准误差构成扰动矩阵。

工业异常检测为物流包装破损识别提供了可迁移的方法与基准。MVTec 3D-AD 同时提供 RGB 与三维信息，证明颜色与表面形态的互补有助于识别单模态难以发现的缺陷 [11]。M3DM 采用对比学习和多记忆库实现混合融合 [12]，跨模态特征映射方法则通过学习正常样本的模态对应关系减少内存占用并提升推理效率 [13]。这些工作主要面向相对稳定的制造环境；跨境物流中的光照、视角、包装材质和振动条件变化更大，不能直接把工业基准上的最优模型等同于现场可用模型。工业视觉异常综述也强调少异常样本、域偏移和评价口径不一致仍是核心限制 [14]。可行的研究路线应以正常状态表征和弱监督事件证据为主，并把跨口岸/跨季节测试作为主评价，而非附加实验。

3 非平稳多变量时序异常与风险演化

货物状态与仓储环境均表现为多变量时序，异常可能是瞬时冲击、持续偏移、变量关系破裂或跨阶段累积。深度时序异常检测综述将现有方法概括为预测、重建、表示学习和混合范式，同时指出数据集、标签与指标差异会显著影响结论 [15]。Anomaly Transformer 使用关联差异区分正常与异常时间点，为长程关系建模提供了代表性思路 [16]；MEMTO 通过记忆模块约束正常模式，缓解重建模型把异常也重建良好的“过泛

化”问题 [17]。面向非平稳环境，动态分解与扩散重建方法显示，显式处理趋势漂移能够减少误报 [18]。

跨境物流的关键困难是网络缺失与真实异常可能相互混淆。例如，连续传感数据突然中断既可能由网络掉线引起，也可能由设备损坏或人为破坏导致。如果将缺测统一插值，可能抹去异常证据；如果将全部缺测标记为异常，又会在弱网环境中产生不可接受的误报。较合理的做法是把观测掩码、缓存状态和网络质量作为模型输入，联合估计“物流状态异常概率”和“观测过程异常概率”。模态一致性方法说明，交换或对齐不同视图的嵌入能够形成额外异常判据 [19]；结构先验约束的图学习则可将已知的传感器因果/拓扑关系纳入模型 [20]。项目可据此区分货物事件、环境事件、设备故障和网络中断四类原因，并通过反事实遮蔽实验检验可辨识边界。

评价协议必须避免人为放大性能。可靠时序异常基准研究指出，点调整等后处理会把只命中异常片段一个点的模型记为整段正确，从而夸大 F1 [21]。因此，除点级 AUROC、AUPRC 和 F1 外，应报告事件级检出率、平均检测延迟、误报持续时间、提前预警量和阈值稳定性。运输—仓储跨阶段研究还需设置两类对照：其一是运输与仓储独立建模，其二是共享表征但不传递风险状态。只有跨阶段模型在跨线路测试中稳定改善早期预警且不显著增加误报，才能支持“风险具有可学习传播结构”的假设。

4 弱网下的信息价值与端边协同

边缘智能研究将深度模型的训练和推理从中心云扩展到端、边、云多层架构，其价值主要体现在低时延、带宽节约和隐私保护 [22]。移动边缘计算综述进一步把问题归纳为卸载决策、通信与计算资源分配及移动性管理 [23]；从通信视角看，边缘系统必须联合考虑无线链路、计算队列与设备能耗 [24]。在跨境运输场景中，网络连接不是连续可用资源，传统“即时卸载或本地执行”的二元决策还应扩展为本地推理、摘要上传、缓存等待和事件抢占等动作。

容迟网络提出的存储—携带—转发思想为间歇连接下的可靠上传奠定了架构基础 [25]，但其目标主要是最终交付，并未显式区分不同数据对风险任务的价值。信息年龄用接收端最新状态距其生成时刻的时间描述信息新鲜度 [26]；有用信息年龄进一步强调，旧数据的损失取决于其对下游任务的效用，而不是时间本身 [27]。任务导向通信据此把优化目标从比特级重建转向控制或推理性能 [28]。面向时限敏感物联网的语义通信研究也说明，在链路受限条件下传输与任务相关的紧凑表示具有潜力 [29]。

这些理论可以转化为跨境物流中的“事件价值”定义：高风险、低置信、信息增益大的片段应优先传输；平稳且可由端侧模型可靠概括的数据可降低采样率或仅上传统计摘要。调度策略需在漏报风险、端到端时延、通信量和能耗之间求解受约束优化，而不能只追求压缩率。已有联合通信—计算设计表明，处理器频率、传输功率和聚合方式共同决定边缘学习能耗 [30]；动态卸载综述则揭示移动节点位置、信道变化和执行时延之

间的耦合 [31]。端侧模型本身也必须可部署：MCUNet 展示了微控制器上模型—推理引擎协同设计的可行性 [32]，AIoT 异常检测综述说明模型性能、内存、时延和功耗应共同报告 [33]。资源感知的端侧分布式推理与轻量异常检测工作进一步表明，实时性收益依赖于模型分割和算法复杂度的联合控制 [34, 35]。

5 物流与仓储场景证据

物流领域已有研究验证了多源感知和边缘计算的应用价值，但其研究目标多偏向效率、可视化或单一环节。食品供应链虚拟化工作展示了物联网对象对在线监测、重规划和决策支持的作用 [36]；物联网与大数据支持供应链决策的综述则指出，传感层需要更强的上下文感知，分布式处理与预测—处方决策之间仍有鸿沟 [37]。近期研究把供应链关注点由效率扩展到韧性，但互操作性、可扩展性与数据质量仍是主要障碍 [38]。这些结论支持从“是否联网”转向“在连接不可靠时如何保持风险感知连续性”。

在具体场景中，航空冷库研究将工业物联网、数字孪生、边云协同和无监督异常检测用于职业安全监测，并开展了真实案例验证 [39]；冷链数据流异常研究说明领域时序具有概念漂移和类别不平衡问题 [40]。港口岸桥监测使用不规则多模态振动序列识别设备异常，表明港口实时数据常呈批次化、不完整且缺少受控异常样本 [41]。港口装卸设备的 ASSIST-IoT 架构强调去中心化数据共享与边缘协作 [42]，海运集装箱混合网络研究则进一步将温度、门状态、LoRaWAN 与低轨卫星链路纳入能效和可靠性分析 [43]。

智能物流异常检测已有蜂窝物联网案例 [44]，贸易物流视觉监测也融合传感器、定位和图像识别完成状态告警 [45]。不过，这些研究大多在单一通信制式或单一业务阶段评价，尚未形成“运输冲击—包装损伤—仓储环境风险”的连续证据链。物联网供应链系统综述同样显示，技术架构与可验证决策收益之间仍需更紧密的实验设计 [46]。因此，本项目的地区特色不能仅靠“新疆口岸”作为应用标签，而应通过真实弱网分布、长距离跨境运输的阶段切换和多语言/多主体数据协作形成具有科学约束的研究情境。

6 不确定性、跨域泛化与评价

模型从实验室走向不同口岸、季节和货类时会发生分布偏移。域泛化研究将其定义为在训练阶段不可见目标域的性能保持问题，常见路线包括域对齐、数据增强、元学习和集成 [47]。但泛化准确率并不等价于可信度：系统性研究表明，数据集偏移会同时破坏准确率与不确定性估计，简单的后处理校准未必可靠 [48]。现代神经网络校准研究给出了可靠性图、期望校准误差和温度缩放等基础工具 [49]；保形预测则能够在交换性等条件下提供分布无关的有限样本覆盖保证 [50]。

对本项目而言，不确定性至少包含三类：传感噪声与缺失引起的观测不确定性、模型参数与数据不足引起的认知不确定性、口岸/季节变化引起的分布不确定性。实验应

同时报告分类/检测性能与 ECE、Brier 分数、风险—覆盖曲线，并检验在模态缺失和弱网强度上升时不确定性是否单调增加。对于高风险告警，可设置选择性预测：当置信度不足时由端侧缓存更多上下文、提高采样率或请求人工复核，而不是输出确定标签。这一机制把不确定性从展示性指标转化为通信和决策动作。

7 讨论

现有文献的主要断裂体现在四个方面。其一，多模态异常检测通常假定各模态同步可用，而弱网研究常把感知数据视为同质数据包，二者对“缺失为何发生”的建模不一致。其二，边缘卸载多以平均时延和能耗为目标，物流异常检测则关注准确率，缺少对稀有高损失事件的联合约束。其三，物流案例证明了系统可运行，却很少提供跨线路、跨季节和受控链路退化下的可重复基准。其四，时序异常模型的结果高度依赖阈值和后处理协议，若不采用事件级指标，技术增益可能不可复现。

由此可见，项目不宜把研究内容拆成彼此独立的“多模态算法、弱网传输、仓储平台”三个系统模块。更有科学价值的组织方式是围绕统一潜变量状态展开：多模态编码器估计物流状态及其不确定性；边缘策略依据风险、信息增益与网络资源决定采样、推理、缓存和传输；跨阶段模型把运输事件作为仓储风险的先验。三部分共享状态变量、优化目标和评价协议，才能形成可证伪的因果链条。

8 展望

后续研究可沿三条可检验路线推进。第一，建立“观测过程—物流状态”双层生成模型，显式区分网络丢失、传感器故障与真实事件，并通过合成遮蔽加小规模实测验证其可辨识边界。第二，将事件价值定义为风险降低量、信息新鲜度与单位资源代价的组合，研究具有安全约束的在线策略；如果策略在同等漏报率下不能降低通信量和能耗，则应拒绝其有效性。第三，构建运输—仓储事件图并进行跨口岸留一验证；若跨阶段模型相较独立模型不能稳定提升提前预警量，则应收缩风险传播假设。数据建设应优先记录原始时间戳、缓存/重传日志、网络状态和传感器健康度，使模型失败能够回溯到观测、通信或推理环节。

9 结论

弱网跨境物流研究的前沿问题不是单项算法精度，而是不完备观测与资源约束共同作用下的可靠决策。多模态学习、时序异常检测、边缘智能、信息时效和物流物联网分别提供了必要工具，但尚缺少统一的状态—风险—资源建模框架。本项目可从可校准的

异步多模态表征、信息价值驱动的端边协同和运输—仓储跨阶段风险演化三个相互约束的方向切入，以真实弱网分布和跨场景评价形成区别于一般智慧物流系统的科学贡献。

参考文献

- [1] Ben-Daya M, Hassini E, Bahroun Z. Internet of things and supply chain management: a literature review[J/OL]. International Journal of Production Research, 2019. <https://doi.org/10.1080/00207543.2017.1402140>.
- [2] Kumar D, Singh R K, Mishra R, Wamba S F. Applications of the internet of things for optimizing warehousing and logistics operations: A systematic literature review and future research directions[J/OL]. Computers & Industrial Engineering, 2022. <https://doi.org/10.1016/j.cie.2022.108455>.
- [3] Baltrušaitis T, Ahuja C, Morency L. Multimodal Machine Learning: A Survey and Taxonomy[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018. <https://doi.org/10.1109/tpami.2018.2798607>.
- [4] Shi W, Cao J, Zhang Q, Li Y, Xu L. Edge Computing: Vision and Challenges[J/OL]. IEEE Internet of Things Journal, 2016. <https://doi.org/10.1109/jiot.2016.2579198>.
- [5] Xu P, Zhu X, Clifton D A. Multimodal Learning With Transformers: A Survey[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2023. <https://doi.org/10.1109/tpami.2023.3275156>.
- [6] Ma M, Ren J, Zhao L, Testuggine D, Peng X. Are Multimodal Transformers Robust to Missing Modality?[J/OL]. 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022. <https://doi.org/10.1109/cvpr52688.2022.01764>.
- [7] Choi J-H, Lee J-S. EmbraceNet: A robust deep learning architecture for multimodal classification[J/OL]. Information Fusion, 2019. <https://doi.org/10.1016/j.inffus.2019.02.010>.
- [8] Ma H, Zhang Q, Zhang C, Wu B, Fu H, Zhou J T, Hu Q. Calibrating Multimodal Learning[J/OL]. Proceedings of the 40th International Conference on Machine Learning, 2023. <https://proceedings.mlr.press/v202/ma23i.html>.

- [9] Yi S, Zheng S, Yang S, Zhou G, Cai J. Anomaly Detection for Asynchronous Multivariate Time Series of Nuclear Power Plants Using a Temporal-Spatial Transformer[J/OL]. Italian National Conference on Sensors, 2024. <https://doi.org/10.3390/s24092845>.
- [10] Wang Y, Ma L, Zhang M, Peng S, Lin Y, Zhao J. Graph-Based Time-Series Decomposition for Multisource Sensors Anomaly Detection[J/OL]. IEEE Sensors Journal, 2024. <https://doi.org/10.1109/jsen.2024.3452088>.
- [11] Bergmann P, Jin X, Sattlegger D, Steger C. The MVTEC 3D-AD Dataset for Unsupervised 3D Anomaly Detection and Localization[J/OL]. Proceedings of the 17th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications, 2022. <https://doi.org/10.5220/0010865000003124>.
- [12] Wang Y, Peng J, Zhang J, Yi R, Wang Y, Wang C. Multimodal Industrial Anomaly Detection via Hybrid Fusion[J/OL]. 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2023. <https://doi.org/10.1109/cvpr52729.2023.00776>.
- [13] Costanzino A, Ramirez P Z, Lisanti G, Stefano L D. Multimodal Industrial Anomaly Detection by Crossmodal Feature Mapping[J/OL]. 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024. <https://doi.org/10.1109/cvpr52733.2024.01631>.
- [14] Liu J, Xie G, Wang J, Li S, Wang C, Zheng F, Jin Y. Deep Industrial Image Anomaly Detection: A Survey[J/OL]. Machine Intelligence Research, 2024. <https://doi.org/10.1007/s11633-023-1459-z>.
- [15] Darban Z Z, Webb G I, Pan S, Aggarwal C C, Salehi M. Deep Learning for Time Series Anomaly Detection: A Survey[J/OL]. ACM Computing Surveys, 2024. <https://doi.org/10.1145/3691338>.
- [16] Xu J, Wu H, Wang J, Long M. Anomaly Transformer: Time Series Anomaly Detection with Association Discrepancy[J/OL]. International Conference on Learning Representations, 2022. https://openreview.net/forum?id=LzQQ89U1qm_.
- [17] Song J, Kim K, Oh J, Cho S. MEMTO: Memory-guided Transformer for Multivariate Time Series Anomaly Detection[J/OL]. Advances in Neural Information Processing Systems 36, 2023. <https://doi.org/10.52202/075280-2525>.

- [18] Wang C, Zhuang Z, Qi Q, Wang J, Wang X, Sun H, Liao J. Drift doesn't Matter: Dynamic Decomposition with Diffusion Reconstruction for Unstable Multivariate Time Series Anomaly Detection[J/OL]. *Advances in Neural Information Processing Systems* 36, 2023. <https://doi.org/10.52202/075280-0473>.
- [19] Liu H, Xi L, Gu M, Huang S, Sheng C, Zhang F. ExTAD: Embedding Exchange Inspired Time Series Anomaly Detection With Modal Consistency[J/OL]. *IEEE Sensors Journal*, 2024. <https://doi.org/10.1109/jsen.2024.3480133>.
- [20] He S, Li G, Xie K, Sharma P. Fusion Graph Structure Learning-Based Multivariate Time Series Anomaly Detection With Structured Prior Knowledge[J/OL]. *IEEE Transactions on Information Forensics and Security*, 2024. <https://doi.org/10.1109/tifs.2024.3459631>.
- [21] Liu Q, Paparrizos J. The Elephant in the Room: Towards A Reliable Time-Series Anomaly Detection Benchmark[J/OL]. *Unknown*, 2024. <https://doi.org/10.52202/079017-3437>.
- [22] Zhou Z, Chen X, Li E, Zeng L, Luo K, Zhang J. Edge Intelligence: Paving the Last Mile of Artificial Intelligence With Edge Computing[J/OL]. *Proceedings of the IEEE*, 2019. <https://doi.org/10.1109/jproc.2019.2918951>.
- [23] Mach P, Becvar Z. Mobile Edge Computing: A Survey on Architecture and Computation Offloading[J/OL]. *IEEE Communications Surveys & Tutorials*, 2017. <https://doi.org/10.1109/comst.2017.2682318>.
- [24] Mao Y, You C, Zhang J, Huang K, Letaief K B. A Survey on Mobile Edge Computing: The Communication Perspective[J/OL]. *IEEE Communications Surveys & Tutorials*, 2017. <https://doi.org/10.1109/comst.2017.2745201>.
- [25] Fall K. A delay-tolerant network architecture for challenged internets[J/OL]. *Proceedings of the 2003 conference on Applications, technologies, architectures, and protocols for computer communications*, 2003. <https://doi.org/10.1145/863955.863960>.
- [26] Yates R D, Sun Y, Brown D R, Kaul S K, Modiano E, Ulukus S. Age of Information: An Introduction and Survey[J/OL]. *IEEE Journal on Selected Areas in Communications*, 2021. <https://doi.org/10.1109/jsac.2021.3065072>.

- [27] Shi T, Cai Z, Li J, Gao H. Optimize the Age of Useful Information in Edge-assisted Energy-harvesting Sensor Networks[J/OL]. ACM Transactions on Sensor Networks, 2024. <https://doi.org/10.1145/3640342>.
- [28] Mostaani A, Vu T X, Sharma S K, Nguyen V-D, Liao Q, Chatzinotas S. Task-Oriented Communication Design in Cyber-Physical Systems: A Survey on Theory and Applications[J/OL]. IEEE Access, 2022. <https://doi.org/10.1109/access.2022.3231039>.
- [29] Cavagna A, Li N, Iosifidis A, Zhang Q. Semantic Communication Enabling Robust Edge Intelligence for Time-Critical IoT Applications[J/OL]. 2023 IEEE International Conference on Communications Workshops (ICC Workshops), 2023. <https://doi.org/10.1109/iccworkshops57953.2023.10283786>.
- [30] Mo X, Xu J. Energy-Efficient Federated Edge Learning with Joint Communication and Computation Design[J/OL]. Journal of Communications and Information Networks, 2021. <https://doi.org/10.23919/jcin.2021.9475121>.
- [31] Huda S A, Moh S. Survey on computation offloading in UAV-Enabled mobile edge computing[J/OL]. Journal of Network and Computer Applications, 2022. <https://doi.org/10.1016/j.jnca.2022.103341>.
- [32] Lin J, Chen W-M, Lin Y, Gan C, Han S. MCUNet: Tiny Deep Learning on IoT Devices[J/OL]. Advances in Neural Information Processing Systems, 2020. <https://proceedings.neurips.cc/paper/2020/hash/86c51678350f656dcc7f490a43946ee5-Abstract.html>.
- [33] Trilles S, Hammad S S, Iskandaryan D. Anomaly detection based on Artificial Intelligence of Things: A Systematic Literature Mapping[J/OL]. Internet of Things, 2024. <https://doi.org/10.1016/j.iot.2024.101063>.
- [34] Yoosefi A, Kargahi M. Resource-aware in-edge distributed real-time deep learning[J/OL]. Internet of Things, 2024. <https://doi.org/10.1016/j.iot.2024.101263>.
- [35] Das R, Luo T. LightESD: Fully-Automated and Lightweight Anomaly Detection Framework for Edge Computing[J/OL]. 2023 IEEE International Conference on Edge Computing and Communications (EDGE), 2023. <https://doi.org/10.1109/edge60047.2023.00032>.

- [36] Verdouw C, Wolfert J, Beulens A, Rialland A. Virtualization of food supply chains with the internet of things[J/OL]. *Journal of Food Engineering*, 2016. <https://doi.org/10.1016/j.jfoodeng.2015.11.009>.
- [37] Koot M, Mes M R, Iacob M E. A systematic literature review of supply chain decision making supported by the Internet of Things and Big Data Analytics[J/OL]. *Computers & Industrial Engineering*, 2021. <https://doi.org/10.1016/j.cie.2020.107076>.
- [38] Shoomal A, Jahanbakht M, Componation P J, Ozay D. Enhancing supply chain resilience and efficiency through internet of things integration: Challenges and opportunities[J/OL]. *Internet of Things*, 2024. <https://doi.org/10.1016/j.iot.2024.101324>.
- [39] Zhan X, Wu W, Shen L, Liao W, Zhao Z, Xia J. Industrial internet of things and unsupervised deep learning enabled real-time occupational safety monitoring in cold storage warehouse[J/OL]. *Safety Science*, 2022. <https://doi.org/10.1016/j.ssci.2022.105766>.
- [40] Xie Z, Long H, Ling C, Zhou Y, Luo Y. An anomaly detection scheme for data stream in cold chain logistics[J/OL]. *PLOS ONE*, 2025. <https://doi.org/10.1371/journal.pone.0315322>.
- [41] Mukherjee A, Sasidharan M, Herrera M, Parlikad A K. Unsupervised constrained discord detection in IoT-based online crane monitoring[J/OL]. *Advanced Engineering Informatics*, 2024. <https://doi.org/10.1016/j.aei.2024.102444>.
- [42] Garro E, Lacalle I, Blanquer F, Ramos A, Martinez A, Sowiński P, Llorente M A, Palau C. Maritime terminals' cargo handling equipment cooperation leveraging IoT and edge computing: The ASSIST-IoT approach[J/OL]. *Transportation Research Procedia*, 2023. <https://doi.org/10.1016/j.trpro.2023.11.831>.
- [43] Ledesma O, Lamo P. Hybrid IoT network for real-time monitoring of maritime containers[J/OL]. *Computer Networks*, 2025. <https://doi.org/10.1016/j.comnet.2025.111627>.
- [44] Savic M, Lukic M, Danilovic D, Bodroski Z, Bajovic D, Mezei I, Vukobratovic D, Skrbic S, Jakovetic D. Deep Learning Anomaly Detection for Cellular IoT With Applications in Smart Logistics[J/OL]. *IEEE Access*, 2021. <https://doi.org/10.1109/access.2021.3072916>.

- [45] Gao Z, Kang C, Wu X. Intelligent Monitoring and Management of Trade Logistics Based on Big Data and Computer Vision Technology[J/OL]. Procedia Computer Science, 2024. <https://doi.org/10.1016/j.procs.2024.09.084>.
- [46] Taj S, Imran A S, Kastrati Z, Daudpota S M, Memon R A, Ahmed J. IoT-based supply chain management: A systematic literature review[J/OL]. Internet of Things, 2023. <https://doi.org/10.1016/j.iot.2023.100982>.
- [47] Zhou K, Liu Z, Qiao Y, Xiang T, Loy C C. Domain Generalization: A Survey[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022. <https://doi.org/10.1109/tpami.2022.3195549>.
- [48] Ovadia Y, Fertig E, Ren J, Nado Z, Sculley D, Nowozin S, Dillon J, Lakshminarayanan B, Snoek J. Can You Trust Your Model's Uncertainty? Evaluating Predictive Uncertainty Under Dataset Shift[J/OL]. Advances in Neural Information Processing Systems, 2019. <https://proceedings.neurips.cc/paper/2019/hash/8558cb408c1d76621371888657d2eb1d-Abstract.html>.
- [49] Guo C, Pleiss G, Sun Y, Weinberger K Q. On Calibration of Modern Neural Networks[J/OL]. Proceedings of the 34th International Conference on Machine Learning, 2017. <https://proceedings.mlr.press/v70/guo17a.html>.
- [50] Angelopoulos A N, Bates S. A Gentle Introduction to Conformal Prediction and Distribution-Free Uncertainty Quantification[J/OL]. arXiv, 2021. <https://doi.org/10.48550/arXiv.2107.07511>.