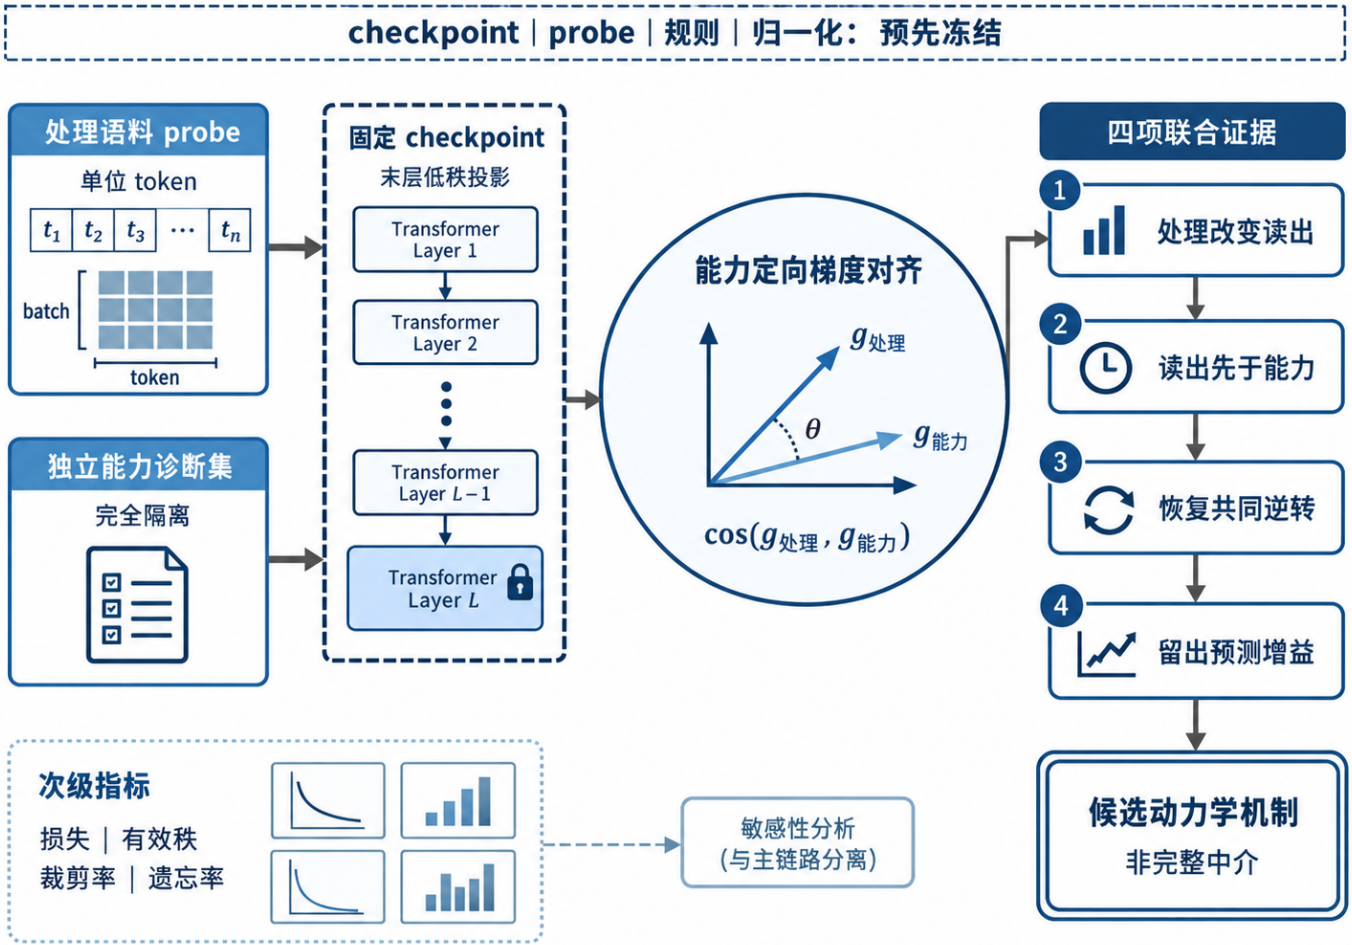

checkpoint | probe | 规则 | 归一化：预先冻结
处理语料 probe
单位 token
t_1 t_2 t_3 ⋯ t_n
batch
token
独立能力诊断集
完全隔离
固定 checkpoint
末层低秩投影
Transformer Layer 1
Transformer Layer 2
Transformer Layer $L-1$
Transformer Layer L
能力定向梯度对齐
$g_{处理}$
θ
$g_{能力}$
$\cos(g_{处理}, g_{能力})$
四项联合证据
1 处理改变读出
2 读出先于能力
3 恢复共同逆转
4 留出预测增益
候选动力学机制
非完整中介
次级指标
损失 | 有效秩
裁剪率 | 遗忘率
敏感性分析
(与主链路分离)