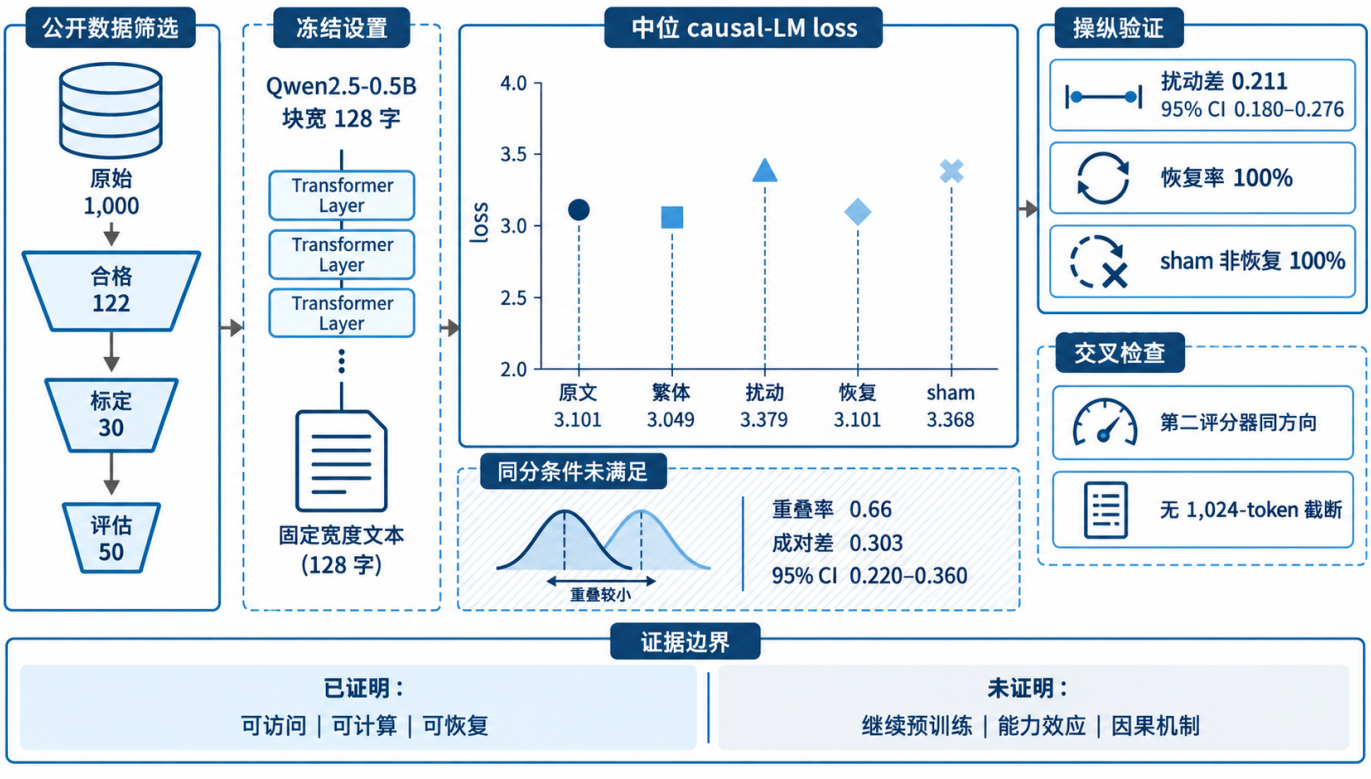

公开数据筛选
原始
1,000
合格
122
标定
30
评估
50
冻结设置
Qwen2.5-0.5B
块宽 128 字
Transformer Layer
Transformer Layer
Transformer Layer
固定宽度文本
(128 字)
中位 causal-LM loss
loss
4.0
3.5
3.0
2.5
2.0
原文
3.101
繁体
3.049
扰动
3.379
恢复
3.101
sham
3.368
操纵验证
扰动差 0.211
95% CI 0.180–0.276
恢复率 100%
sham 非恢复 100%
交叉检查
第二评分器同方向
无 1,024-token 截断
同分条件未满足
重叠较小
重叠率 0.66
成对差 0.303
95% CI 0.220–0.360
证据边界
已证明：
可访问 | 可计算 | 可恢复
未证明：
继续预训练 | 能力效应 | 因果机制