报告正文（2026版）

参照以下提纲撰写，要求内容翔实、清晰，层次分明，标题突出。**申请书正文原则上不超过 30 页，鼓励简洁表达。请勿删除或改动下述提纲标题及括号中的文字。**

（一）立项依据：

（为什么要开展此项研究，研究的科学技术价值如何）

1.1 研究背景与意义

预训练语料不再只是模型训练的被动原料，其组成会影响模型的知识边界、语言能力和计算效率。随着模型参数和训练预算增加，无差别扩充语料受到许可、重复、噪声和算力成本的共同限制。在既定计算条件下，哪些数据能够产生有效学习更新，因而成为语言模型从规模扩张转向数据机制研究时必须回答的问题。计算最优训练规律说明模型规模、训练 token 与性能之间存在系统约束[1, 2, 3]，大规模语料工程也表明，来源选择、去重、过滤和混合方式能够影响训练过程与最终能力[4, 5, 6]。语料质量由此超出了预处理工程指标的范畴：它引起何种学习效应，这些效应在什么条件下成立，仍需专门研究。

目前常用的质量评价多依赖困惑度、表面规范性、来源声誉或与百科类“高质量文本”的相似程度。此类指标便于扩展到海量网页，却把不同性质的文本压缩到同一排序轴上。乱码、异常截断、段落错序等结构破损会削弱上下文的可学习关系；网络/地域书写、简繁异体或中英混写等结构完整但模型低熟悉的中文表达，也可能因困惑度较高或偏离规范语体而获得低分。两者的表面分数相近，训练含义却未必相同：修复前者可能减少与有效学习目标不一致的更新，删除后者则可能减少语体、实体和长尾知识的非冗余支持。若不区分这两种来源，“提高平均质量”便可能同时包含去除结构缺陷的收益和收缩语义支持的损失。

这一矛盾在中文语料中尤为适合被严格检验。中文没有天然词间空格，简繁/异体、古今语体、网络表达和中英混写会共同影响 tokenizer 切分、序列长度、模型困惑度与规范性判断；表面“不熟悉”并不等同于语义破损。公开中文模型和评价基准已经为中文理解能力研究提供了可复核载体[7, 8, 9]，但多语言质量过滤研究也提示，跨语言评分需要显式处理语言差异，不能直接把英语网页中的质量经验平移到中文[10]。研究中文语料的意义因而不在于把现有筛选器换一批数据验证，而在于

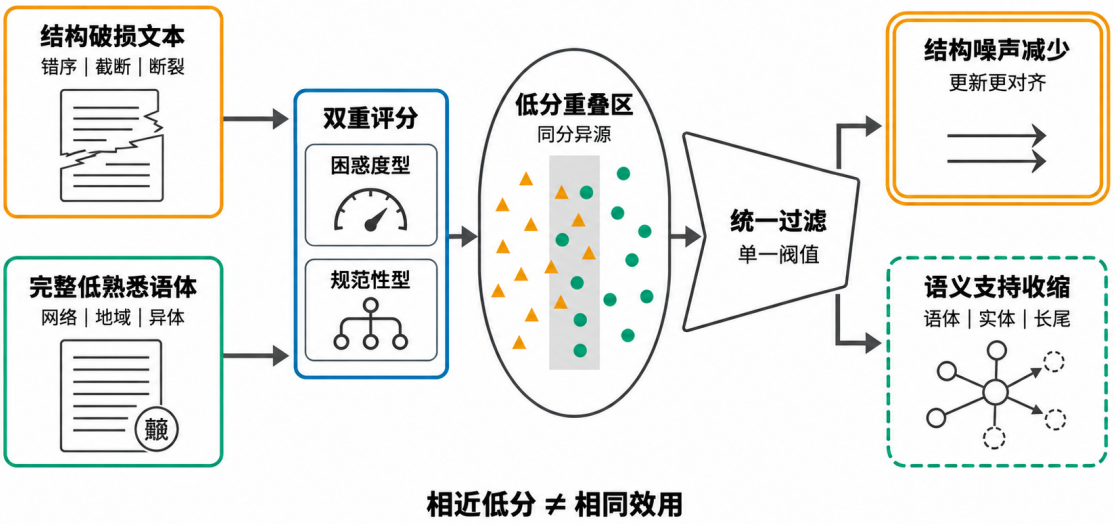


图 1. 相近低质量表征的异源构成及统一过滤悖论（概念示意）

利用中文书写与语体异质性，检验“表面质量表征与训练效用是否等价”这一更一般的机制命题。

本项目聚焦公开可许可中文语料和小中规模开源自回归模型的受控继续预训练，不从零训练通用大模型，也不追求覆盖所有中文现象。项目拟预注册一类结构完整、来源可核验但模型低熟悉的中文语体作为确认性对象，并以另一类书写/语体现象作稳健性复核；通过可逆结构修复、sham 编辑、同语体非冗余支持补回、同语体窄支持补回和主流文本伪补回，分别定义结构缺陷削减与语义支持损失的反事实。若能说明相近低质量表征为何形成不同作用路径和反事实响应，就可把语料筛选研究从“哪个分数更准”推进到“分数背后的效用路径在何种条件下成立”，也为防止低频中文表达在自动过滤中被系统性排除提供可检验的理论依据。

1.2 国内外研究现状及发展动态分析

预训练语料工程已从规模构建转向质量策展，但质量对象仍常被混合。 大规模开放语料的建设形成了网页抽取、语言识别、规则过滤、去重、来源记录和数据卡等基本流程。RefinedWeb、Dolma 等工作显示，经系统处理的网页语料可以支撑有竞争力的语言模型训练[4, 5]；数据审计研究则强调，仅知道语料规模不足以理解其组成和潜在偏差，需要追溯来源、内容类别与处理历史[11, 12]。去重研究证明，训练样本重复与模型记忆、过拟合及评价污染密切相关[13, 14]。这些研究奠定了“数据可治理”的基础，但文档完整性、集合多样性和特定模型上的边际效用分别属于文档

级、集合级与模型条件层级，三者并不能由一个静态分数自然统一。

近年来的数据选择方法开始从单规则转向多维评分或多评价器协同。Meta-rater 组合多维信号评估预训练样本，Multi-Actor 通过多主体协作提高数据选择效率，FIRE 则研究多种质量评分的灵活整合[15, 16, 17]。多语言质量判别进一步尝试缓解单一语言评分器的迁移问题[10]。这些进展提高了排序表达力，但其主要目标仍是预测或优化筛选结果。当结构破损与低频但有效的语体在评分空间中重叠时，增加评分器数量未必能解释两类样本为何具有不同训练效应。“怎样打分”已有较多探索，而“同一低分由何种机制产生、删除后果为何不同”仍缺少反事实证据。

质量过滤与多样性保持的矛盾已被认识，但现有结果不足以识别作用路径。 数据选择研究已经注意到高质量、重要性和多样性之间不能相互替代。面向重要数据的多样性选择直接把覆盖纳入预训练样本选择[18]，网页重写等路线则尝试在不简单删除内容的情况下改善文本形态[19]。MiniPile 等数据高效研究也说明，更小但经过选择的语料可以改变单位 token 收益[20]。因此，本项目不把“过滤会损失多样性”或“质量与覆盖存在权衡”作为创新结论；这些认识已构成研究背景。

尚未解决的是，现有工作多比较不同筛选策略或阈值产生的净效果。阈值提高会同时改变结构缺陷比例、来源构成、独立样本数、长尾覆盖和重复曝光，观察到的能力升降无法区分是缺陷减少、支持收缩、语体曝光变化，还是处理后重复训练轮次增加造成的。即使在相同 token 预算下，字符数、有效语义单元、packing 效率和数据处理成本也可能不同。缺少“保持支持只修复结构”和“保持语体曝光只改变非冗余广度”的正交反事实，质量收益与覆盖损失仍只是事后解释，不能形成可证伪的机制判断。

数据混合与动态重加权揭示模型条件效用，却难以替代机制识别。 DoReMi、DoGE 和数据混合律等工作以代理模型或验证目标优化领域配比，表明最优数据组合依赖目标分布和模型条件[21, 22, 23]。Skill-it! 从技能依赖出发组织数据，ScaleBiO 等方法则将预训练数据重加权写成可扩展的双层优化问题[24, 25]。自影响重加权和动态损失重加权进一步说明，样本价值随训练状态和评价目标变化，固定排序不是唯一合理选择[26, 27]。

这条路线说明数据效用取决于具体条件，同时留下两个问题。第一，数据混合方法通常以验证损失或聚合能力为优化目标，容易把机制不同的样本统一解释为权重差异；它可以找到更有效的组合，却未必回答结构修复与语义支持恢复为何产生

差异。第二，代理模型上得到的领域权重、排序或阈值会受到模型规模、tokenizer 和基础训练史影响，直接外推存在风险。本项目据此把处理前模型知识状态作为双路径效应的边界条件，不另行开发动态选样算法。只有从共同 checkpoint 随机分叉，才能区分状态调节与处理后的路径依赖。

训练数据影响分析提供了机制读出，但相关性不能自动成为因果中介。 训练数据影响与估值研究尝试追踪单个样本或数据子集对模型输出的贡献，包括自影响、影响函数、事实追踪和免训练估值等路线 [28, 29, 30, 31, 32]。这些方法为观察“某批数据的更新朝向何处”提供了工具，也暴露出计算开销、目标依赖和尺度迁移等限制。训练数据抽取研究表明，模型可能保留可被抽取的训练记忆；这要求能力评价进一步排除训练—评价近邻和污染，不能把可复现答案直接视为一般知识吸收 [33, 34]。

对本项目而言，原始损失更低不一定表示样本更有用，梯度方差更大也可能同时来自有价值的新信息和有害结构噪声。为降低事后选择自由度，本项目只把“能力定向梯度对齐”作为主动力学读出，即在固定 probe 上度量训练 batch 梯度与独立能力诊断集梯度的单位 token 归一化方向关系。该读出仍只是局部候选中介：只有处理先改变读出，读出对后续独立能力有留出预测增益，并且修复/恢复时读出与能力共同逆转，才支持动力学中介解释。仅凭加入中介变量后回归系数改变，不足以声称机制成立。

中文场景具备研究基础，但“使用中文数据”本身不是创新。 中文开放模型、语料构建和多任务评价的发展，使得受控继续预训练与中文能力测量成为可执行研究对象 [7, 8, 9]。与此同时，基准可能受污染、反复调参和构念覆盖不足影响，单一榜单不能代表语体、知识与长尾能力 [35]。多语言筛选工作证明语言条件需要进入质量评价 [10]，但尚不能回答中文内部的表面规范性、模型熟悉度和语义完整性如何共同塑造训练效用。

中文语料在本项目中构成一项压力测试：结构完整的低频中文语体与真正结构破损的文本可能被静态质量表征压缩为相近低分，但两者分别关联可学习的非冗余支持与低目标对齐更新。确认这一点需要至少两类异质评分器、人工语义完整性审查以及独立能力终点，单个自建分类器不足以支持判断。所得结论限于预注册中文语体、公开数据来源和小中规模继续预训练条件，不预设该机制为中文独有。

1.3 现有研究的不足

综上，现有工作已经证明数据处理会影响预训练结果，也形成了质量评分、多样性选择、数据混合和影响估计等丰富方法，但仍存在三项相互关联的认知缺口。

第一，**静态低质量表征的效用异质性缺少可干预解释**。结构破损与模型低熟悉的完整中文语体可能获得相近分数，现有筛选对比却难以说明两类低分样本的效用为何不同。若只提高分类准确率或组合更多指标，仍可能把评分器的测量偏差当作数据质量机制。

第二，**缺陷削减与语义支持损失缺少路径特异的反事实证据**。常规过滤同时改变质量、语体比例、非冗余广度和曝光次数；观察到强过滤后能力下降，并不能证明原因是覆盖损失。同语体非冗余补回是否优于同语体重复/窄支持补回和主流文本补回，是区分“非冗余支持”“语体曝光”与“等量补数”的关键反证，但尚少有研究在受控继续预训练中同时设置这些对照。

第三，**两条路径的动力学证据和适用边界尚不清楚**。梯度、损失和遗忘指标可能都与最终能力相关，却处于不同统计层级；把大量 token 或 checkpoint 当作独立样本会产生伪重复。来源和模型状态变化还可能使效应反号。需要以训练运行为推断单位，冻结主读出和能力终点，并在独立来源中检验效应方向、预测区间和拒绝外推条件。

这三项缺口依次涉及低分来源、作用路径和适用边界：先识别两类低分来源，再用特异恢复和负对照分离作用路径，最后检验路径效应能否跨来源保持以及何时失效。三者共同指向同一个机制问题。

1.4 关键科学问题与研究切入点

本项目拟回答的中心科学问题是：**中文语料中，结构破损文本与结构完整但模型低熟悉的中文语体为何会获得相近的低质量表征，却经由结构缺陷削减和非冗余语义支持损失形成不同作用路径与反事实响应；这种效用异质性如何受模型既有知识状态调节？**

围绕该问题提出如下可证伪假设：**中文语料的静态低质量表征混合了结构缺陷与低模型熟悉度两类成分。结构破损产生与有效学习目标低对齐的更新；结构完整但模型低熟悉的中文语体可提供面向相应能力的非冗余更新。因此，保持语义支持的结构修复应提高训练更新的能力定向梯度对齐并改善通用能力；保持语体曝光量的非冗余支持补回应选择性改善语体与长尾能力。前一路径检验结构损伤及恢复，后一路径检验移除后的支持补回；二者共同解释低质量表征的效用异质性，不把两个**

估计量直接解释为同一种过滤效应的方向比较。

该假设允许被直接否定：在分词与 packing、总 token、语体曝光量及训练—评价重叠受控后，若原文恢复相对 sham 编辑不能提高能力定向梯度对齐和独立后测能力，则结构路径被否定；若同语体非冗余补回不优于同语体等量重复/窄支持补回及主流文本补回，则语义支持路径被否定。任一路径失败均不以“状态依赖”或重新校准作兜底解释。

本项目从评分、干预、动力学与能力四个层级切入，不另行构造综合质量分。首先用两类异质质量表征和人工盲审定位“分数重叠而生成机制不同”的样本层；继而以可逆结构破损、原文恢复和 sham 编辑识别结构路径，以同语体非冗余、同语体窄支持和主流文本补回识别支持路径；最后通过共同 checkpoint 随机分叉和独立来源的冻结协议复核模型状态与外部边界。即使这些实验没有产生更好的过滤策略，反证结果仍能回答两类效应是否存在、哪些替代机制可以解释效应以及结论能否外推。

参考文献

[1] Hoffmann J, Borgeaud S, Mensch A, Buchatskaya E, Cai T, Rutherford E, de Las Casas D, Hendricks L A, Welbl J, Clark A. Training Compute-Optimal Large Language Models[J/OL]. arXiv (Cornell University), 2022. https://openalex.org/W4225591000.

[2] Rae J W, Borgeaud S, Cai T, Millican K, Hoffmann J, Song F, Aslanides J, Henderson S B, Ring R, Young S. Scaling Language Models: Methods, Analysis & Insights from Training Gopher[J/OL]. arXiv (Cornell University), 2021. https://openalex.org/W4226146865.

[3] Kaplan J, McCandlish S, Henighan T, Brown T B, Chess B, Child R, Gray S, Radford A, Wu J, Amodei D. Scaling Laws for Neural Language Models[J/OL]. arXiv (Cornell University), 2020. https://arxiv.org/abs/2001.08361.

[4] Penedo G, Malartic Q, Hesslow D, Cojocaru R, Cappelli A, Alobeidli H, Pannier B, Almazrouei E, Launay J. The RefinedWeb Dataset for Falcon LLM: Outperforming Curated Corpora with Web Data, and Web Data Only[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4379468930.

[5] Soldaini L, Kinney R, Bhagia A, Schwenk D, Atkinson D, Authur R, Bogin B, Chandu K R, Dumas J, Elazar Y. Dolma: an Open Corpus of Three Trillion Tokens for Language Model Pretraining Research[C/OL] // Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). [S.l.] : Association for Computational Linguistics, 2024 : 15725 – 15788. https://aclanthology.org/2024.acl-long.840/.

[6] Almazrouei E, Alobeidli H, Alshamsi A, Cappelli A, Cojocaru R, Debbah M, Goffinet É, Hesslow D, Launay J, Malartic Q. The Falcon Series of Open Language Models[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4389157038.

[7] Dong G, Pan D, Sun Y, Zhang S, Liang Z, Wu X, Shen Y, Yang F, Sun H, Li T. BaichuanSEED: Sharing the Potential of ExtensivE Data Collection and Deduplication by Introducing a Competitive Large Language Model Baseline[J/OL]. arXiv (Cornell University), 2024. https://openalex.org/W4402705130.

[8] GLM Team. ChatGLM: A Family of Large Language Models from GLM-130B to GLM-4 All Tools[J/OL]. arXiv (Cornell University), 2024. https://openalex.org/W4399837985.

[9] Li H, Zhang Y, Koto F, Yang Y, Zhao H, Gong Y, Duan N, Baldwin T. CMMLU: Measuring massive multitask language understanding in Chinese[C/OL] // Findings of the Association for Computational Linguistics: ACL 2024. [S.l.]: Association for Computational Linguistics, 2024: 11260–11285. https://aclanthology.org/2024.findings-acl.671/.

[10] Ali M, Brack M, Lübbering M, Wendt E, Khan A G, Rutmann R, Jude A, Kraus M, Weber A A, Stollenwerk F, Kaczér D, Mai F, Flek L, Sifa R, Flores-Herr N, Koehler J, Schramowski P, Fromm M, Kersting K. Judging Quality Across Languages: A Multilingual Approach to Pretraining Data Filtering with Language Models[C/OL] // Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. 2025: 8859–8898. https://aclanthology.org/2025.emnlp-main.449/.

[11] Elazar Y, Bhagia A, Magnusson I, Ravichander A, Schwenk D, Suhr A, Walsh P, Groeneveld D, Soldaini L, Singh S. What's In My Big Data?[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4388185104.

[12] Desai M, Pasquetto I V, Jacobs A Z, Card D. An archival perspective on pretraining data[J/OL]. Patterns, 2024. https://openalex.org/W4393321314.

[13] Lee K, Ippolito D, Nystrom A, Zhang C, Eck D, Callison-Burch C, Carlini N. Deduplicating Training Data Makes Language Models Better[J/OL]. Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2022. https://openalex.org/W3177765786.

[14] Carlini N, Ippolito D, Jagielski M, Lee K, Tramèr F, Zhang C. Quantifying Memorization Across Neural Language Models[J/OL]. arXiv (Cornell University), 2022. https://openalex.org/W4221159672.

[15] Zhuang X, Peng J, Ma R, Wang Y, Bai T, Wei X, Qiu J, Zhang C, Qian Y, He C. Meta-rater: A Multi-dimensional Data Selection Method for Pre-training Language Models[C/OL] // Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics. 2025: 10856–10896. https://aclanthology.org/2025.acl-long.533/.

[16] Bai T, Yang L, Wong Z H, Sun F, Zhuang X, Peng J, Zhang C, Wu L, Qiu J, Zhang W, Yuan B, He C. Efficient Pretraining Data Selection for Language Models via Multi-Actor Collaboration[C/OL] // Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics. 2025: 9465–9491. https://aclanthology.org/2025.acl-long.466/.

[17] Xu L, Zhang X, Duan F, Wang S, Weng R, Wang J, Cai X. FIRE: Flexible Integration of Data Quality Ratings for Effective Pretraining[C/OL] // Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. [S.l.]: Association for Computational Linguistics, 2025: 14521–14541. https://aclanthology.org/2025.emnlp-main.735/.

[18] Zhang C, Zhong H, Zhang K, Chai C, Wang R, Zhuang X, Bai T, Qiu J, Cao L, Fan J. Harnessing Diversity for Important Data Selection in Pretraining Large Language Models[J/OL]. arXiv (Cornell University), 2024. https://openalex.org/W4403321931.

[19] Maini P, Seto S, Bai R, Grangier D, Zhang Y, Jaitly N. Rephrasing the Web: A Recipe for Compute and Data-Efficient Language Modeling[C/OL] // Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). [S.l.]: Association for Computational Linguistics, 2024: 14044–14072. https://aclanthology.org/2024.acl-long.757/.

[20] Kaddour J. The MiniPile Challenge for Data-Efficient Language Models[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4366330500.

[21] Xie S M, Pham H, Dong X, Du N, Liu H, Lu Y, Liang P, Le Q V, Ma T, Yu A W. DoReMi:

Optimizing Data Mixtures Speeds Up Language Model Pretraining[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4377121615.
[22] Fan S, Pagliardini M, Jaggi M. DoGE: Domain Reweighting with Generalization Estimation[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4387947154.
[23] Ye J, Liu P, Sun T-C, Zhan J, Zhou Y, Qiu X. Data Mixing Laws: Optimizing Data Mixtures by Predicting Language Modeling Performance[J/OL]. arXiv (Cornell University), 2024. https://openalex.org/W4393213783.
[24] Chen M F, Roberts N, Bhatia K, Wang J, Zhang C, Sala F, Ré C. Skill-it! A Data-Driven Skills Framework for Understanding and Training Language Models[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4385373703.
[25] Pan R, Zhang D, Zhang H, Pan X, Xu M, Zhang J, Pi R, Wang X, Zhang T. ScaleBiO: Scalable Bilevel Optimization for LLM Data Reweighting[J/OL]. arXiv (Cornell University), 2024. https://openalex.org/W4400222097.
[26] Thakkar M, Bolukbasi T, Ganapathy S, Vashishth S, Chandar S, Talukdar P. Self-Influence Guided Data Reweighting for Language Model Pre-training[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4389519618.
[27] Sow D, Woisetschläger H, Bulusu S, Wang S, Jacobsen H, Liang Y. Dynamic Loss-Based Sample Reweighting for Improved Large Language Model Pretraining[J/OL]. arXiv (Cornell University), 2025. https://openalex.org/W4407359523.
[28] Hammoudeh Z, Lowd D. Training data influence analysis and estimation: a survey[J/OL]. Machine Learning, 2024. https://openalex.org/W4393306008.
[29] Choe S, Ahn H, Bae J, Zhao K, Chung Y, Pratapa A, Neiswanger W, Strubell E, Mitamura T, Schneider J G, Hovy E, Grosse R B, Xing E P. What is Your Data Worth to GPT? LLM-Scale Data Valuation with Influence Functions[C/OL] // Advances in Neural Information Processing Systems 38. 2025 : 162015 – 162056. https://proceedings.neurips.cc/paper_files/paper/2025/hash/d6d26053b977f8c589669fd201615119-Abstract-Conference.html.
[30] Chang T A, Rajagopal D, Bolukbasi T, Dixon L, Tenney I. Scalable Influence and Fact Tracing for Large Language Model Pretraining[J/OL]. arXiv (Cornell University), 2024. https://openalex.org/W4404304976.
[31] Ki N, Choi H, Chung H W. Data Valuation Without Training of a Model[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4313531492.
[32] Jiang K F, Liang W, Zou J, Kwon Y. OpenDataVal: a Unified Benchmark for Data Valuation[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4381562228.
[33] Carlini N, Tramèr F, Wallace E, Jagielski M, Herbert-Voss A, Lee K, Roberts A P, Brown T B, Song D, Úlfar Erlingsson. Extracting Training Data from Large Language Models[J/OL]. arXiv (Cornell University), 2020. https://openalex.org/W3112689365.
[34] Nasr M, Carlini N, Hayase J, Jagielski M, Cooper A F, Ippolito D, Choquette-Choo C A, Wallace E, Tramèr F, Lee K. Scalable Extraction of Training Data from (Production) Language Models[J/OL]. arXiv (Cornell University), 2023. https://openalex.org/W4389216598.
[35] McIntosh T R, Sušnjak T, Arachchilage N, Liu T, Watters P, Halgamuge M N. Inadequacies of Large Language Model Benchmarks in the Era of Generative Artificial Intelligence[J/OL]. arXiv, 2024. https://arxiv.org/abs/2402.09880.

（二）研究内容：

（提纲不做限制，请按照研究工作的自身逻辑撰写。应提炼出特色与创新点、年度研究计划）

1.1 研究内容

本项目围绕“相近低质量表征为何形成不同作用路径与反事实响应”这一中心问题，将结构缺陷削减和非冗余语义支持损失拆分为两条可独立反证的路径。研究对象限定为许可可追溯的公开中文语料与小中规模开源自回归模型的继续预训练。主要结果由训练运行层面的路径效应、处理特异性、能力定向梯度对齐和独立来源复核共同判定，不以质量评分器的榜单性能或最优筛选阈值判定。

研究内容一：构建中文低质量表征“同分异源”的可识别样本层。 选择两个彼此独立、许可和版本可核验的公开中文语料来源。来源 A 用于形成和检验假设，来源 B 仅在协议冻结后用于外部复核，并须具有足够的目标语体独立 token、独立站点/时间层和可执行的跨来源近邻去重；任一条件不满足时，来源 B 只复核仍满足准入条件的路径。对语料完成来源审计、隐私和敏感内容处理、文档级与跨文档去重、语言/编码检查及数据卡记录，按来源、主题/实体、语体与重复簇建立索引。正式语料名称将在许可与独立 token 审计后确定，暂定一个异质网页/社区来源与一个相对规范的百科或知识来源；若严格处理后任一关键臂无法提供共同训练预算所需的独立 token，则所有臂统一下调预算，不以重复曝光补足。

在中文现象上，预注册一类结构完整、来源可核验但模型低熟悉的中文语体作为确认性对象，暂定为规范书面表达与网络/地域书写语体的语义匹配对；另从简繁/异体或中英混写中选择一种作稳健性复核。对照定义不依赖“是否规范”的价值判断，而由四项可观测条件共同确定：结构与语义完整性经人工复核，来源可追溯，语料中出现频率较低，独立定位模型判断的处理前熟悉度较低。候选定位使用与确认性基座、诊断集和最终测试集隔离的数据分片与评分模型；确认性基座的处理前熟悉度只作为冻结协变量和效应调节量，不参与样本纳入。两名以上标注者在不知道质量分和实验结果的条件下判断结构完整、语义保持、事实一致与语体属性；一致性不足时先修订标注规范，不进入确认性训练。

质量表征至少包含两类异质信号：一类为独立定位模型给出的困惑度或可学习性连续分数，另一类为来源/规范性分类或多维质量分数[15, 16, 17, 10]。质量分只用于定位结构破损样本与完整低熟悉语体的分数重叠区域，不作为因果暴露，也不读取确认性训练或能力结果。对两类样本进行分层匹配并报告分数、长度、来源、主

题和 tokenization 的平衡情况；若“同分”只出现在一个评分器或无法达到预注册重叠标准，则中心“低质量表征效用异质性”命题判为不成立。此后两条干预至多作为结构损伤和支持广度的独立子研究，不再用于支持本项目题目所述中心结论。

研究内容一将形成可审计的数据卡、中文语体操作定义、人工标注规范、两类评分器版本、同分样本层和六个处理臂的确定性生成器。此阶段依据许可可追溯性、人工一致性、语义保持、评分重叠和处理臂平衡验收，不提前比较模型性能。通过验收的样本层用于后续两条路径的随机干预。

臂	唯一处理	所属对比
A0	共同破损前体经精确逆操作恢复，保留目标语体	两条路径共同参考
A1	保留共同前体的结构破损状态	结构损伤总效应
A2	对共同破损前体作等量无效操作，不恢复结构	结构处理特异性
A3	移除目标语体，补入等 token 主流文本	支持损失/伪补回
A4	移除同一集合，补入同语体非冗余样本	支持补回主臂
A5	移除同一集合，补入同语体窄支持样本	排除单纯语体曝光

A0–A2 与 A3–A5 使用互不重叠的目标文档集合；各主对比共享背景池与训练预算，只改变表中所列处理。A0 中结构目标由共同破损前体经精确逆操作恢复，语体目标则保持原支持，是两条路径的共同参考；两个路径的估计量不作方向比较。

研究内容二：识别结构缺陷削减的训练效应、动力学证据及来源边界。 针对段落错序、异常截断和连接结构破坏等可逆低层缺陷，从研究内容一的结构完整文档中随机生成共同破损前体。A1 保留该破损状态，A0 对前体实施精确逆操作恢复原结构，A2 对同一前体实施操作次数、位置与长度变化匹配但不恢复结构的 sham；A0 与 A2 经历相同次数的后续处理。优先选择能够保持核心语义单元、字符/token 长度与序列边界近似可比的操作；对无法配平的编辑记录其 tokenization、截断和 packing 差异，不据此作机制归因。三臂保持来源、主题、文档数、非 padding token、更新步数、优化器、数据顺序区组和总训练预算一致。

在来源 A 的同一初始 checkpoint 上，对三个处理臂进行成对随机继续预训练。训练运行是主推断单位，同一主种子成对控制语料抽样、batch 顺序、dropout 和评测随机性；token、checkpoint 和 benchmark 条目均不作为额外重复。结构路径的主要能力终点为预注册的通用语言与知识保持聚合指标，主要对比为“结构完整相对结构破损”的总效应，以及“结构完整相对 sham 编辑”的处理特异效应。能力结果揭盲前先完成结构标签、语义保持、tokenization 和 packing 的操纵验收；预期排序锁定为结构完整优于结构破损和 sham，且结构破损与 sham 落入预设等效区间。若

sham 与完整等效，首先判为操纵失败或当前剂量下结构效应不可识别，结构路径停止，不以优化器重调作事后挽救。

主动力学读出定义为“能力定向梯度对齐”：在确认性结果揭盲前固定的 checkpoint 和 probe mini-batch 上，对模型末层低秩投影梯度计算处理语料与完全独立能力诊断集之间的单位 token 归一化余弦；内积只作敏感性分析。主公式、投影维度、checkpoint 位置、probe 生成规则和归一化方式写入冻结分析清单，同一 manifest 只产生一个主读数。它表征局部更新对诊断目标的一步预期方向，不等同于完整因果中介。损失波动、梯度有效秩、裁剪率和遗忘率作为次级稳健性指标。只有当处理先改变主读出、主读出对独立后测能力有留出预测增益，并且原文恢复时读出与能力共同逆转，才认为结果支持动力学候选机制；任何一项失败均降低结论强度，不以次级指标替换主结果。

来源 A 上的分析完成后，冻结结构操纵、主终点、动力学读出、效应方向、预测区间和统计代码，在来源 B 上只复核 A0–A1 主对比，不重新选择阈值和指标。来源或操纵验收失败判为不可复核，区间过宽判为证据不足；只有条件均通过后效应仍反号或持续落在冻结区间之外、且一次固定预算校准无改善时，才拒绝该结构效应外推。研究内容二最终给出结构路径的运行级效应、恢复特异性、动力学证据及来源边界。

研究内容三：识别非冗余语义支持损失及其状态—来源—尺度边界。 从研究内容一的确认性中文语体中固定一个待移除集合，在相同背景池和训练预算下构造四种状态：保留原语体支持的完整参考；移除目标语体后补入等 token、匹配长度与质量分的主流文本；移除同一集合后补入不重合、非冗余的同语体样本；移除同一集合后补入同语体等量重复或主题/实体高度集中的窄支持样本。目标语体内部的非冗余广度优先由来源、主题/实体分层和去重簇定义，嵌入覆盖指标只作辅助验证，避免用另一个黑箱分数重新定义“支持”。

支持路径先以 A0–A3 定义移除目标语体并以主流文本补回所产生的支持损失总效应，再用两个必要特异性对比解释该损失：A4–A3 判断同语体非冗余补回的恢复效应，A4–A5 排除“只要增加同语体 token 曝光即可”的替代解释。主要能力终点为目标语体与长尾能力聚合指标；完整路径还要求 A4 与 A0 落入预注册等效范围。若 A4 优于 A3、A5 但未与 A0 等效，只称部分恢复；若非冗余与窄支持均优于主流补回但二者无差异，结论收缩为语体曝光效应；若三者无差异，则支持路径不成立。

评价集与训练补回语料按文档、作者/站点、时间、主题和高阶表达模板隔离，并在不同词汇重叠阈值下重复分析，以排除直接记忆和评测对齐。能力定向梯度对齐在本内容中改用独立目标语体诊断集，检验同等语体曝光下非冗余支持是否形成更面向目标能力的更新。诊断集不兼作最终能力测试。

来源 A 上的支持路径通过后，一方面从同一基础训练轨迹的两个共同 checkpoint 随机分叉，检验“非冗余补回—窄支持补回”差异的状态调节；另一方面冻结 A4–A3 的处理规则、主终点、动力学读出、效应方向、预测区间和统计代码，在来源 B 上进行有限复核，不重新选择语体、阈值和指标。来源/操纵失败、区间过宽与条件通过后的真实异质分别报告，只有最后一类可触发拒绝外推。若两条路径在来源 B 均不保持方向，取消模型尺度探索；否则仅在同 tokenizer 家族的较大模型上复核少数关键臂。研究内容三最终给出支持恢复效应、语体曝光与非冗余广度的区分、动力学读出及状态—来源—尺度边界。

1.2 研究目标

总体目标是建立并检验中文预训练语料低质量表征效用异质性的双路径解释，获得结构缺陷削减与非冗余语义支持损失的路径特异证据、训练动力学候选机制及有限外部边界。

具体目标为：（1）形成可复核的中文“分数重叠、生成机制不同”样本层和反事实语料生成协议，区分结构完整性、模型熟悉度与静态质量评分；（2）估计结构修复相对破损与 sham 编辑的运行级效应，检验能力定向梯度读出的时间有序性、可恢复性及来源边界；（3）在语体曝光量匹配时区分同语体非冗余支持、同语体窄支持与主流文本补回，确定支持损失的动力学证据及状态、来源与尺度边界。

上述目标均不以“模型性能必须提升”为完成条件。若结构或支持路径被负对照否定，项目将按预注册规则删除相应机制，并报告可替代解释及其边界；这种可反证性本身是研究目标的组成部分。

1.3 拟解决的关键科学问题

结构缺陷路径。 在语义单元、来源、分词/packing 与训练预算匹配的可逆干预中，结构破损及其原文恢复如何改变能力定向梯度对齐；该读出是否构成通向独立通用能力变化的可重复候选中介？

非冗余支持路径及状态边界。 在低频中文语体 token 曝光量与静态质量匹配时，非冗余支持相对等量重复/窄支持是否产生特异的语体与长尾能力增益；该效应如何受共同 checkpoint 的处理前知识状态调节？

有限外部效度。 两条随机干预效应及其能力定向梯度读出中，哪些能在独立中文语料来源中复现，哪些只能在固定目标样本预算下校准；何种支持不足或不确定性应触发拒绝外推？

1.4 研究方法与技术路线

总体技术路线。 以两个可追溯的公开中文语料来源为输入，先由研究内容一构建“同分异源”样本层和六臂反事实语料；然后并行进入研究内容二的结构缺陷削减路径和研究内容三的非冗余语义支持路径。两条路径均先在来源 A 进行成对随机继续预训练和动力学检验，再将存活对比冻结后转入来源 B 复核，最终给出路径是否成立及其状态、来源和尺度边界。

总体流程为：来源审计与盲法标注 → 同分样本层与六臂语料 → 来源 A 双路径随机干预 → 能力与动力学联合判定 → 来源 B 冻结复核。

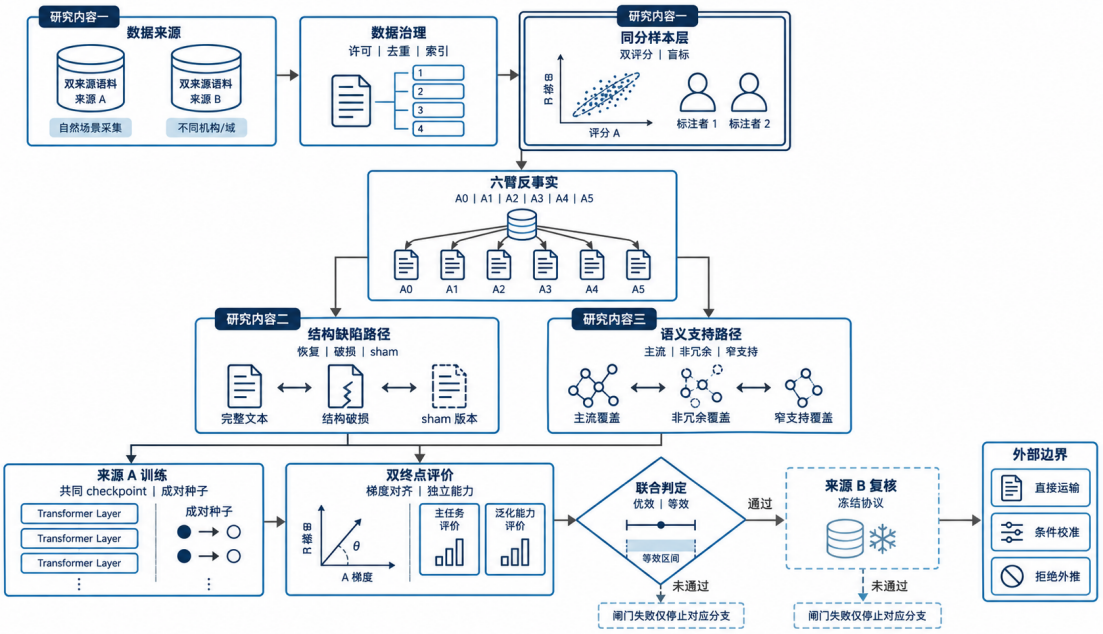


图 2. 三项研究内容与双路径证据闭环总体框架

共性训练、测量与统计方法。 研究内容二、三共用约 1B 规模开源基座，每个处理臂设六个成对主种子，匹配非 padding token、序列长度、优化器、更新步数与训练 FLOPs。单次训练暂定 0.40B token，实际值仅根据先导吞吐、独立语料规模和揭盲前功效模拟校准。训练运行 r 是唯一主推断单位，checkpoint、batch 和 probe 文档不作为额外重复。

在 checkpoint t 上，定义处理臂 a 对能力 k 的定向梯度对齐为

$$G_{rkt}^{(a)} = \frac{\left\langle g_{\text{train},rt}^{(a)}, g_{\text{probe},kt} \right\rangle}{\left\| g_{\text{train},rt}^{(a)} \right\|_2 \left\| g_{\text{probe},kt} \right\|_2}, \tag{1}$$

其中两类梯度都经单位 token 归一化并投影到预先固定的末层低秩子空间。仅当处理先改变 G、G 对独立后测能力具有留出预测增益，并在恢复或支持补回时与能力共同逆转，才视为候选动力学证据。两条主路径各预分配单侧 $\alpha = 0.025$，以六个配对区组的精确符号翻转检验和交并式联合规则作正式判定。训练、probe 与最终测试集分层隔离，所有运行由唯一 manifest 追踪。

研究内容一对应路线：同分异源样本层构建。 以两个公开中文来源为输入，完成许可、隐私、去重和来源审计，建立来源—语体—主题/实体—重复簇索引。以困惑度/可学习性和来源/规范性两类分数组成 $\mathbf{s}(x)$，将结构破损样本 x_i^{dam} 与完整低熟悉语体 x_j^{lf} 的可匹配集定义为

$$\mathcal{M}_\varepsilon = \left\{ (i,j) : \left\| \widetilde{\mathbf{s}}(x_i^{\text{dam}}) - \widetilde{\mathbf{s}}(x_j^{\text{lf}}) \right\|_\infty \le \varepsilon,\ B_{ij} = 1 \right\}, \tag{2}$$

其中 B_{ij} 表示长度、来源、主题和 tokenization 已通过预注册平衡，ε 在不读取能力结果时冻结。两名以上标注者盲法复核结构完整、语义保持、事实一致和语体属性，关键维度 Krippendorff α 低于试标后冻结的阈值则返工。

对 $\mathcal{M}_\varepsilon$ 中的样本分层匹配，以统一背景池生成 A0–A5，并审计独立 token、重复曝光、语体比例、主题覆盖、padding、截断和 FLOPs；主对比的有效 token 或 FLOPs 偏差暂定不超过 2%。本路线输出数据卡、标注规范、同分样本层和确定性六臂生成器；许可、一致性、语义保持、分数重叠与臂间平衡均通过后，分别向研究内容二、三输出互不重叠的目标文档。

研究内容二对应路线：结构缺陷削减的效应、动力学与来源边界。 以研究内容一产出的结构完整文档和生成器为输入，建立共同破损前体：A1 保留段落错序、异常截断或连接破坏，A0 依索引精确恢复，A2 执行等量但无恢复作用的 sham。三臂通过 tokenization、packing、曝光量和训练预算验收后，从来源 A 的共同 checkpoint 成对继续预训练。对运行 r 的通用能力终点 $Y_r(a)$，定义

$$\tau_{\text{str}} = \mathrm{E}_r[Y_r(\mathrm{A0}) - Y_r(\mathrm{A1})], \qquad \tau_{\text{spec}} = \mathrm{E}_r[Y_r(\mathrm{A0}) - Y_r(\mathrm{A2})]. \tag{3}$$

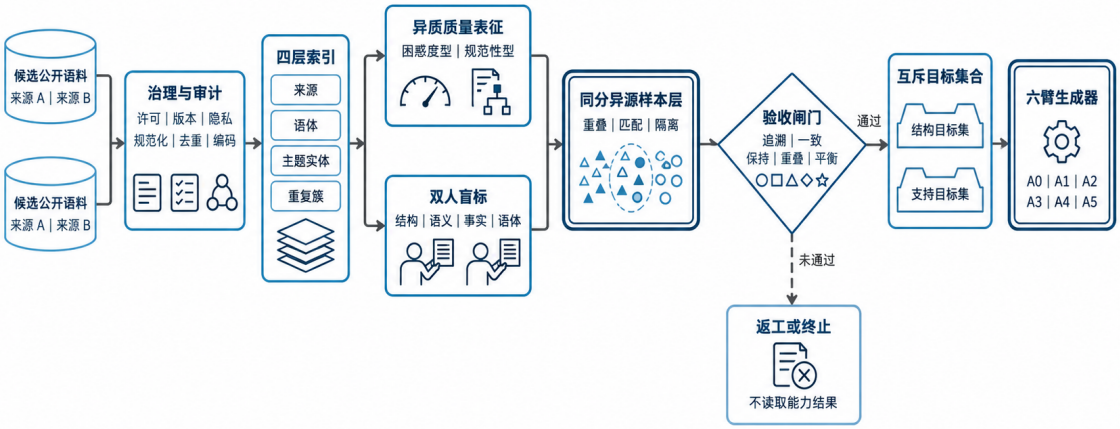


图 3. 研究路线一：同分异源样本层构建与验收

τ_{str} 估计结构恢复相对破损的总效应，τ_{spec} 检验该效应是否超出等量编辑本身。

两个对比的单侧 97.5% 随机化反演置信下界均超过各自最小实践意义阈值，且 G 满足时间先行、留出预测和恢复共同逆转时，才确认完整结构路径。随后冻结 A0–A1 的处理规则、方向、区间和代码，在来源 B 复核：准入/操纵失败判为不可复核，区间过宽判为证据不足，条件通过后仍反号或超出冻结区间才触发校准或拒绝外推。本路线输出结构效应、动力学证据及来源边界，路径失败则停止其外部复核。

研究内容三对应路线：非冗余语义支持的效应、动力学与状态—来源—尺度边界。以研究内容一确认的目标语体、主题/实体层与去重簇为输入，固定同一待移除集合：A0 保留完整支持，A3 以等 token 主流文本补回，A4 以同语体非冗余样本补回，A5 以同语体窄支持补回。四臂通过语体曝光量、长度、质量分、tokenization、packing 和预算平衡后成对继续预训练。以目标语体/长尾能力 $Z_r(a)$ 为终点，定义

$$\tau_{\text{loss}} = \mathrm{E}_r[Z_r(\mathrm{A0}) - Z_r(\mathrm{A3})], \tag{4}$$

$$\tau_{\text{restore}} = \mathrm{E}_r[Z_r(\mathrm{A4}) - Z_r(\mathrm{A3})], \quad \tau_{\text{breadth}} = \mathrm{E}_r[Z_r(\mathrm{A4}) - Z_r(\mathrm{A5})]. \tag{5}$$

三个效应分别表征支持损失、非冗余补回和超出单纯语体曝光的支持广度效应。完整恢复还需满足

$$\mathrm{CI}_{95\%}(\mathrm{E}_r[Z_r(\mathrm{A4}) - Z_r(\mathrm{A0})]) \subset [-\Delta_{\text{eq}}, \Delta_{\text{eq}}], \tag{6}$$

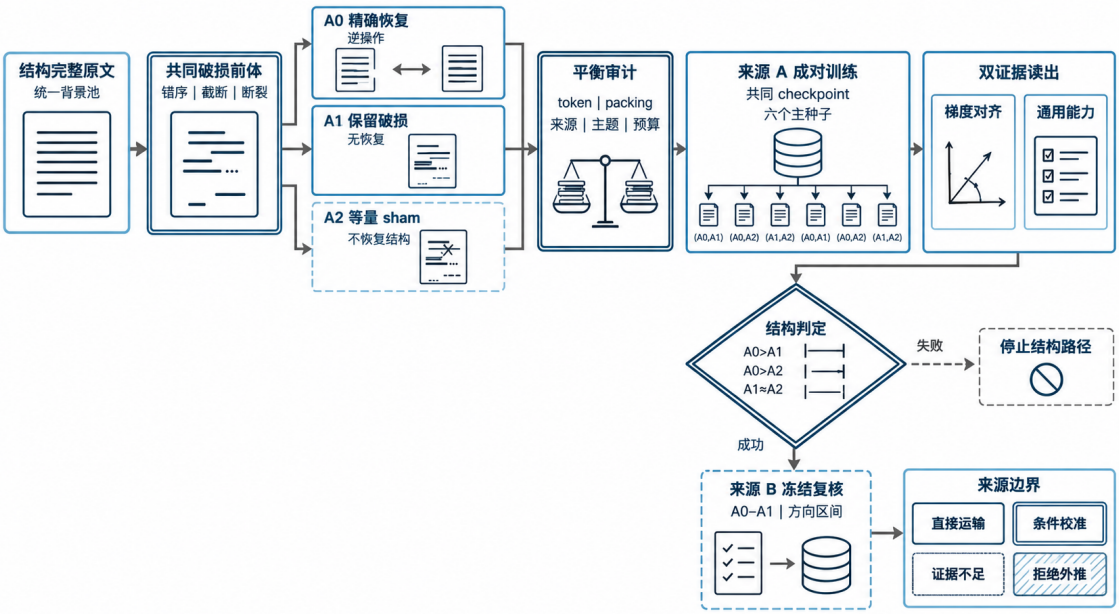


图 4. 研究路线二：结构缺陷削减、动力学判定与来源边界

其中 Δ_{eq} 由 benchmark 重测误差与科学最小意义在揭盲前冻结。

三个优效对比的单侧 97.5% 置信下界均超过阈值，且上述等效条件成立时，才确认完整支持路径；A4 未与 A0 等效时只称部分恢复，A4 与 A5 无差异时收缩为语体曝光效应。主路径通过后，从两个共同 checkpoint 分叉检验状态调节，并将 A4–A3 冻结后转入来源 B 复核；复核采用与研究内容二相同的准入、证据不足与拒绝外推规则。本路线输出支持效应、动力学读出及状态—来源—尺度边界；仅在至少一条路径于来源 B 保持方向时，才在同 tokenizer 家族较大模型上进行少量复核。

1.5 关键技术

结构与语义支持的可分离干预。 关键不是生成更多清洗版本，而是在保持语义支持时改变结构缺陷、在保持语体曝光时改变非冗余广度。需建立可逆结构编辑、等编辑量 sham、主题/实体分层补回和重复簇控制，使每个主对比只改变预定路径；无法达到预注册平衡时主动放弃强因果措辞。

能力定向梯度读出的低成本测量。 全数据、全参数影响函数不适合本项目资源。拟在固定的少量 checkpoint、probe 文档和末层/低秩梯度投影上计算目标定向对齐，统一单位 token 归一化和诊断集隔离；通过留一种子、留一来源预测与恢复共同逆转检验其有效性，控制计算与存储开销。

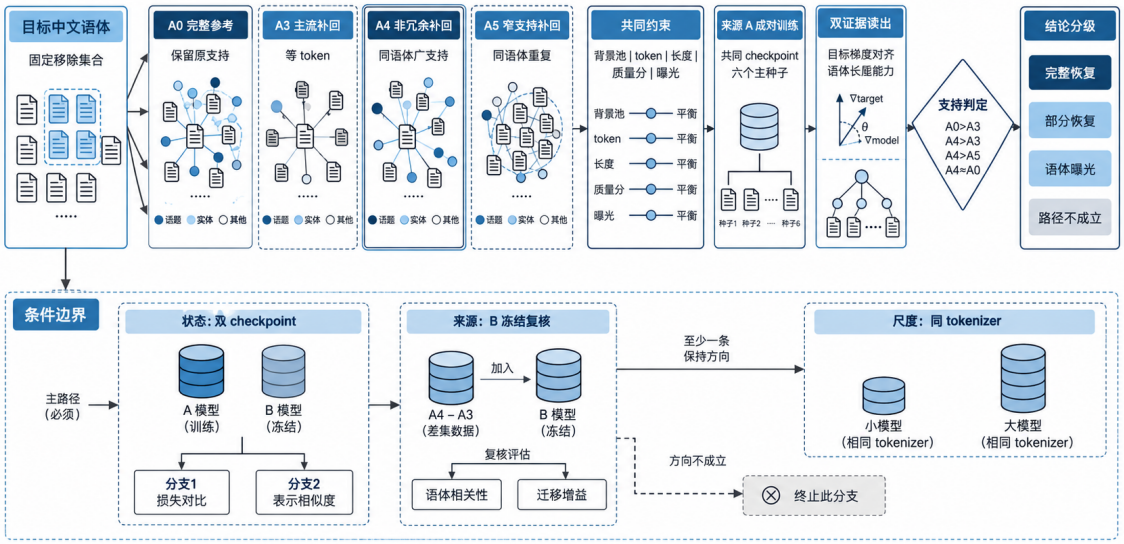


图 5. 研究路线三：非冗余语义支持及状态—来源—尺度边界

运行级可重复与泄漏防控。 所有科学运行由唯一 manifest 登记数据版本、处理臂、种子、token、优化配置、checkpoint 和评价版本；统计代码禁止把 checkpoint、题目或文档当作独立复制。训练、诊断和测试按多层近邻关系隔离，避免同语体恢复被直接记忆解释。来源 B 严格沿用来源 A 确定的协议，以降低外部验证中的二次调参偏差。

1.6 可行性分析

理论与方法可行。 数据筛选、多维评分、领域重加权与影响估计已形成可用方法基础[18, 21, 22, 28, 30]。本项目不需发明全新的通用预训练框架，而是把成熟的语料处理与梯度观测工具置于可逆干预和负对照中，用更严格的识别问题约束方法选择。主假设可由六个处理臂和两个能力终点直接支持或否定，统计层级明确。

数据与合规可行。 研究只纳入许可、来源和版本可核验的公开中文语料，先完成数据卡和可公开范围审计再训练。确认性语体只选一类，另一类作复核，避免现象清单膨胀。若目标语体不足以支持预定独立 token，则统一降低所有臂预算或收缩为较小代理模型，不重复曝光稀缺语料以制造样本量。

计算条件可行。 申请人团队现有稳定可用计算条件包括 A40 GPU 8 张和 RTX 3090 Ti GPU 6 张。处理 token 上限拆分为：首年六臂工程先导 $6 \times 0.10 = 0.6$B，来源 A 确认性训练 $36 \times 0.40 = 14.4$B，来源 B 冻结主对比复核 $24 \times 0.40 = 9.6$B，可选状态

和尺度探索至多 2.8B，合计约 27.4B；其中可选 2.8B 在闸门失败或资源不足时取消。首年另以不超过 10M token 的 smoke test 实测吞吐、显存、I/O、checkpoint/probe 存储和评测成本，换算 GPU 时及失败重跑余量后再冻结年度运行矩阵；不把尚未落实的 A100 条件计入方案。

组织与风险可控。 数据许可、标注、训练、统计和泄漏审计之间有清晰接口，团队可按职责分工并用统一 manifest 汇总。停止规则预先覆盖操纵失败、路径无效和外部反号：评分重叠失败时，结论限于评分器的条件失配；sham 操纵不合格时停止结构路径，不报告处理特异结论；非冗余与窄支持无差异时，只保留语体曝光解释；动力学读出失败时，保留随机化总效应并删除候选机制解释；来源 B 的来源/操纵失败、估计不精确和真实异质分别报告。分阶段规则避免因单个环节失败而扩大实验搜索范围。

1.7 项目特色

本项目不把中文语料质量研究处理成“再训练一个评分器”或“寻找更优过滤阈值”，而是把相近低质量表征背后的生成原因作为研究对象。结构破损与结构完整但模型低熟悉的中文语体，可能在困惑度、规范性或高质量来源相似度上获得近似判断；本项目利用中文语体与书写异质性构造确认性反例，并以可逆修复、特异支持恢复和伪恢复检验两类样本的训练效用是否来自不同路径。结果即使不产生更高的平均榜单分，只要能支持或否定路径假设，仍可形成关于语料质量表征含义的科学结论。

项目还把失败边界纳入研究设计。结构或支持路径未通过负对照时即删除相应机制，独立来源中出现反号或校准失败时明确拒绝外推，不通过增加语体、阈值和模型寻找有利结果。这套分阶段判定规则使“路径是否存在、何时成立、何时不能迁移”具有同等证据地位。

1.8 创新点

（1）从质量—覆盖相关权衡推进到低质量表征的路径特异分解。 现有工作已认识到强过滤可能损失多样性，本项目不重复这一结论，而是用保持语义支持的结构完整/破损与 sham 对照、同语体非冗余补回、同语体窄支持补回和主流文本伪补回定义两套反事实，分别识别结构缺陷损伤及非冗余语义支持损失。两套估计量不被直接解释为同一种过滤效应的方向比较，其路径特异性由负对照和等效区间判定，不依赖一个可任意加权的综合质量分。

（2）检验中文表面规范性与训练效用的非等价机制。 以语义匹配的规范书面表达和结构完整但模型低熟悉的中文语体为确认性对象，比较至少两类异质质量表征，检验模型低熟悉度是否被误作数据低质量；再以能力定向梯度对齐和独立能力终点区分其与真实结构破损的学习后果。中文在这里是产生“评分相近、因果来源不同”压力测试的理论条件，而非更换数据集的本地化标签。

（3）揭示双路径效应的非对称外部边界。 结构路径重点检验效应方向能否在独立来源保持，支持路径重点检验其随处理前知识状态和目标支持重叠变化的条件效应。来源 A 的协议、效应方向和区间在进入来源 B 前冻结，以“直接运输—条件校准—拒绝外推”描述结果。创新落在两条路径具有何种不同的外部效度结构，校准和拒绝规则仅为检验工具，不被包装成新的通用算法。

1.9 年度研究计划

以下按四个执行年度编排，具体起止年月须以当年度项目指南和批准通知为准。

第一执行年度：操作定义、数据治理与操纵验证。 完成两个候选公开中文来源的许可、版本、隐私和独立 token 审计，确定来源 A/B；冻结一类确认性中文语体和一类稳健性复核现象，形成结构完整性、语义保持、事实一致与语体属性的盲法标注规范。实现困惑度型和来源/规范性型两类质量表征，构建分数重叠样本层与六臂反事实语料生成器。完成每臂一次、单次暂定 0.10B token 的非推断性工程先导，检验评分重叠、人工一致性、sham 有效性、语义保持、token/packing 平衡和训练稳定性；单次先导不用于估计种子间方差或证明等效。里程碑为数据卡、标注一致性报告、六臂平衡表、冻结的统计分析计划和可复现 smoke test；任一操纵不合格先返工，不进入确认性训练。

第二执行年度：来源 A 的双路径确认与动力学检验。 在固定约 1B 开源基座上执行六个处理臂、六个全新成对主种子的继续预训练，单次 token 暂定 0.40B，并以首年吞吐、独立语料规模和功效模拟校准。完成通用语言/知识与目标语体/长尾两个主能力终点的运行级分析，检验结构完整相对破损与 sham 的恢复特异性，以及同语体非冗余补回相对主流和窄支持补回的支持特异性。同步计算能力定向梯度对齐，判断其是否满足处理先行、恢复共同逆转和留出预测增益。里程碑为两条路径的效应/等效区间、候选机制判断和继续/收缩/停止决定；失败分支不进入后续外推。

第三执行年度：独立来源的冻结协议复核。 将来源 A 中存活路径的处理规则、主终点、主动力学读出、效应方向、预测区间和代码冻结，在来源 B 上复核结构完整/破损和主流/同语体非冗余补回四个关键臂，暂定每臂六个成对种子、每次 0.40B token。该阶段只运输冻结主对比，不宣称再次验证 sham 或窄支持特异性；先区分来源准入失败、操纵失败、估计不精确与真实效应异质，再评价方向、冻结区间覆盖以及一次固定预算校准的误差变化。里程碑为有限运输复核报告和“直接运输、条件校准、证据不足、拒绝外推”判定，不新增来源追逐一致性。

第四执行年度：状态/尺度边界探索与综合凝练。 仅对前三年通过闸门的路径开展处理前知识状态随机分叉；若至少一条路径在来源 B 保持方向，再以同 tokenizer 家族的较大模型完成少数关键臂探索。两类实验均只报告方向、区间和失败模式，不作普遍显著性或跨架构因果主张。整合路径效应、能力定向梯度读出、来源边界与替代解释，完成论文、可复现代码、数据处理协议和可公开派生标注的整理。里程碑为双路径机制的支持/部分支持/反证结论及其适用范围。

1.10 预期研究结果

（1）形成一套可复核的中文语料结构完整性、模型熟悉度与静态质量表征分层方法，以及由结构修复、sham、主流补回、同语体非冗余补回和同语体窄支持补回构成的反事实协议。该产物强调操作定义和审计证据，不追求成为通用质量评分标准。

（2）获得结构缺陷削减相对破损与 sham 的运行级效应和反证结果，评估能力定向梯度对齐是否满足处理先行、恢复共同逆转与留出预测增益，并给出该结构效应在独立中文来源中的运输、校准或拒绝外推边界。

（3）获得非冗余语义支持损失、补回恢复和支持广度的运行级效应及等效区间，区分语体曝光与非冗余广度，检验能力定向梯度读出，并形成状态—来源—尺度边界图。具体论文数量、投稿期刊/会议、数据开放范围和软件版本根据真实结果与语料许可确定，不把平台、标准、商业模型或全部原始语料公开列为必达成果。

（三）研究基础：

1．研究基础与可行性分析（与本项目相关的研究工作积累和已取得的研究工作成绩，研究风险的应对措施等）；

1.1 与本项目相关的研究工作积累

申请人长期从事机器学习、深度学习、多源信息融合与模型训练研究，在研究问题凝练、表征与模型设计、实验组织、结果分析和软件实现方面积累了经验。这些工作尚不是中文预训练语料质量机制的专属先导研究，但可从三个方面支撑本项目：异质信息的分层表示、匹配与解耦经验，有助于区分静态质量表征、结构完整性与模型熟悉度；条件校准、状态空间推理和多层表征研究，有助于分析处理前状态、训练轨迹和能力终点之间的关系；数据治理、模型训练、自动实验、版本管理和统计评价能力，则可支撑多处理臂、成对随机种子与冻结协议的可复现实施。

在代表性工作中，申请人作为通讯作者完成了跨模态检索研究“Feature Fusion Mamba Hashing via Decoupling for Cross-Modal Retrieval”（*IEEE Signal Processing Letters*, 2026, DOI: 10.1109/LSP.2026.3652952），负责研究构思、方法设计、实验指导、结果分析及论文撰写与修改。该工作形成了对耦合因素进行分解并通过对照实验验证的研究经验，可迁移到本项目“评分相近但生成机制不同”的变量拆分。申请人作为通讯作者完成了遥感视觉问答研究“RSHR+: Progressive Question-Conditioned Visual Calibration and Structured State-Space Reasoning for Remote Sensing Visual Question Answering”（*Expert Systems with Applications*, 2026, 328: 132953, DOI: 10.1016/j.eswa.2026.132953），积累了条件校准、结构化状态建模和复杂评价组织经验。申请人作为第一作者、通讯作者完成了“Knowledge-Aware Image Understanding with Multi-Level Visual Representation Enhancement for Visual Question Answering”（*Machine Learning*, 2024, 113(6): 3789–3805, DOI: 10.1007/s10994-023-06426-6），形成了多层表示与知识相关能力评价的研究基础。

公开数据上的结构操纵预实验。 为先检查数据可得性、扰动管道和恢复对照，申请人下载了ChineseWebText2.0公开测试集（数据卡声明 Apache-2.0；原文件 1,000 条，文件哈希已归档）。按文本长度 400–600 字、发布方质量分不低于 0.35 且毒性标签为 0 筛得 122 条；固定随机种子 20270906，以 30 条选定扰动强度，其余 50 条作独立评估。预实验对每条文本生成简体归一化原文、语义/顺序不变的繁体字形变体、字符块置换扰动、依索引精确逆变换的恢复文本，以及从同一破损前体出发但不执行逆变换的 sham 文本。

在固定版本的Qwen2.5-0.5B（Apache-2.0）上，标定集从 4–128 字的候选块宽中选定 128 字，随后冻结参数。在 50 条评估样本上，原文、完整字形变体、结构扰动、

精确恢复和 sham 的中位 causal-LM loss 分别为 3.101、3.049、3.379、3.101 和 3.368，五组均未触发 1,024-token 截断。扰动相对原文的成对中位差为 0.211（95% bootstrap CI: 0.180–0.276）；精确恢复率为 100% 且恢复后损失与原文完全一致，sham 非恢复率为 100%。字符三元语言模型在另一评估集上得到相同方向，表明该方向不依赖单一评分器。

该预实验只证明公开数据/模型可访问、扰动可计算且逆操作可核查，不等同于继续预训练、能力终点或因果机制验证。扰动与字形变体虽有 0.66 的直方图重叠率，但成对中位差仍为 0.303（95% bootstrap CI: 0.220–0.360），不支持静态评分等价。而且繁简转换改变了 token 数。因此，正式研究仍须用段落错序/连接破坏替代固定字符块，完成双人语体和语义保持审计，并严格匹配 token 与 packing。上述代表成果仍只作为方法论与研究组织能力证据；本申请不主张已有性能提升或机制验证。

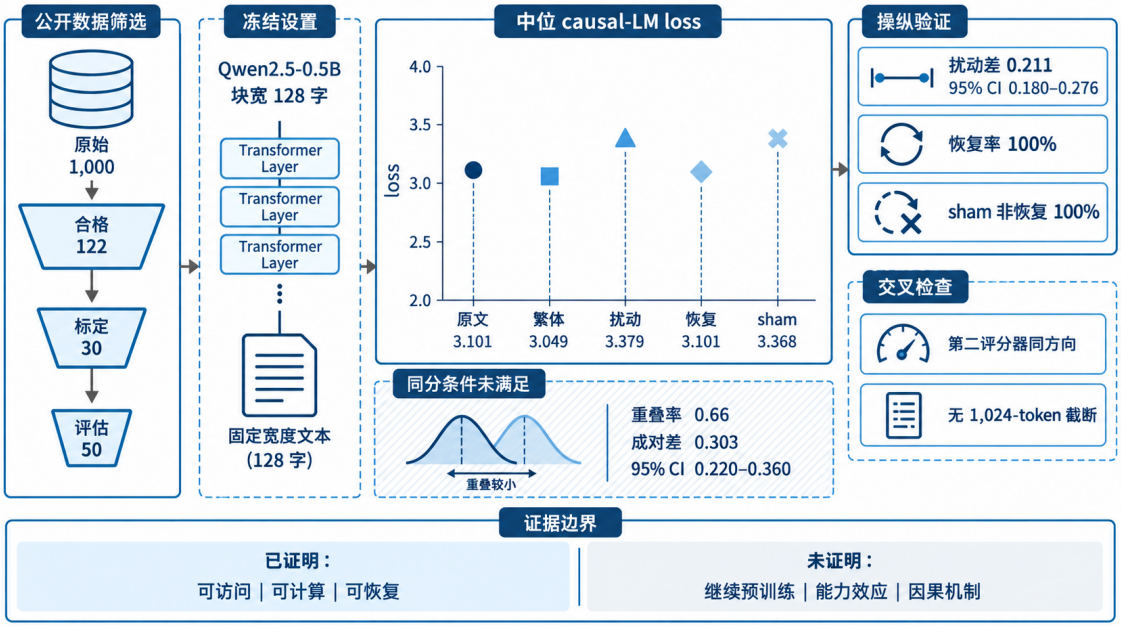


图 6. 公开数据结构操纵预实验流程、结果与证据边界

1.2 已取得的研究工作成绩

申请人已取得的相关成绩主要表现为独立组织机器学习研究、指导实验实施和完成同行评议成果的能力。前述三项代表性论文均已核验题录与作者贡献，其中两项由申请人担任通讯作者，一项由申请人担任第一作者兼通讯作者。它们分别覆盖解耦式表征融合、问题条件校准与结构化推理、多层知识相关表征，能够为本项目的路径拆分、状态条件分析和多层能力评价提供经验支撑。

申请人主持自治区高校基本科研业务费培育类项目和政企数字化知识库横向课

题，并参与国家自然科学基金地区项目等科研任务，具备项目计划、数据整理、模型研究和成果组织经验。现有在研项目的题目、经费、执行期和与本申请的关系在“正在承担的科研项目情况”中如实列示；本项目不把其他项目的论文、数据或代码自动归入当前申请，也不把参与项目的总经费视为本项目可支配条件。

在科研工程条件方面，申请人已具备 Linux、Python、深度学习框架、Git 和 LaTeX 等工具链使用基础，能够建立数据版本、训练配置、随机种子、checkpoint、评测版本和统计输出之间的追踪关系。这些条件能够支撑运行记录清单（run manifest）、双来源冻结协议和失败结果保留。上述预实验已形成公开数据版本清单、确定性扰动/恢复/sham 脚本和静态评分记录；正式语料索引、双人中文语体标注、六臂反事实生成器、继续预训练和动力学测量代码尚未形成，均列为拟开展任务。

1.3 可行性分析

理论可行性。 项目的关键不是假定某种过滤策略必然更优，而是把结构缺陷与语义支持定义为不同层级的处理，并用恢复和负对照决定路径是否成立。现有数据选择、多维质量评价、影响估计和中文能力评价方法为评分、继续预训练及测量提供了可复用工具；中心假设由结构完整/破损/sham 和主流/同语体非冗余/同语体窄支持两组对照直接约束，结果可以支持、部分支持或否定，理论链条具备闭合的反证条件。

技术可行性。 申请人在深度模型设计、条件校准、多层表示、实验指导和结果分析方面的已核验成果，能够支撑从数据表征到模型训练和评价的技术链。项目不采用全数据、全参数影响函数，而在少量固定 checkpoint、probe 文档和末层/低秩梯度投影上计算能力定向梯度对齐；确认性研究限定在约 1B 规模模型的继续预训练，来源 B 只复核关键处理臂，状态与尺度实验可按闸门取消。该设计将机制证据与资源成本同时纳入约束。

团队可行性。 申请人负责科学问题、实验协议、统计口径和成果质量控制。已确认的七名研究生参与者具备文本整理与质量审计、条件效用建模、数据处理、域泛化、语言模型训练、负迁移分析、代码整合与统计分析等互补能力。其中，孔哲、张建宏和于得武的既定任务分别与文本清洗审计、等预算效用实验和版本/日志/统计主链直接对应；其他成员围绕数据处理、模型训练与稳健性分析提供辅助。所有处理臂使用统一数据字典和 run manifest，减少多人协作导致的口径漂移。

条件可行性。 已确认可稳定使用 NVIDIA A40 8 张和 RTX 3090 Ti 6 张。A40 用于同构继续预训练，3090 Ti 用于质量评分、去重检索、benchmark 推理和 smoke test；项目不以尚未落实的 A100 或固定学院配额为前提。若首年实测吞吐和存储低于预期，优先取消尺度与状态探索并统一降低单次 token，保留来源 A 的成对主种子和关键负对照。

上述四方面与研究内容逐项对应：数据治理和标注能力用于构建同分样本层，模型与实验基础用于实施两条干预路线，工程与统计能力用于动力学测量和运行级推断，双来源协议与分阶段资源计划用于有限外部复核。公开数据预实验补充了数据可得性、扰动效应方向和逆操作可核查性证据，但不替代继续预训练先导与机制检验。

1.4 研究风险与应对措施

以下依次讨论风险一（技术操纵）、风险二（统计识别）、风险三（进度与合规）、风险四（计算资源）和风险五（外部效度），并为每项风险设置早期信号、替代路线和降级交付。

技术风险：同分样本层或反事实操纵不成立。 早期信号是结构破损样本与完整低熟悉语体无法在两类评分器上形成预设重叠，sham 编辑意外改善结构，或关键处理臂的 token、长度与 packing 无法达到等效范围。应对措施是把“同分异效”收缩为特定评分器的条件失配；优先保留最易配平的段落错序和连接破坏，重新设计 sham；仍无法配平时只报告随机化总效应，不作路径特异或中介结论。降级交付为评分器失配与操纵失败的系统审计报告。

统计风险：继续预训练效应小于运行间方差。 工程先导只检查许可、操纵、平衡、稳定性、吞吐和 benchmark 重测误差，不读取臂间效应方向。揭盲前功效模拟若显示六个成对种子不足，优先取消尺度/状态探索并把可选预算转给来源 A 增加配对种子；仍不足则将相应路径降为区间估计性研究，不改变主方向、终点、对比和效应阈值。若总效应存在而动力学读出失败，则保留总效应、删除候选机制解释。

进度与合规风险：语料许可、下载或人工复核滞后。 早期信号是来源条款无法确认、再分发边界不清、实际下载与数据卡不符，或人工标注一致性低于暂定返工线。应对措施是只纳入许可和来源可追溯的子集，以第二个候选公开来源替换不可核验来源；将标注先缩小为操作定义试验，修订规范后再扩展。若来源 B 延迟，先完成来

源 A 的确认性闭环，不以未审计数据追赶进度。

资源风险：GPU 吞吐、排队或存储不足。 早期信号是 10M token 基准运行推算的总节点小时超出可用时段，checkpoint I/O 成为瓶颈，或不同 GPU 混用导致运行不可比。应对措施是保持 A40 同构训练、3090 Ti 承担评分与评测，减少长期保存 checkpoint，仅保留共同分叉点、最终模型和压缩动力学统计；按“取消尺度探索—取消状态探索—统一下调 token”的顺序收缩，不把未落实设备写入解决方案。

外部效度风险：来源 B 复核失败。 先检查来源准入、目标语体独立 token 和操纵有效性；这些条件失败只说明复核不可实施。条件通过但区间过宽时报告证据不足；只有效应反号或持续落在来源 A 冻结区间之外且一次预注册校准无改善时，才判为拒绝外推边界。各类失败分别报告，不追加来源和模型追求同向结果。

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、全国重点实验室和部门重点实验室等研究基地的计划与落实情况）；

2.1 已具备的实验条件

计算与软件条件。 申请人已确认可稳定使用 NVIDIA A40 GPU 8 张和 RTX 3090 Ti GPU 6 张，并具备 Linux、Python、深度学习框架、Git 与 LaTeX 等软件和工程工具链。A40 可组成同构训练环境，承担约 1B 规模开源模型的成对继续预训练；3090 Ti 用于质量评分、去重检索、人工审计辅助、模型推理和小规模 smoke test，避免异构显卡混入同一同步数据并行作业。现有工具链能够记录数据版本、代码提交、模型配置、随机种子、日志与统计结果，支撑双来源冻结协议。

人员与任务条件。 申请人具备研究构思、模型设计、实验指导、结果分析和论文写作经验，负责总体科学问题、干预协议、统计口径与成果质量控制。七名已确认参与的新疆大学研究生计划在项目周期内参与：孔哲负责低资源文本整理、清洗与质量审计，张建宏负责条件效用建模与等预算样本选择实验，于得武负责代码整合、版本管理、实验日志与统计分析；杨铄、孟星宇、桑乐、吕中原分别具备数据处理、域泛化/适配、语言模型训练和负迁移消融等任务基础。后四类能力作为数据处理与稳健性分析的辅助条件，不将本项目重新扩展为 OCR、多语种或多模态研究。

数据与合规条件。 本项目不依赖私有业务数据或人体受试样本。已实际下载 ChineseWebText2.0 公开测试分片，复核数据卡所声明的 Apache-2.0 许可，并记录 1,000 条原始数据的文件哈希、筛选规则和随机种子；同时已固定 Qwen2.5-0.5B 的模型 revision 与权重哈希，并完成静态 loss 复核。这些资产证明小样本下载、版本固定、扰动—恢复与日志链路可运行，不代表来源 A/B 的全量许可审计已完成。正式语料仍须逐来源检查条款、去重、隐私/敏感内容和训练—评价隔离；不能再分发的数据只保留索引、配置和统计信息，按许可决定派生标注与模型产物的开放范围。

2.2 尚缺少的实验条件及拟解决的途径

目前已形成一个公开测试分片、初版扰动/恢复/sham 脚本、两类静态评分结果和完整运行日志；尚缺用于确认性训练的正式来源 A/B 语料索引、双人语体与语义标注、六臂平衡表、继续预训练配置、能力评价脚本和消融日志。第一年度将按“完整许可/来源核验—人工试标—段落/连接层六臂生成与 token/packing 平衡审计—10M token smoke test”的顺序补齐；静态预实验不作为继续预训练或机制证据。

目前没有已落实的语言学/语料库外部合作者或专属人工标注平台。项目主方案采用可操作的结构完整、语义保持、事实一致和语体属性标注，由团队开展双人独立标注与分歧复核；如后续获得正式合作，可将专家复核作为增强条件，但不以未确认合作作为项目完成前提。标注一致性不足时先缩小样本、修订规则并重复试标，而非直接扩大人力。

学院公共算力可按流程申请，但固定账号、设备型号和额度尚未落实；A100 八卡资源也未落实，均不计入稳定条件。主方案只按已确认的 A40 与 3090 Ti 设计。若排队或存储资源不足，取消模型尺度和状态探索、减少 checkpoint 长期保留并统一下调单次 token，保留来源 A 的六个成对主种子、sham 和支持窄化对照。

来源 B 及较大模型只承担外部边界验证。若候选公开语料在许可、独立 token 或来源独立性上不满足要求，来源 B 可降级为不同来源层的严格留出环境，并明确外部效度减弱；若同家族较大模型所需显存和节点时超出首年实测预算，则直接取消尺度探索，不影响双路径核心检验。

2.3 利用研究基地的计划与落实情况

本项目当前未以国家实验室、全国重点实验室或部门重点实验室的专属设备、数据与合作承诺作为实施条件，也暂无已落实的相关研究基地使用协议。核心研究依托申请人已确认可稳定使用的计算资源和团队完成。如项目实施期间通过正式申请获得校级或更高层级公共平台资源，仅用于补充训练时段、存储和结果复核，并

在使用前记录授权范围和资源证明；未落实前不写入固定配额或既有合作。

3．正在承担的与本项目相关的科研项目情况（申请人和主要参与者正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的资助机构、项目类别、批准号、项目名称、获资助金额、起止年月、与本项目的关系及负责的内容等）；

（1）自治区高校基本科研业务费科研项目（培育类），项目编号 XJEDU2026P005，项目名称“融合多源数据大模型驱动的光伏发电功率预测方法研究”，经费 5 万元（直接经费 3.9 万元、间接经费 1.1 万元），执行期 2026 年 1 月至 2026 年 12 月，申请人主持，负责总体方案、模型研究和成果组织。该项目研究对象为光伏功率预测，与本申请的中文预训练语料质量机制在研究对象、数据、科学问题和成果上不同；其关联仅为深度模型研究与项目组织经验，不与本申请重复资助。

（2）新疆数字云创有限公司委托横向课题，合同编号 202604140013，项目名称“面向政企数字化应用的智能知识库与问答系统研发”，经费 12 万元，执行期 2026 年 6 月至 2026 年 10 月，申请人主持，合同任务为构建一个知识库，项目进行中，成果及知识产权由合同双方共同享有。该课题面向政企知识库工程交付，本申请面向中文预训练语料筛选效应的基础机制，两者不共用研究目标和考核成果；可复用的仅是数据治理和软件工程经验，任何合同数据与成果均不自动进入本申请。

上述项目的经费、数据和设备不计入本项目可支配资源。申请人将通过独立的数据版本、代码仓库、运行清单和成果标注管理项目边界，避免任务与成果重复归属。

4．完成国家自然科学基金项目情况（对申请人负责的前一个已资助期满的科学基金项目（项目名称及批准号）完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该项目的研究工作总结摘要（限 500 字）和相关成果详细目录）。

申请人未主持完成国家自然科学基金项目，故无前一个已资助期满项目的完成情况需要报告。

（四）其他需要说明的情况：

1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系；已收到自然科学基金委不予受理或不予资助决定的，无需列出）。

申请人同年申请不同类型国家自然科学基金项目的情况，须以2027年基金委申请系统中的最终申请清单为准。当前待申请人确认：【待补F-LLM-01：同年申请其他类型项目的项目类型与名称，或明确确认无此情况】。正式提交前将据此形成明确的肯定句或否定句，并与系统记录逐项核对。

2. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

本申请依托单位为新疆大学。同年申请的其他国家自然科学基金项目是否存在申请单位不一致，须以2027年基金委申请系统和依托单位科研管理记录为准。当前待申请人确认：【待补F-LLM-02：同年其他申请的项目名称与申请单位，或明确确认不存在单位不一致】。正式提交前将删除待补标记并写明核对结论。

3. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在与正在承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

申请人参与承担的在研国家自然科学基金地区项目“数据驱动下基于互补型生成对抗网络与神经统计模型的公路沙害智能预警研究”（批准号62466056）在基金委系统中的登记单位为新疆大学，与本申请依托单位一致，不存在承担中项目单位与本申请单位不一致的情况。

4. 申请人和主要参与者同年以不同专业技术职务（职称）申请或参与申请科学基金项目的情况（应详细说明原因）。

申请人当前专业技术职务为副教授。同年申请国家自然科学基金项目时是否使用不同专业技术职务，仍须逐项核对 2027 年申请记录和人事证明。当前待申请人确认：【待补 F-LLM-03：同年各项申请所用专业技术职务及不一致原因，或明确确认均为副教授】。正式提交前将据实写成明确结论。

5. 其他。

除前述事项外，是否还有需要说明的其他情况，须由申请人结合 2027 年基金委系统、依托单位要求和本人诚信声明作最终核对。当前待申请人确认：【待补 F-LLM-04：其他需说明事项的具体内容，或明确确认无其他情况】。本项不会以流程推断替代申请人本人确认。